

Введение в машинное обучение

Машинное обучение

Александр Безносиков

Московский физико-технический институт

7 сентября 2026



Система оценивания

Вид активности	Баллы
Основные домашние задания	от 0 до 5
Дополнительные домашние задания	от 0 до 2
Экзамен	от 1 до 6
Итого:	от 1 до 10



Чат курса

Канал лаборатории



Рис. 1: @brainlaboratory

Обучение с учителем (Supervised learning)

На вход подается выборка (data sample) X , состоящая из пар (x_i, y_i) :

$$X = \{ (x_1, y_1), \dots, (x_n, y_n) \}.$$

- $y_i \in \mathcal{Y}$ – значение целевой функции (переменная/target/dependent variable), $\mathcal{Y}$ – пространство меток (значений целевого признака);
- $x_i \in \mathcal{X}$ – объект (наблюдение/sample/instance), $\mathcal{X}$ – пространство объектов (входов);
- Специфика задач обучения состоит в том, что нам известны значения меток y_i .

Пространство объектов

Объекты могут быть почти произвольными:

- тексты;
- временные ряды/последовательности;
- изображения (как 2D, так и 3D/4D);
- вектора/графы;
- ...

Признаковое описание

В признаковом описании i -ый объект имеет следующий вид:

$$x_i = (x_{i1}, \dots, x_{id}) \in \mathbb{R}^d,$$

где x_{ij} – j -ый признак i -го объекта.

Матрица «объект-признак» (data matrix)

Сэмплы
(экземпляры, наблюдения)

	Длина чашелистика	Ширина чашелистика	Длина листа	Ширина листа	Класс
1	5.1	3.5	1.4	0.2	Щетинистый
2	4.9	3.0	1.4	0.2	Щетинистый
...					
50	6.4	3.5	4.5	1.2	Разноцветный
...					
150	5.9	3.0	5.0	1.8	Виргинский


Признаки
(атрибуты, измерения, размеры)

Классы
(целевые объекты)



Обучение с учителем (Supervised learning)

Основной целью является восстановление зависимости $g : \mathcal{X} \rightarrow \mathcal{Y}$, чтобы уметь восстанавливать метки на новых объектах x .



Типы задач обучения с учителем


Классификация (Classification)

Множество $\mathcal{Y}$ дискретно и $|\mathcal{Y}| = k \ll \infty$.

- 1 Бинарная: $\mathcal{Y} = \{0, 1\}$ или $\mathcal{Y} = \{-1, +1\}$
(binary classification);
- 2 k *непересекающихся* классов: $\mathcal{Y} = \{0, 1, \dots, k\}$
(multiclass classification);
- 3 k *пересекающихся* классов: $\mathcal{Y} = \{0, 1\}^k$
(multilabel classification).


Типы задач обучения с учителем (визуализация)

Бинарная классификация (Binary classification)



Типы задач обучения с учителем (визуализация)


Multiclass vs. multilabel classification



Типы задач обучения с учителем: регрессия

Одномерная линейная регрессия (linear regression)


Множество $\mathcal{Y}$ непрерывно: $\mathcal{Y} = \mathbb{R}$, так как мы считаем, что предсказываемая величина (зарплата) – вещественное число.



Типы задач обучения с учителем: регрессия

Одномерная полиномиальная регрессия (polynomial regression)


Множество $\mathcal{Y}$ непрерывно: $\mathcal{Y} = \mathbb{R}$



Типы задач обучения с учителем: регрессия

Многомерная регрессия (multi-dimensional regression)

Множество $\mathcal{Y}$ непрерывно: $\mathcal{Y} = \mathbb{R}^n$. В примере мы по количеству часов подготовки студента предсказываем вектор $(r_1, r_2) \in \mathbb{R}^2$, где r_1 – результат студента на предыдущем экзамене, r_2 – результат на текущем (к которому готовился).



Матрица «объект-признак» (data matrix)

Сэмплы

(экземпляры, наблюдения)

	Длина чашелистика	Ширина чашелистика	Длина листа	Ширина листа	Класс
1	5.1	3.5	1.4	0.2	Щетинистый
2	4.9	3.0	1.4	0.2	Щетинистый
...					
50	6.4	3.5	4.5	1.2	Разноцветный
...					
150	5.9	3.0	5.0	1.8	Виргинский


Признаки

(атрибуты, измерения, размеры)

Классы

(целевые объекты)

Лист




Чашелистик

Визуализация в двумерном пространстве признаков:



Матрица «объект-признак» (data matrix)

Визуализация в двумерном пространстве признаков:



Генерация признаков

Необходимость признаков

Чем *больше* признаков у объекта – тем *качественнее* можно применить ML подход к её решению.

Но объекты могут не быть заданы в признаковом пространстве, либо заданы неинформативно.

Пример	Неинформативно	Информативно
Вершины в графе	Номер вершины	Номер вершины, её входящая/исходящая степень, достижимость других вершин из неё
Пользователи соцсети	ID пользователя	ID пользователя, контакты, увлечения, статистика общения
Географические данные	Координаты (широта, долгота)	Координата, высота, тип объекта и другие метаданные (например, название места).

Генерация признаков (примеры)

- **Классификация спама:** $\mathcal{X}$ – письма, $\mathcal{Y}$ – бинарная величина (спам/не спам), признаки – длина письма, число вхождений слова, отправитель;
- **Прогнозирование цен акций:** $\mathcal{X}$ – ситуация на рынке, $\mathcal{Y}$ – цена на акцию через час; признаки – исторические цены, объемы торгов, новостной фон;
- **Медицинская диагностика:** $\mathcal{X}$ – пациенты, $\mathcal{Y}$ – диагнозы, признаки – результаты анализов, возраст, пол, история болезней, генетические маркеры;
- **Прогнозирование спроса на товары:** $\mathcal{X}$ – данные о продажах, $\mathcal{Y}$ – спрос на товар; признаки – сезонность, акции, цены конкурентов, отзывы покупателей, погодные условия;
- **Распознавание изображений:** $\mathcal{X}$ – изображения, $\mathcal{Y}$ – класс объекта; признаки – цветные гистограммы, текстуры, границы, ключевые точки, признаки;
- **Анализ текстовых данных:** $\mathcal{X}$ – тексты, $\mathcal{Y}$ – тематика или тональность; признаки – частота слов, n-граммы, синтаксические особенности.

Математическая постановка задачи обучения: модель и веса

- Природа может быть слишком сложной, чтобы её полноценно описать, ограничим поиск отображения из $g(\cdot) : \mathcal{X} \rightarrow \mathcal{Y}$.

Математическая постановка задачи обучения: модель и веса

- Природа может быть слишком сложной, чтобы её полноценно описать, ограничим поиск отображения из $g(\cdot) : \mathcal{X} \rightarrow \mathcal{Y}$. **Вопрос:** каким образом можно ограничить поиск g , при этом хочется удобства перебора по всем таким g ?

Математическая постановка задачи обучения: модель и веса

- Природа может быть слишком сложной, чтобы её полноценно описать, ограничим поиск отображения из $g(\cdot) : \mathcal{X} \rightarrow \mathcal{Y}$. **Вопрос:** каким образом можно ограничить поиск g , при этом хочется удобства перебора по всем таким g ?
- Введём параметризацию $g(\cdot, w)$, зависящую от **вектора весов (parameters)** w . Примеры:
 - 1 $g(x, w) = w_0 + x_1 \cdot w_1 + x_2 \cdot w_2$.

Математическая постановка задачи обучения: модель и веса

- Природа может быть слишком сложной, чтобы её полноценно описать, ограничим поиск отображения из $g(\cdot) : \mathcal{X} \rightarrow \mathcal{Y}$. **Вопрос:** каким образом можно ограничить поиск g , при этом хочется удобства перебора по всем таким g ?
- Введём параметризацию $g(\cdot, w)$, зависящую от **вектора весов (parameters)** w . Примеры:
 - 1 $g(x, w) = w_0 + x_1 \cdot w_1 + x_2 \cdot w_2$.
 - 2 $g(x, w) = \begin{cases} 1, & \text{если } x_1 + w_1 > 10, \\ 0, & \text{иначе,} \end{cases}$

Математическая постановка задачи обучения: модель и веса

- Природа может быть слишком сложной, чтобы её полноценно описать, ограничим поиск отображения из $g(\cdot) : \mathcal{X} \rightarrow \mathcal{Y}$. **Вопрос:** каким образом можно ограничить поиск g , при этом хочется удобства перебора по всем таким g ?
- Введём параметризацию $g(\cdot, w)$, зависящую от **вектора весов (parameters)** w . Примеры:
 - 1 $g(x, w) = w_0 + x_1 \cdot w_1 + x_2 \cdot w_2$.
 - 2 $g(x, w) = \begin{cases} 1, & \text{если } x_1 + w_1 > 10, \\ 0, & \text{иначе,} \end{cases}$
 - 3 часто $g(\cdot, w)$ – это композиция более атомарных функций:
 $g(\cdot, w) = g_m(\dots g_2(g_1(\cdot, w_1), w_2), \dots w_m)$.
- $g(\cdot, w)$ мы будем называть **моделью машинного обучения**.

Математическая постановка задачи обучения: функция потерь

- Глобально мы бы хотели, чтобы для любой пары (объект x , ответ y) наша модель с весами w отвечала бы следующему свойству:
 $g(x, w) = y$ (верно бы угадывала ответ).

Математическая постановка задачи обучения: функция потерь

- Глобально мы бы хотели, чтобы для любой пары (объект x , ответ y) наша модель с весами w отвечала бы следующему свойству: $g(x, w) = y$ (верно бы угадывала ответ).
- Модель с произвольными весами w очевидно может не дать хоть немного правильные предсказания природы. Чтобы "научить" модель (подобрать веса/параметры) нужно измерить степень непохожести ответов: модели и реального.

Математическая постановка задачи обучения: функция потерь

- Глобально мы бы хотели, чтобы для любой пары (объект x , ответ y) наша модель с весами w отвечала бы следующему свойству: $g(x, w) = y$ (верно бы угадывала ответ).
- Модель с произвольными весами w очевидно может не дать хоть немного правильные предсказания природы. Чтобы "научить" модель (подобрать веса/параметры) нужно измерить степень непохожести ответов: модели и реального.
- Введём функцию потерь (loss) $\ell(\cdot, \cdot)$, зависящую от двух аргументов. Примеры
 - $\ell(y_1, y_2) = (y_1 - y_2)^2$.
 - $\ell(y_1, y_2) = \begin{cases} 1, & \text{если } y_1 \neq y_2, \\ 0, & \text{иначе,} \end{cases}$

Математическая постановка задачи обучения: функция потерь

- Глобально мы бы хотели, чтобы для любой пары (объект x , ответ y) наша модель с весами w отвечала бы следующему свойству: $g(x, w) = y$ (верно бы угадывала ответ).
- Модель с произвольными весами w очевидно может не дать хоть немного правильные предсказания природы. Чтобы "научить" модель (подобрать веса/параметры) нужно измерить степень непохожести ответов: модели и реального.
- Введём функцию потерь (loss) $\ell(\cdot, \cdot)$, зависящую от двух аргументов. Примеры
 - 1 $\ell(y_1, y_2) = (y_1 - y_2)^2$.
 - 2 $\ell(y_1, y_2) = \begin{cases} 1, & \text{если } y_1 \neq y_2, \\ 0, & \text{иначе,} \end{cases}$
- Нас будет интересовать: $\ell(g(x, w), y)$.

Математическая постановка задачи обучения: формулировка

- **Вопрос:** Формально откуда берутся данные?

Математическая постановка задачи обучения: формулировка

- **Вопрос:** Формально откуда берутся данные? Они приходят из некоторой «природы» (случайного распределения) $\mathcal{D}$.

Математическая постановка задачи обучения: формулировка

- **Вопрос:** Формально откуда берутся данные? Они приходят из некоторой «природы» (случайного распределения) $\mathcal{D}$.

Цель supervised обучения

Формальная цель supervised машинного обучения – найти природу $\mathcal{D}$ в точности или приблизить её с помощью g .

Математическая постановка задачи обучения: формулировка

- **Вопрос:** Формально откуда берутся данные? Они приходят из некоторой «природы» (случайного распределения) $\mathcal{D}$.

Цель supervised обучения

Формальная цель supervised машинного обучения – найти природу $\mathcal{D}$ в точности или приблизить её с помощью g .

- Тогда задачу машинного обучения можно сформулировать следующим образом:

Математическая постановка задачи supervised обучения

$$\min_{w \in \mathbb{R}^d} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)]$$

- Получается, что мы хотим минимизировать потери модели в среднем по всей природе.

Математическая постановка задачи обучения: формулировка

- **Вопрос:** В чём проблема решения задачи оптимизации $\min_{w \in \mathbb{R}^d} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)]$?

Математическая постановка задачи обучения: формулировка

- **Вопрос:** В чём проблема решения задачи оптимизации $\min_{w \in \mathbb{R}^d} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)]$? $\mathcal{D}$ неизвестна, поэтому интеграл (математическое ожидание) никак не посчитать.

Математическая постановка задачи обучения: формулировка

- **Вопрос:** В чём проблема решения задачи оптимизации $\min_{w \in \mathbb{R}^d} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)]$? $\mathcal{D}$ неизвестна, поэтому интеграл (математическое ожидание) никак не посчитать. **Вопрос:** Как быть? Что обычно есть вместо $\mathcal{D}$?

Математическая постановка задачи обучения: формулировка

- **Вопрос:** В чём проблема решения задачи оптимизации $\min_{w \in \mathbb{R}^d} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)]$? $\mathcal{D}$ неизвестна, поэтому интеграл (математическое ожидание) никак не посчитать. **Вопрос:** Как быть? Что обычно есть вместо $\mathcal{D}$?
- Для этого как раз и используется выборка:

$$\{x_i, y_i\}_{i=1}^n \sim \mathcal{D}.$$

Математическая постановка задачи обучения: формулировка

- **Вопрос:** В чём проблема решения задачи оптимизации $\min_{w \in \mathbb{R}^d} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)]$? $\mathcal{D}$ неизвестна, поэтому интеграл (математическое ожидание) никак не посчитать. **Вопрос:** Как быть? Что обычно есть вместо $\mathcal{D}$?
- Для этого как раз и используется выборка:

$$\{x_i, y_i\}_{i=1}^n \sim \mathcal{D}.$$
- Тогда интеграл с предыдущего слайда можно приблизить с помощью следующего выражения:

Минимизация эмпирического риска (ERM)

$$\min_{w \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n \ell(g(x_i, w), y_i)$$

Математическая постановка задачи обучения: формулировка

- **Вопрос:** В чём проблема решения задачи оптимизации $\min_{w \in \mathbb{R}^d} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)]$? $\mathcal{D}$ неизвестна, поэтому интеграл (математическое ожидание) никак не посчитать. **Вопрос:** Как быть? Что обычно есть вместо $\mathcal{D}$?
- Для этого как раз и используется выборка:

$$\{x_i, y_i\}_{i=1}^n \sim \mathcal{D}.$$
- Тогда интеграл с предыдущего слайда можно приблизить с помощью следующего выражения:

Минимизация эмпирического риска (ERM)

$$\min_{w \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n \ell(g(x_i, w), y_i)$$

Вопрос: Как называется такой способ приближения интеграла?

Математическая постановка задачи обучения: формулировка

- **Вопрос:** В чём проблема решения задачи оптимизации $\min_{w \in \mathbb{R}^d} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)]$? $\mathcal{D}$ неизвестна, поэтому интеграл (математическое ожидание) никак не посчитать. **Вопрос:** Как быть? Что обычно есть вместо $\mathcal{D}$?
- Для этого как раз и используется выборка:
$$\{x_i, y_i\}_{i=1}^n \sim \mathcal{D}.$$
- Тогда интеграл с предыдущего слайда можно приблизить с помощью следующего выражения:

Минимизация эмпирического риска (ERM)

$$\min_{w \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n \ell(g(x_i, w), y_i)$$

Вопрос: Как называется такой способ приближения интеграла?
Монте-Карло сэмплирование.

Математическая постановка задачи обучения: сравнение

$$\min_{w \in \mathbb{R}^d} f(w) := \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)] \quad \text{vs} \quad \min_{w \in \mathbb{R}^d} \hat{f}(w) := \frac{1}{n} \sum_{i=1}^n \ell(g(x_i, w), y_i)$$

Хотим решить левую задачу (найти вектор w^* , дающий минимум f), а решаем правую (находим $\hat{w}^*$ для $\hat{f}$). **Вопрос:** Насколько близки эти задачи? Какие фактор могут влиять на близость?

Математическая постановка задачи обучения: сравнение

$$\min_{w \in \mathbb{R}^d} f(w) := \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(g(x, w), y)] \quad \text{vs} \quad \min_{w \in \mathbb{R}^d} \hat{f}(w) := \frac{1}{n} \sum_{i=1}^n \ell(g(x_i, w), y_i)$$

Хотим решить левую задачу (найти вектор w^* , дающий минимум f), а решаем правую (находим $\hat{w}^*$ для $\hat{f}$). **Вопрос:** Насколько близки эти задачи? Какие фактор могут влиять на близость?


Теорема

Если функция $\ell(g(x, w), y)$ выпукла M -Липшицева по w , тогда с вероятностью хотя бы $1 - \delta$

$$f(\hat{w}^*) - f(w^*) = O \left(\sqrt{\frac{M^2 d \ln(n) \ln(d/\delta)}{n}} \right).$$

Математическая постановка задачи обучения: сравнение

С вероятностью хотя бы $1 - \delta$: $f(\hat{w}^*) - f(w^*) = O\left(\sqrt{\frac{M^2 d \ln(n) \ln(d/\delta)}{n}}\right)$



Переобучение

- Из-за того, что мы решили не совсем ту задачу и нашли $\hat{w}^*$ вместо w^* , и по факту «подстроились» под имеющиеся данные, может случиться эффект переобучения.

Переобучение

- Из-за того, что мы решили не совсем ту задачу и нашли $\hat{w}^*$ вместо w^* , и по факту «подстроились» под имеющиеся данные, может случиться эффект переобучения.

Переобучение (overfitting).

Не имея проблем с известными данными, модель работает плохо на уже новых данных, которые пришли из $\mathcal{D}$.

Переобучение

- Из-за того, что мы решили не совсем ту задачу и нашли $\hat{w}^*$ вместо w^* , и по факту «подстроились» под имеющиеся данные, может случиться эффект переобучения.

Переобучение (overfitting).

Не имея проблем с известными данными, модель работает плохо на уже новых данных, которые пришли из $\mathcal{D}$.

- Эффект переобучения может произойти прежде всего из-за двух вещей:
 - 1 нехватки данных/большого отличия обучающей и тестовой выборок,

Переобучение

- Из-за того, что мы решили не совсем ту задачу и нашли $\hat{w}^*$ вместо w^* , и по факту «подстроились» под имеющиеся данные, может случиться эффект переобучения.

Переобучение (overfitting).

Не имея проблем с известными данными, модель работает плохо на уже новых данных, которые пришли из $\mathcal{D}$.

- Эффект переобучения может произойти прежде всего из-за двух вещей:
 - 1 нехватки данных/большого отличия обучающей и тестовой выборки,
 - 2 слишком большой и сложной модели

Основные причины переобучения

- 1 Нехватка данных/большого отличия обучающей и тестовой выборок

Пример: В наборе снимков МРТ здоровых пациентов и пациентов, больных раком, может быть сильно больше здоровых пациентов, чем больных, и все больные окажутся в тестовой выборке.

Основные причины переобучения

- 1 Нехватка данных/большого отличия обучающей и тестовой выборок

Пример: В наборе снимков МРТ здоровых пациентов и пациентов, больных раком, может быть сильно больше здоровых пациентов, чем больных, и все больные окажутся в тестовой выборке.

- 2 Слишком большая и сложная модель. Удивительно, оказывается, что данных может быть нормальное количество, но из-за того, что используется слишком подробная модель, она воспринимает природу $\mathcal{D}$ слишком буквально.

Пример: На табличных данных с небольшим размером выборки (1-10 тыс. строк) в таких задачах, как прогнозирование кредитного скоринга (выдать человеку кредит или нет), нейронные сети склонны к переобучению и они не улавливают более общие зависимости, в отличие от классических ML моделей.

Примеры переобучения

Представим задачу регрессии на данных, имеющих распределение вида параболы с некоторым гауссовским шумом. Есть три модели: линейная регрессия, полиномиальная со степенью 2 и полиномиальная высших порядков (степень больше 2). **Вопрос:** какая модель покажет себя лучше?

Примеры переобучения

Представим задачу регрессии на данных, имеющих распределение вида параболы с некоторым гауссовским шумом. Есть три модели: линейная регрессия, полиномиальная со степенью 2 и полиномиальная высших порядков (степень больше 2). **Вопрос:** какая модель покажет себя лучше?

- 1 Первая модель не даст должного качества, так как линейей невозможно хорошо приблизить параболу;

Примеры переобучения

Представим задачу регрессии на данных, имеющих распределение вида параболы с некоторым гауссовским шумом. Есть три модели: линейная регрессия, полиномиальная со степенью 2 и полиномиальная высших порядков (степень больше 2). **Вопрос:** какая модель покажет себя лучше?


- 1 Первая модель не даст должного качества, так как линейей невозможно хорошо приблизить параболу;
- 2 Вторая модель прекрасно покажет себя, так как полностью соответствует данным;

Примеры переобучения

Представим задачу регрессии на данных, имеющих распределение вида параболы с некоторым гауссовским шумом. Есть три модели: линейная регрессия, полиномиальная со степенью 2 и полиномиальная высших порядков (степень больше 2). **Вопрос:** какая модель покажет себя лучше?

- 1 Первая модель не даст должного качества, так как линейной невозможно хорошо приблизить параболу;
- 2 Вторая модель прекрасно покажет себя, так как полностью соответствует данным;
- 3 Третья модель слишком сложна – вместо параболы она будет выдавать полиномы большей степени проходящих через каждую точку данных, что не соответствует сути данных.

Примеры переобучения



Борьба с переобучением: big data

Бороться с переобучением можно на различных этапах:

Борьба с переобучением: big data

Бороться с переобучением можно на различных этапах:

- Очевидный способ: чем больше данных, тем лучшего качество обучения можно добиться. **Вопрос:** всегда ли увеличение данных ведёт к улучшению качества работы модели?

Борьба с переобучением: big data

Бороться с переобучением можно на различных этапах:

- Очевидный способ: чем больше данных, тем лучшего качество обучения можно добиться. **Вопрос:** всегда ли увеличение данных ведёт к улучшению качества работы модели? Нет
- Модель может быть слишком простой, чтобы хорошо «подстроиться» под природу, как бы много данных у нас ни было. Не зря нейросети становятся все больше и больше (или зря?)

Борьба с переобучением: регуляризация

- Другой вариант – модифицировать задачу оптимизации: поменять функцию потерь или добавить ограничения на w :

$$\min_{w \in \mathbb{R}^d} \left[\hat{f}(w) + \frac{\lambda}{2} \|w\|_2^2 \right] \quad \text{или} \quad \min_{\|w\|_2 \leq D} \hat{f}(w)$$

Вопрос: Что дают такие изменения?

Борьба с переобучением: регуляризация

- Другой вариант – модифицировать задачу оптимизации: поменять функцию потерь или добавить ограничения на w :

$$\min_{w \in \mathbb{R}^d} \left[\hat{f}(w) + \frac{\lambda}{2} \|w\|_2^2 \right] \quad \text{или} \quad \min_{\|w\|_2 \leq D} \hat{f}(w)$$

Вопрос: Что дают такие изменения? И в этом и в другом случае мы хотим, чтобы w не уходили далеко от 0. Первый трюк называется **регуляризацией**.

Регуляризация

Цель регуляризации часто заключается не только в "удержании" весов модели w . Другие виды регуляризации, например, использование ℓ_1 -нормы может обеспечить разрежённость итогового вектора весов. Почему и зачем – не сегодня.

Борьба с переобучением: валидация

- Задача поиска $\hat{w}^*$ для $\hat{f}$ решается численно, т.е. мы итеративно приближаемся к решению. Можно просто не доходить до $\hat{w}^*$, а остановиться раньше (early stopping). **Вопрос:** но как понять уже пора или нет?

Борьба с переобучением: валидация

Разделим имеющуюся выборку на две части: тренировочную (train) и валидационную (validation). Будем решать задачу минимизации только на *train* части:

$$\min_{w \in \mathbb{R}^d} \frac{1}{n^{\text{train}}} \sum_{i=1}^{n^{\text{train}}} \ell(g(x_i^{\text{train}}, w), y_i^{\text{train}})$$

Борьба с переобучением: валидация

Разделим имеющуюся выборку на две части: тренировочную (train) и валидационную (validation). Будем решать задачу минимизации только на *train* части:

$$\min_{w \in \mathbb{R}^d} \frac{1}{n^{\text{train}}} \sum_{i=1}^{n^{\text{train}}} \ell(g(x_i^{\text{train}}, w), y_i^{\text{train}})$$

- Запустим процесс решения задачи минимизации, стартуем из w^0 .

Борьба с переобучением: валидация

Разделим имеющуюся выборку на две части: тренировочную (train) и валидационную (validation). Будем решать задачу минимизации только на *train* части:

$$\min_{w \in \mathbb{R}^d} \frac{1}{n^{\text{train}}} \sum_{i=1}^{n^{\text{train}}} \ell(g(x_i^{\text{train}}, w), y_i^{\text{train}})$$

- Запустим процесс решения задачи минимизации, стартуем из w^0 .
- Знаем, что $w^k \rightarrow \hat{w}_{\text{train}}^*$ для $k \in \mathbb{N}$. **Вопрос:** Что мы можем сказать про качество решения $\hat{w}_{\text{train}}^*$?

Борьба с переобучением: валидация

Разделим имеющуюся выборку на две части: тренировочную (train) и валидационную (validation). Будем решать задачу минимизации только на *train* части:

$$\min_{w \in \mathbb{R}^d} \frac{1}{n^{\text{train}}} \sum_{i=1}^{n^{\text{train}}} \ell(g(x_i^{\text{train}}, w), y_i^{\text{train}})$$

- Запустим процесс решения задачи минимизации, стартуем из w^0 .
- Знаем, что $w^k \rightarrow \hat{w}_{\text{train}}^*$ для $k \in \mathbb{N}$. **Вопрос:** Что мы можем сказать про качество решения $\hat{w}_{\text{train}}^*$? В общем случае оно даже хуже, чем $\hat{w}^*$.

Борьба с переобучением: валидация

Разделим имеющуюся выборку на две части: тренировочную (train) и валидационную (validation). Будем решать задачу минимизации только на *train* части:

$$\min_{w \in \mathbb{R}^d} \frac{1}{n^{\text{train}}} \sum_{i=1}^{n^{\text{train}}} \ell(g(x_i^{\text{train}}, w), y_i^{\text{train}})$$

- Запустим процесс решения задачи минимизации, начнем из w^0 .
- Знаем, что $w^k \rightarrow \hat{w}_{\text{train}}^*$ для $k \in \mathbb{N}$. **Вопрос:** Что мы можем сказать про качество решения $\hat{w}_{\text{train}}^*$? В общем случае оно даже хуже, чем $\hat{w}^*$.
- Но в силу того, что w^0 плохое решение, как для f , так и для $\hat{f}$ и $\hat{f}^{\text{train}}$. Поэтому до какого-то момента процесс оптимизации w^k приближается к w^* .

Борьба с переобучением: валидация

Разделим имеющуюся выборку на две части: тренировочную (train) и валидационную (validation). Будем решать задачу минимизации только на *train* части:

$$\min_{w \in \mathbb{R}^d} \frac{1}{n^{\text{train}}} \sum_{i=1}^{n^{\text{train}}} \ell(g(x_i^{\text{train}}, w), y_i^{\text{train}})$$

- Запустим процесс решения задачи минимизации, начнем из w^0 .
- Знаем, что $w^k \rightarrow \hat{w}_{\text{train}}^*$ для $k \in \mathbb{N}$. **Вопрос:** Что мы можем сказать про качество решения $\hat{w}_{\text{train}}^*$? В общем случае оно даже хуже, чем $\hat{w}^*$.
- Но в силу того, что w^0 плохое решение, как для f , так и для $\hat{f}$ и $\hat{f}^{\text{train}}$. Поэтому до какого-то момента процесс оптимизации w^k приближается к w^* . **Вопрос:** Как словить момент для остановки процесса (помните про валидационную выборку)?

Борьба с переобучением: валидация

- При минимизации функции f^{train} (обучении) мы не видели валидационную выборку. Естественная идея, проверить на ней качество текущего решения w^k , предполагая, что валидационная выборка – это новые данные пришедшие из неизвестного распределения $\mathcal{D}$, которое мы и хотим найти. **Вопрос:** Как проверить?

Борьба с переобучением: валидация

- При минимизации функции f^{train} (обучении) мы не видели валидационную выборку. Естественная идея, проверить на ней качество текущего решения w^k , предполагая, что валидационная выборка – это новые данные пришедшие из неизвестного распределения $\mathcal{D}$, которое мы и хотим найти. **Вопрос:** Как проверить? Например, измерить потери на валидационной выборке:

$$\hat{f}^{\text{val}}(w^k) := \frac{1}{n^{\text{val}}} \sum_{i=1}^{n^{\text{val}}} \ell(g(x_i^{\text{val}}, w^k), y_i^{\text{val}}),$$


Борьба с переобучением: валидация

- При минимизации функции f^{train} (обучении) мы не видели валидационную выборку. Естественная идея, проверить на ней качество текущего решения w^k , предполагая, что валидационная выборка – это новые данные пришедшие из неизвестного распределения $\mathcal{D}$, которое мы и хотим найти. **Вопрос:** Как проверить? Например, измерить потери на валидационной выборке:

$$\hat{f}^{\text{val}}(w^k) := \frac{1}{n^{\text{val}}} \sum_{i=1}^{n^{\text{val}}} \ell(g(x_i^{\text{val}}, w^k), y_i^{\text{val}}),$$

и словить некоторый момент времени k^* , что потери на валидации начинают расти: $f^{\text{val}}(w^{k^*-1}) \geq f^{\text{val}}(w^{k^*}) < f^{\text{val}}(w^{k^*+1})$.

Борьба с переобучением: валидация



Основные требования к модели

- Качество – высокие показатели метрик в задаче (например, точность предсказаний на тестовой выборке);

Основные требования к модели

- Качество – высокие показатели метрик в задаче (например, точность предсказаний на тестовой выборке);
- Эффективность – время обучения/инференса;

Основные требования к модели

- Качество – высокие показатели метрик в задаче (например, точность предсказаний на тестовой выборке);
- Эффективность – время обучения/инференса;
- Робастность – устойчивость к шуму в данных;

Основные требования к модели

- Качество – высокие показатели метрик в задаче (например, точность предсказаний на тестовой выборке);
- Эффективность – время обучения/инференса;
- Робастность – устойчивость к шуму в данных;
- Масштабируемость – при увеличении объема данных поведение модели не изменится;

Основные требования к модели

- Качество – высокие показатели метрик в задаче (например, точность предсказаний на тестовой выборке);
- Эффективность – время обучения/инференса;
- Робастность – устойчивость к шуму в данных;
- Масштабируемость – при увеличении объема данных поведение модели не изменится;
- Интерпретируемость – объясняемость результатов модели;

Основные требования к модели

- Качество – высокие показатели метрик в задаче (например, точность предсказаний на тестовой выборке);
- Эффективность – время обучения/инференса;
- Робастность – устойчивость к шуму в данных;
- Масштабируемость – при увеличении объема данных поведение модели не изменится;
- Интерпретируемость – объясняемость результатов модели;
- Компактность – затраты на хранение модели.

Другие виды обучения

- 1 Обучение без учителя (Un-/Self-supervised learning) – нужно «понять» структуру пространства $\mathcal{X}$;

Другие виды обучения

- ① Обучение без учителя (Un-/Self-supervised learning) – нужно «понять» структуру пространства $\mathcal{X}$;

Примеры:

- Кластеризация – разбиение данных на группы по схожести. Например, это задача сегментации клиентов.
- Понижение размерности. Уменьшение количества признаков с сохранением важной информации.
- Поиск аномалий в данных

Другие виды обучения

- 1 Обучение без учителя (Un-/Self-supervised learning) – нужно «понять» структуру пространства $\mathcal{X}$;

Примеры:

- Кластеризация – разбиение данных на группы по схожести. Например, это задача сегментации клиентов.
 - Понижение размерности. Уменьшение количества признаков с сохранением важной информации.
 - Поиск аномалий в данных
- 2 Обучение с частично размеченными данными (Semi-supervised learning) – $X = \{ (x_1, y_1), \dots, (x_k, y_k), x_{k+1}, \dots, x_n \}$;
Пример: Классификация писем на спам/не спам. Есть маленький размеченный датасет, но при обучении модели могут использовать структуры из большого неразмеченного датасета для улучшения качества.

Другие виды обучения

- ③ Обучение с подкреплением (Reinforcement learning) – агент взаимодействует со средой и обучается посредством получения наград за свои действия;

Пример: Беспилотные автомобили. Например, может быть награда за плавные вождение и остановки и штрафы за нарушение ПДД.

Другие виды обучения

- ③ Обучение с подкреплением (Reinforcement learning) – агент взаимодействует со средой и обучается посредством получения наград за свои действия;

Пример: Беспилотные автомобили. Например, может быть награда за плавные вождение и остановки и штрафы за нарушение ПДД.

- ④ Онлайн обучение (Online learning) – в каждый конкретный момент доступна лишь небольшая выборка объектов;

Пример: Рекомендательные системы на маркетплейсах могут быть построены при помощи онлайн обучения, так как постоянно поступают новые данные о меняющихся предпочтениях пользователей.

Другие виды обучения

- ③ Обучение с подкреплением (Reinforcement learning) – агент взаимодействует со средой и обучается посредством получения наград за свои действия;
Пример: Беспилотные автомобили. Например, может быть награда за плавные вождение и остановки и штрафы за нарушение ПДД.
- ④ Онлайн обучение (Online learning) – в каждый конкретный момент доступна лишь небольшая выборка объектов;
Пример: Рекомендательные системы на маркетплейсах могут быть построены при помощи онлайн обучения, так как постоянно поступают новые данные о меняющихся предпочтениях пользователей.
- ⑤ Обучение с переносом (Transfer learning) – решение новых задач с помощью решений старых.