

Основы статистики для машинного обучения

Машинное обучение

Наиль Баширов

Московский физико-технический институт

14 сентября 2026



Зачем машинному обучению статистика?

Алгоритм видит только конечный набор наблюдений, но должен работать на новых данных.



Зачем машинному обучению статистика?

Алгоритм видит только конечный набор наблюдений, но должен работать на новых данных.



Статистика отвечает на три вопроса:

- что именно мы предполагаем о данных;
- как по выборке оценить неизвестные величины;
- насколько можно доверять полученному ответу.

О чем лекция

- 1 Данные как случайная выборка и параметрическая модель.
- 2 Два вида сходимости, закон больших чисел и центральная предельная теорема.
- 3 Статистики, свойства оценок, моменты и квантили.
- 4 Доверительные и предсказательные интервалы, проверка гипотез.
- 5 Максимальное правдоподобие и связь вероятностной модели с функцией потерь.
- 6 Байесовский взгляд, MAP и регуляризация.
- 7 Бутстрэп как следующий инструмент для сложных статистик.

Суть

Вероятностное предположение о данных превращается в функцию потерь, а конечность выборки приводит к неопределённости оценки.

Обозначения

Символ	Смысл	Символ	Смысл
P_Z	распределение наблюдения Z	F	функция распределения скалярной величины
$p(z \mid \theta)$	плотность или вероятность в модели	$\mathcal{Z}$	пространство наблюдений
θ	неизвестный параметр	Θ	множество допустимых параметров
w	параметры предсказателя; частный случай θ	$\mathcal{D}$	наблюдаемая выборка
n	размер обучающей выборки	$\hat{\theta}$	оценка параметра по данным
$\ell(y, f(x))$	потеря на одном объекте	$L(\theta; \mathcal{D})$	функция правдоподобия

Соглашение

Заглавные Z, X, Y обозначают случайные величины, строчные z, x, y – их реализации, а индекс i – номер наблюдения.

Два уровня: распределение и выборка

Генеральная совокупность

P_Z – распределение всех объектов, которые могли бы встретиться в задаче. Для скалярного Z

$$F(t) = P_Z((-\infty, t]),$$

а при наличии плотности

$$F(t) = \int_{-\infty}^t p(u) du.$$

Выборка

$$\mathcal{D} = (Z_1, \dots, Z_n), \quad Z_i \in \mathcal{Z}.$$

В обучении с учителем

$Z_i = (X_i, Y_i)$, а реализация
 $z_i = (x_i, y_i)$.

Цель

По конечной $\mathcal{D}$ сделать вывод о неизвестном P_Z или о будущих объектах из него.

Предположение i.i.d.

Часто начинают с модели

$$Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} P_Z.$$

- **Независимость:** знание Z_i не меняет распределение других наблюдений.
- **Одинаковое распределение:** все Z_i получены одним и тем же механизмом.

Тогда совместное распределение раскладывается в произведение:

$$p(z_1, \dots, z_n) = \prod_{i=1}^n p(z_i).$$

Предположение i.i.d.

Часто начинают с модели

$$Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} P_Z.$$

- **Независимость:** знание Z_i не меняет распределение других наблюдений.
- **Одинаковое распределение:** все Z_i получены одним и тем же механизмом.

Тогда совместное распределение раскладывается в произведение:

$$p(z_1, \dots, z_n) = \prod_{i=1}^n p(z_i).$$

Именно это простое равенство позже превратит правдоподобие в сумму потерь по объектам.

Когда i.i.d. нарушается?

- последовательные измерения образуют временной ряд;
- несколько строк относятся к одному пользователю или пациенту;
- источники имеют разные распределения или механизмы отбора;
- механизм сбора данных меняется со временем;
- обучающая выборка отфильтрована не так, как будущий поток.

Практическое следствие

Разбиение на обучающую и тестовую части и бутстрэп выполняют на уровне независимой единицы наблюдения: пользователя, пациента или временного блока, а не обязательно отдельной строки.

Параметрическая модель

Вместо произвольного P_Z выберем семейство распределений

$$\{p(z \mid \theta) : \theta \in \Theta\},$$

где θ – неизвестный параметр.

Примеры

- $X \sim \text{Bernoulli}(p)$, $\theta = p$;
- $X \sim \mathcal{N}(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$;
- $Y \mid X = x \sim \mathcal{N}(f_w(x), \sigma^2)$, $\theta = (w, \sigma^2)$.

Здесь w – параметры предсказателя и частный случай общего параметра θ . Модель является приближением реального механизма данных, а не фактом о нём.

Что даёт вероятностная модель?

После выбора $p(z \mid \theta)$ можно:

- сравнивать разные значения параметра θ ;
- получать функцию потерь из $-\log p(z \mid \theta)$;
- оценивать неопределённость параметров и прогнозов;
- генерировать новые наблюдения и проверять адекватность модели.

Цена удобства

Все выводы условны относительно предположений: распределения, независимости, одинаковости наблюдений и способа сбора выборки.

Два вида сходимости: $\xrightarrow{P}$ и $\xrightarrow{d}$

Мы сформулировали вероятностную модель; теперь нужен язык, который описывает, как оценки ведут себя при росте выборки.

Сходимость по вероятности

$$X_n \xrightarrow{P} X \iff \forall \varepsilon > 0 : \mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0.$$

Значения X_n с высокой вероятностью становятся близки к X .

Сходимость по распределению

$$X_n \xrightarrow{d} X \iff F_{X_n}(t) \rightarrow F_X(t)$$

во всех точках непрерывности F_X . Сходится форма распределения, но не обязательно сами значения.

Сходимость по вероятности влечёт сходимость по распределению; обратное в общем случае неверно.

ЗБЧ, ЦПТ и пределы больших данных

Закон больших чисел

Если X_i i.i.d. и $\mathbb{E}|g(X)| < \infty$, то

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \xrightarrow{P} \mathbb{E}g(X).$$

Для оценки k -го момента требуется $\mathbb{E}|X|^k < \infty$.

Рост n не исправляет

- смещение при сборе данных;
- train–production shift;
- зависимость наблюдений;
- неверную модель;
- утечку целевой переменной.

Центральная предельная теорема

Если $\mathbb{E}X = \mu$ и $\text{Var}(X) = \sigma^2 < \infty$, то

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0, 1), \quad \text{SE}(\bar{X}_n) \approx \frac{S}{\sqrt{n}}.$$

Практический вывод

Больше данных уменьшает случайную ошибку примерно как $1/\sqrt{n}$, но не устраняет систематические ошибки постановки.

Статистика и оценка

ЗБЧ и ЦПТ описывают выборочные средние; теперь определим функции данных, используемые для статистического вывода.

Статистика

Любая измеримая функция

$$T = T(Z_1, \dots, Z_n),$$

не зависящая от неизвестного параметра.

Оценка

Статистика $\hat{\theta}$, приближающая неизвестный θ .

Примеры

- $\bar{X} = n^{-1} \sum_i X_i$ оценивает $\mathbb{E}X$;
- выборочная медиана оценивает медиану;
- ассигасу на тесте оценивает вероятность правильного ответа фиксированной модели.

Оценки и моменты: краткое напоминание

Оценка и её ошибка

$\hat{\theta} = T(\mathcal{D})$ зависит от случайной выборки, поэтому сама является случайной величиной.

$$\text{Bias}(\hat{\theta}) = \mathbb{E}\hat{\theta} - \theta,$$

$$\hat{\theta}_n \xrightarrow{P} \theta \quad (\text{состоятельность}).$$

$$\mathbb{E}(\hat{\theta} - \theta)^2 = \text{Var}(\hat{\theta}) + \text{Bias}^2(\hat{\theta}).$$

Смещение и разброс нужно оценивать совместно.

Моменты и дисперсия

$$m'_k = \mathbb{E}X^k, \quad \hat{m}'_k = \frac{1}{n} \sum_{i=1}^n X_i^k,$$

$$m_k = \mathbb{E}(X - \mu)^k, \quad \hat{m}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k.$$

Высокие моменты особенно чувствительны к выбросам.

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Делитель $n - 1$ компенсирует одну степень свободы, потраченную на оценку $\bar{X}$; при i.i.d. $\mathbb{E}S^2 = \sigma^2$.

Ковариация, PLCC и SRCC

Ковариация и корреляция Пирсона

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)].$$

$$\widehat{\text{Cov}}(X, Y) = \frac{1}{n-1} \sum_i (X_i - \bar{X})(Y_i - \bar{Y}).$$

$$r_{XY} = \frac{\widehat{\text{Cov}}(X, Y)}{S_X S_Y}.$$

Нулевая корреляция не означает независимость, а высокая корреляция сама по себе не доказывает причинность.

Пример: no-reference IQA

Модель по изображению предсказывает качество $\hat{y}_i$, а y_i – mean opinion score (MOS):

$$R_i = \text{rank}(\hat{y}_i), \quad M_i = \text{rank}(y_i),$$

$$\text{PLCC} = r_{\hat{y}, y}, \quad \text{SRCC} = r_{R, M}.$$

PLCC измеряет линейное согласие, SRCC – совпадение порядка.

Метрика похожести и loss

$$Q_{\text{corr}} = \frac{\text{PLCC} + \text{SRCC}}{2}, \quad \ell_{\text{corr}} = 1 - Q_{\text{corr}}.$$

Обычный SRCC недифференцируем из-за ранжирования; при обучении используют soft-rank или гладкий суррогат.

Квантили и центральная область

Для функции распределения F определим

$$q_\gamma = \inf\{t : F(t) \geq \gamma\}, \quad 0 < \gamma < 1.$$

Если распределение непрерывно, то центральная область для U имеет вид


$$\mathbb{P}(q_{\alpha/2} \leq U \leq q_{1-\alpha/2}) = 1 - \alpha.$$

По выборке

$$\hat{F}_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[X_i \leq t],$$

$$\hat{q}_\gamma = \inf\{t : \hat{F}_n(t) \geq \gamma\}.$$

Эмпирические квантили далее понадобятся для бутстрэп-интервалов.



Две хвостовые области имеют суммарную вероятность α , центральная область – вероятность $1 - \alpha$.

От квантилей к доверительному интервалу

Для параметра μ выберем опорную статистику, распределение которой известно или хорошо приближается:

$$U_\mu = \frac{\bar{X} - \mu}{S/\sqrt{n}} \approx \mathcal{N}(0, 1).$$

Центральная область стандартного нормального распределения даёт

$$\mathbb{P}(-z_{1-\alpha/2} \leq U_\mu \leq z_{1-\alpha/2}) \approx 1 - \alpha.$$

Обращая неравенство относительно μ , получаем

$$\mu \in \left[\bar{X} - z_{1-\alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + z_{1-\alpha/2} \frac{S}{\sqrt{n}} \right].$$

Общий принцип

Найти распределение опорной статистики $\longrightarrow$ взять его квантили $\longrightarrow$ обратить неравенство относительно параметра.

Распределение Стьюдента и точный интервал

Если $X_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$, то

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim \mathcal{N}(0, 1),$$


$$V = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

причём Z и V независимы. Поэтому

$$T = \frac{Z}{\sqrt{V/(n-1)}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Точный интервал при нормальной модели

$$\mu \in \bar{X} \pm t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}}.$$



При малых n оценка S добавляет неопределённость, поэтому хвосты t -распределения тяжелее. При $\nu \rightarrow \infty$ имеем $t_\nu \xrightarrow{d} \mathcal{N}(0, 1)$.

Что означает доверительный интервал?

До наблюдения данных $C(\mathcal{D})$ – случайный интервал. Для 95%-процедуры

$$\mathbb{P}_{\theta}(\theta \in C(\mathcal{D})) \approx 0.95.$$


При повторении эксперимента тем же способом примерно 95% построенных интервалов накроют истинный параметр.

После наблюдения данных $[L_{\text{bound}}, U_{\text{bound}}]$ фиксирован; его ширина показывает точность оценки.

Чего интервал не означает

Это не вероятность 95% для фиксированного θ и не диапазон для 95% будущих наблюдений. Гарантия зависит от модели и дизайна выборки.

Доверительный и предсказательный интервалы



Рассмотрим модель, в которой

$$m(x_0) = \mathbb{E}[Y \mid X = x_0],$$

$$Y_{\text{new}} = m(x_0) + \varepsilon_{\text{new}}.$$

Доверительный интервал: где находится средний ответ $m(x_0)$?

Предсказательный интервал: где окажется новое Y_{new} ? Он дополнительно учитывает шум ε_{new} .

$$\text{Var}(Y_{\text{new}} - \hat{m}) = \text{Var}(\hat{m} - m) + \text{Var}(\varepsilon_{\text{new}}).$$

Вывод

ДИ нужен для среднего эффекта, предсказательный интервал – для отдельного объекта. Больше данных сужает ДИ, но не устраняет шум нового наблюдения.

Критерий как решающее правило

Интервалы описывают множество правдоподобных значений параметра; теперь превратим неопределённость в формальное решение.

Стат. критерий – правило $\varphi : \mathcal{D} \mapsto \{\text{отвергнуть } H_0, \text{ не отвергать } H_0\}$.

Критическая область и уровень

Критическая область K содержит выборки, при которых H_0 отвергается. Уровень ограничивает вероятность ложного отвержения:

$$\sup_{\theta \in \Theta_0} \mathbb{P}_{\theta}(\mathcal{D} \in K) \leq \alpha.$$

Важно: это свойство правила φ , а не конкретной выборки.

Односторонний критерий ищет отклонение в заранее выбранную сторону, двусторонний – в обе стороны. Выбор определяется H_1 до анализа данных.

Нулевая и альтернативная гипотезы

- H_0 – базовое утверждение, например $\mu = \mu_0$ или $\mu_A = \mu_B$;
- H_1 – рассматриваемое отклонение от H_0 ;
- $T(\mathcal{D})$ – статистика, экстремальные значения которой противоречат H_0 .

p-value


Вероятность при условии H_0 получить значение статистики не менее экстремальное, чем наблюдаемое, в направлении, заданном H_1 .

Если заранее выбран уровень значимости α и $p\text{-value} \leq \alpha$, H_0 отвергают.

Важно


p-value не равен вероятности истинности H_0 и не измеряет размер эффекта.

Нулевое распределение: решение, p-value и ДИ



Вывод: p-value показывает конфликт с H_0 , но не размер и не практическую значимость эффекта.

Ошибки I и II рода



Ошибка I рода

Отвергнуть верную H_0 .
Вероятность α задаётся
при проектировании
критерия.

Ошибка II рода

Не отвергнуть H_0 , когда
верна альтернатива.
Вероятность β зависит от
эффекта и размера
выборки.

Мощность

$1 - \beta$ – вероятность
обнаружить эффект
заданного размера. Её
оценивают до
эксперимента.

Компромисс: при фиксированном n уменьшение α повышает β ; рост выборки или эффекта раздвигает распределения и повышает мощность.

t-критерий для среднего

Для нормальной i.i.d.-выборки проверим $H_0 : \mu = \mu_0$ против $H_1 : \mu \neq \mu_0$.

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \underset{H_0}{\sim} t_{n-1}.$$

Пусть $U \sim t_{n-1}$. Двусторонний p-value:

$$p = 2\mathbb{P}(U \geq |T_{\text{obs}}|).$$

Эквивалентная запись через интервал

H_0 отвергается на уровне α , если μ_0 не входит в $\bar{X} \pm t_{n-1, 1-\alpha/2} S/\sqrt{n}$.

Точное равенство $T \sim t_{n-1}$ требует нормальности данных. Это то же распределительное утверждение, которое дало точный t-интервал для среднего ранее.

U-критерий Манна–Уитни

Пусть $X_1, \dots, X_m$ и $Y_1, \dots, Y_n$ – две независимые выборки.

$$U = \sum_{i=1}^m \sum_{j=1}^n \left[\mathbb{I}(Y_j > X_i) + \frac{1}{2} \mathbb{I}(Y_j = X_i) \right].$$

Вероятностная интерпретация

$$\frac{U}{mn} = \hat{\mathbb{P}}(Y > X) + \frac{1}{2} \hat{\mathbb{P}}(Y = X).$$

Большое U означает, что значения группы Y обычно выше.

Важно

Критерий сравнивает распределения. Интерпретация только как сравнение медиан требует дополнительных предположений об их форме.

От модели к оценке параметра

Ранее мы определили свойства хороших оценок; теперь выведем саму оценку непосредственно из вероятностной модели.

Функция правдоподобия

$$L(\theta; \mathcal{D}) = \prod_{i=1}^n p(Z_i | \theta).$$

Данные зафиксированы, а функция рассматривается по θ .

Оценка максимального правдоподобия

$$\hat{\theta}_{\text{MLE}} = \operatorname{argmax}_{\theta \in \Theta} L(\theta; \mathcal{D}).$$

Правдоподобие не является вероятностью параметра: в классическом подходе θ неслучаен.

Почему используют логарифм?

Логарифм строго возрастает, поэтому точка максимума не меняется:

$$\hat{\theta}_{\text{MLE}} = \underset{\theta}{\operatorname{argmax}} \log L(\theta; \mathcal{D}), \quad \log L(\theta; \mathcal{D}) = \sum_{i=1}^n \log p(Z_i | \theta).$$

- произведение превращается в сумму;
- производные считать проще;
- вычисления устойчивее: произведение малых вероятностей не обнуляется.

Почему используют логарифм?

Логарифм строго возрастает, поэтому точка максимума не меняется:

$$\hat{\theta}_{\text{MLE}} = \underset{\theta}{\operatorname{argmax}} \log L(\theta; \mathcal{D}), \quad \log L(\theta; \mathcal{D}) = \sum_{i=1}^n \log p(Z_i | \theta).$$

- произведение превращается в сумму;
- производные считать проще;
- вычисления устойчивее: произведение малых вероятностей не обнуляется.

Максимизация $\log L$ эквивалентна минимизации отрицательного лог-правдоподобия:

$$-\log L(\theta; \mathcal{D}) = \sum_{i=1}^n \underbrace{-\log p(Z_i | \theta)}_{\text{потеря на объекте}}.$$

Пример: распределение Бернулли

Пусть $X_i \in \{0, 1\}$ и $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$. Обозначим $s = \sum_i X_i$.

$$\log L(p; \mathcal{D}) = s \log p + (n - s) \log(1 - p).$$

Условие оптимума во внутренней точке:

$$\frac{d}{dp} \log L(p; \mathcal{D}) = \frac{s}{p} - \frac{n - s}{1 - p} = 0.$$

Результат

$$\hat{p}_{\text{MLE}} = \frac{s}{n} = \bar{X}.$$

Наблюдаемая доля единиц является MLE вероятности успеха.

Пример: нормальное распределение

Пусть $X_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$. Тогда

$$\log L(\mu, \sigma^2; \mathcal{D}) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2.$$

Из условий оптимума получаем

$$\hat{\mu}_{\text{MLE}} = \bar{X}, \quad \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Замечание

MLE дисперсии смещена. Максимальное правдоподобие не обязано давать несмещённую оценку при конечном n , хотя здесь оценка состоятельна.

Пример: распределение Лапласа

Пусть $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Laplace}(\mu, b)$ с плотностью

$$p(x \mid \mu, b) = \frac{1}{2b} \exp\left(-\frac{|x - \mu|}{b}\right).$$

При фиксированном b лог-правдоподобие имеет вид

$$\log L(\mu; \mathcal{D}) = -n \log(2b) - \frac{1}{b} \sum_{i=1}^n |X_i - \mu|.$$

MLE параметра положения

$$\hat{\mu}_{\text{MLE}} \in \underset{\mu}{\operatorname{argmin}} \sum_{i=1}^n |X_i - \mu|.$$

MLE является выборочной медианой; при чётном n подходит любая точка между двумя центральными наблюдениями.

Что из уже знакомого оказалось MLE?

Модель	MLE	Знакомая статистика
$X_i \sim \mathcal{N}(\mu, \sigma^2)$, σ^2 фиксирована	$\hat{\mu} = \bar{X}$	выборочное среднее
$X_i \sim \mathcal{N}(\mu, \sigma^2)$	$\hat{\sigma}^2 = \hat{\sigma}_n^2$	второй центральный момент с делителем n , не S^2
$X_i \sim \text{Bernoulli}(p)$	$\hat{p} = s/n$	выборочная доля успехов
$X_i \sim \text{Laplace}(\mu, b)$, b фиксирован	$\hat{\mu} \in \text{median}(X_1, \dots, X_n)$	выборочная медиана

Одна и та же статистика получает статус MLE только после указания модели; выбор распределения определяет и оценки, и соответствующую функцию потерь.

Модель ошибки: нормальное распределение и MSE

Пусть ошибки прогноза независимы и имеют нормальное распределение:

$$\varepsilon_i = y_i - f_w(x_i) \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2).$$

Отрицательное лог-правдоподобие одного наблюдения равно

$$-\log p(y_i | x_i, w) = \frac{(y_i - f_w(x_i))^2}{2\sigma^2} + C.$$

Следствие

Максимизация правдоподобия по w эквивалентна минимизации

$$\text{MSE}(w) = \frac{1}{n} \sum_{i=1}^n (y_i - f_w(x_i))^2.$$

Интерпретация: квадратичная потеря соответствует симметричному шуму с тонкими хвостами и сильно штрафует большие ошибки.

Модель ошибки: распределение Лапласа и MAE

Пусть ошибка прогноза $\varepsilon_i = y_i - f_w(x_i)$ имеет распределение Лапласа:

$$\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \text{Laplace}(0, b), \quad p(\varepsilon) = \frac{1}{2b} \exp\left(-\frac{|\varepsilon|}{b}\right).$$

Тогда отрицательное лог-правдоподобие одного наблюдения равно

$$-\log p(y_i | x_i, w) = \frac{|y_i - f_w(x_i)|}{b} + C.$$

Следствие

Максимизация правдоподобия по w эквивалентна минимизации

$$\text{MAE}(w) = \frac{1}{n} \sum_{i=1}^n |y_i - f_w(x_i)|.$$

Лапласовский шум имеет более тяжёлые хвосты, поэтому абсолютная потеря устойчивее к отдельным большим отклонениям, чем MSE.

Модель ответа: распределение Бернулли и logloss

В классификации вместо аддитивной ошибки задают условное распределение ответа:

$$Y_i \mid x_i \sim \text{Bernoulli}(q_w(x_i)), \quad y_i \in \{0, 1\}, \quad q_w(x_i) \in (0, 1).$$

Отрицательное лог-правдоподобие одного наблюдения равно

$$-\log p(y_i \mid x_i, w) = -y_i \log q_w(x_i) - (1 - y_i) \log(1 - q_w(x_i)).$$

Следствие

Максимизация правдоподобия по w эквивалентна минимизации

$$\text{logloss}(w) = -\frac{1}{n} \sum_{i=1}^n [y_i \log q_w(x_i) + (1 - y_i) \log(1 - q_w(x_i))].$$

Logloss особенно сильно штрафует уверенные ошибочные вероятностные прогнозы.

Модель и функция потерь

Модель ошибки	Отрицательное лог-правдоподобие	Потеря
Нормальная	$(y - f(x))^2 / (2\sigma^2) + C$	квадратичная
Лапласа	$ y - f(x) / b + C$	абсолютная
Бернулли	$-y \log q - (1 - y) \log(1 - q)$	logloss

Главная идея

Выбор функции потерь означает выбор того, какие ошибки модель считает типичными.

Информация Фишера и точность MLE

1. Score и информация

Score – производная лог-плотности по параметру:

$$s_{\theta}(Z) = \frac{\partial}{\partial \theta} \log p(Z | \theta).$$

Из нормировки плотности следует

$$\mathbb{E}_{\theta} s_{\theta}(Z) = \frac{\partial}{\partial \theta} \int p(z | \theta) dz = 0.$$

Информация Фишера – дисперсия score, или средняя отрицательная кривизна лог-плотности:

$$I(\theta) = \mathbb{E}_{\theta}[s_{\theta}(Z)^2] = -\mathbb{E}_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log p(Z | \theta) \right].$$

Для n i.i.d. наблюдений $I_n(\theta) = nI(\theta)$.

2. Откуда она возникает в MLE

Пусть $\ell_n(\theta) = \sum_i \log p(Z_i | \theta)$. Поскольку $\ell'_n(\hat{\theta}) = 0$, разложение около истинного параметра даёт

$$\sqrt{n}(\hat{\theta} - \theta) \approx \frac{\ell'_n(\theta)/\sqrt{n}}{-\ell''_n(\theta)/n}.$$

По ЦПТ и ЗБЧ

$$\begin{aligned} \frac{\ell'_n(\theta)}{\sqrt{n}} &\xrightarrow{d} \mathcal{N}(0, I(\theta)), \\ -\frac{\ell''_n(\theta)}{n} &\xrightarrow{P} I(\theta). \end{aligned}$$

Значит, $I(\theta)$ возникает как предельная кривизна лог-правдоподобия около максимума.

Асимптотика: больше $I(\theta)$ – точнее оценка

$$\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \xrightarrow{d} \mathcal{N}(0, I(\theta)^{-1}), \quad \text{SE}(\hat{\theta}_{\text{MLE}}) \approx \frac{1}{\sqrt{nI(\theta)}}.$$

Параметр тоже становится случайным

Зададим априорную плотность $\pi(\theta) \equiv p(\theta)$ и модель данных $p(\mathcal{D} | \theta)$. Совместную плотность можно разложить двумя способами:

$$p(\mathcal{D}, \theta) = p(\mathcal{D} | \theta)\pi(\theta) = p(\theta | \mathcal{D})p(\mathcal{D}).$$

Отсюда следует формула Байеса с явно выписанной нормировкой:

$$p(\theta | \mathcal{D}) = \frac{p(\mathcal{D} | \theta)\pi(\theta)}{\int_{\Theta} p(\mathcal{D} | u)\pi(u) du}$$

Что обозначают вероятности?

$\pi(\theta)$ и $p(\theta | \mathcal{D})$ описывают случайный параметр до и после наблюдения данных. В $p(\mathcal{D} | \theta)$ параметр фиксирован, а случайна выборка; после наблюдения в $p(\theta | \mathcal{D})$ фиксирована $\mathcal{D}$.

Байесовский вывод и место MAP

1. Байесовский вывод

Результат вывода – всё распределение $p(\theta | \mathcal{D})$. Из него получают апостериорные средние, интервалы и прогнозы:

$$\mathbb{E}[g(\theta) | \mathcal{D}] = \int g(\theta)p(\theta | \mathcal{D}) d\theta,$$

$$\mathbb{P}(\theta \in C | \mathcal{D}) = 1 - \alpha,$$

$$p(y_* | x_*, \mathcal{D}) = \int p(y_* | x_*, \theta)p(\theta | \mathcal{D}) d\theta.$$

2. Где здесь MAP?

MAP сохраняет только моду апостериорной плотности:

$$\hat{\theta}_{\text{MAP}} = \underset{\theta}{\operatorname{argmax}} p(\theta | \mathcal{D}).$$

Интеграл в полном прогнозе иногда заменяют plug-in приближением:

$$p(y_* | x_*, \mathcal{D}) \approx p(y_* | x_*, \hat{\theta}_{\text{MAP}}).$$

Приближение не передаёт ширину, асимметрию и мультимодальность постериора.

Не смешивать интервалы

Credible interval: $\mathcal{D}$ фиксирована, случаен θ . Confidence interval: θ фиксирован, случаен интервал по новой выборке.

MAP-оценка: от формулы Байеса к оптимизации

Из формулы Байеса $p(\theta | \mathcal{D}) = L(\theta; \mathcal{D})\pi(\theta)/p(\mathcal{D})$. Знаменатель $p(\mathcal{D})$ не зависит от θ , поэтому

$$\begin{aligned}\hat{\theta}_{\text{MAP}} &= \operatorname{argmax}_{\theta} p(\theta | \mathcal{D}) \\ &= \operatorname{argmax}_{\theta} L(\theta; \mathcal{D})\pi(\theta) = \operatorname{argmax}_{\theta} [\log L(\theta; \mathcal{D}) + \log \pi(\theta)].\end{aligned}$$

Откуда появился $\log p(\theta)$?

Это логарифм априорной плотности $\pi(\theta) \equiv p(\theta)$: произведение likelihood и prior после логарифмирования становится суммой.

Эквивалентная задача минимизации:

$$\underbrace{-\sum_i \log p(Z_i | \theta)}_{\text{ошибка на данных}} + \underbrace{(-\log \pi(\theta))}_{\text{штраф из prior}} \rightarrow \min_{\theta}.$$

Почему MAP и MLE сходятся к одному параметру?

Пусть $\theta \in \Theta \subset \mathbb{R}^d$, а θ_0 – истинный параметр. Введём

$$Q_n(\theta) = -\frac{1}{n} \log L(\theta; \mathcal{D}) = -\frac{1}{n} \sum_{i=1}^n \log p(Z_i | \theta), \quad Q(\theta) = \mathbb{E}_{\theta_0}[-\log p(Z | \theta)].$$

Тогда оценочные векторы являются минимумами двух близких функций:

$$\hat{\theta}_{\text{MLE}} \in \underset{\theta \in \Theta}{\operatorname{argmin}} Q_n(\theta),$$

$$\hat{\theta}_{\text{MAP}} \in \underset{\theta \in \Theta}{\operatorname{argmin}} \left[Q_n(\theta) - \frac{1}{n} \log \pi(\theta) \right].$$

Предположим, что Θ компактно, Q имеет единственный минимум θ_0 , выполняется равномерный ЗБЧ, а $\log \pi(\theta)$ ограничен на Θ . Тогда

$$\sup_{\theta \in \Theta} |Q_n(\theta) - Q(\theta)| \xrightarrow{P} 0, \quad \sup_{\theta \in \Theta} \left| Q_n(\theta) - \frac{1}{n} \log \pi(\theta) - Q(\theta) \right| \xrightarrow{P} 0.$$

По теореме об аргументе минимума

$$\hat{\theta}_{\text{MLE}} \xrightarrow{P} \theta_0, \quad \hat{\theta}_{\text{MAP}} \xrightarrow{P} \theta_0.$$

Следовательно, по неравенству треугольника

$$\|\hat{\theta}_{\text{MAP}} - \hat{\theta}_{\text{MLE}}\| \leq \|\hat{\theta}_{\text{MAP}} - \theta_0\| + \|\hat{\theta}_{\text{MLE}} - \theta_0\| \xrightarrow{P} 0.$$

Априорное распределение как регуляризатор

В MAP-задаче регуляризатор равен отрицательному логарифму prior:

$$-\log L(w; \mathcal{D}) - \log \pi(w) \longrightarrow \min_w.$$

Гауссовский prior

Если $w \sim \mathcal{N}(0, \tau^2 I_d)$, то

$$\pi(w) = (2\pi\tau^2)^{-d/2} \exp\left(-\frac{\|w\|_2^2}{2\tau^2}\right).$$

Поэтому

$$-\log \pi(w) = \frac{\|w\|_2^2}{2\tau^2} + C, \quad \lambda_2 = \frac{1}{2\tau^2}.$$

Коэффициенты регуляризации определяются масштабами априорных распределений: меньшие τ или b означают более сильный штраф.

Лапласовский prior

Если $w_j \stackrel{\text{i.i.d.}}{\sim} \text{Laplace}(0, b)$, то

$$\pi(w) = \prod_{j=1}^d \frac{1}{2b} e^{-|w_j|/b} = (2b)^{-d} \exp\left(-\frac{\|w\|_1}{b}\right).$$

Поэтому

$$-\log \pi(w) = \frac{\|w\|_1}{b} + C, \quad \lambda_1 = \frac{1}{b}.$$

Что делать для сложной статистики?

Для средних и регулярных MLE мы получили формулы стандартной ошибки; для сложной статистики аналитического ответа может не быть.

Для среднего известны удобные формулы. Но как оценить разброс:

- медианы или высокого квантиля;
- F1-score или ROC-AUC;
- разности метрик двух моделей;
- параметра сложного алгоритма?

Об этом позднее

Для таких задач используют бутстрэп: он приближает выборочное распределение статистики повторным ресэмплингом данных.