

Линейная регрессия

Машинное обучение

Александр Безносиков

Московский физико-технический институт

21 сентября 2026



Линейная регрессия

- Вспомним прошлую лекцию: в машинном обучении мы ищем такое отображение $g: \mathbb{R}^d \rightarrow \mathbb{R}$, чтобы оно наилучшим образом приближало связь пространства объектов $\mathcal{X} \rightarrow \mathcal{Y}$.

Линейная регрессия

- Вспомним прошлую лекцию: в машинном обучении мы ищем такое отображение $g: \mathbb{R}^d \rightarrow \mathbb{R}$, чтобы оно наилучшим образом приближало связь пространства объектов $\mathcal{X} \rightarrow \mathcal{Y}$.
- В данной лекции мы работаем в предположении, что целевая переменная y^i **линейно** зависит от объектов x^i .

Линейная регрессия

- Вспомним прошлую лекцию: в машинном обучении мы ищем такое отображение $g: \mathbb{R}^d \rightarrow \mathbb{R}$, чтобы оно наилучшим образом приближало связь пространства объектов $\mathcal{X} \rightarrow \mathcal{Y}$.
- В данной лекции мы работаем в предположении, что целевая переменная y^i **линейно** зависит от объектов x^i . Более формально:

Постановка задачи линейной регрессии

Мы ищем такую функцию

$$g(x^i, w) = w_0 + \sum_{j=1}^d x_j^i w_j,$$

чтобы она максимально точно приближало значение целевой метки y^i .

- В дальнейшем мы всегда настраиваемые параметры w любой необязательно линейной модели g будем называть весами.
- В случае линейной модели название «веса» передает и четкий физический смысл.

Веса: важность предобработки

- Рассмотрим пример зависимости:

x_1	x_2	y
1	2000	2,2
2	3000	3,3
4	4000	4,5

Веса: важность предобработки

- Рассмотрим пример зависимости:

x_1	x_2	y
1	2000	2,2
2	3000	3,3
4	4000	4,5

Вопрос: Какие веса для модели ($w_0 + w_1x_1 + w_2x_2 = y$) нужно взять, чтобы повторить зависимость?

Веса: важность предобработки

- Рассмотрим пример зависимости:

x_1	x_2	y
1	2000	2,2
2	3000	3,3
4	4000	4,5

Вопрос: Какие веса для модели ($w_0 + w_1x_1 + w_2x_2 = y$) нужно взять, чтобы повторить зависимость?

- $w_0 = 0,1$, $w_1 = 0,1$, $w_2 = 0,001$.
- Вопрос:** исходя из размеров весов, можем ли мы что-то сказать о важности каждого из признаков?

Веса: важность предобработки

- Рассмотрим пример зависимости:

x_1	x_2	y
1	2000	2,2
2	3000	3,3
4	4000	4,5

Вопрос: Какие веса для модели ($w_0 + w_1x_1 + w_2x_2 = y$) нужно взять, чтобы повторить зависимость?

- $w_0 = 0,1$, $w_1 = 0,1$, $w_2 = 0,001$.
- Вопрос:** исходя из размеров весов, можем ли мы что-то сказать о важности каждого из признаков? Хочется сказать, что первый признак более важный, так как имеет больший вес, **НО** в то же время изменение второго признака на 50% привело к изменению итоговой метки почти на эти же 50%.

Весы: важность предобработки

- **Вопрос:** как сделать так, чтобы веса w несли информацию о важности признака?

Веса: важность предобработки

- **Вопрос:** как сделать так, чтобы веса w несли информацию о важности признака?
- Попробуем предобработать данные следующим образом, в пределах каждого из признаков отшкалируем так, чтобы все значения лежали в отрезке $[0; 1]$.
- Это просто сделать, например,

$$\tilde{x}_j^i = \frac{x_j^i}{\max_{k \in [n]} |x_j^k|}$$

или

$$\tilde{x}_j^i = \frac{x_j^i - \min_{k \in [n]} x_j^k}{\max_{k \in [n]} |x_j^k| - \min_{k \in [n]} x_j^k}$$

Вес = значимость

- Вспользуемся первым правилом и преобразуем таблицу из примера:

$\tilde{x}_1$	$\tilde{x}_2$	y
0,25	0,5	2,2
0,5	0,75	3,3
1	1	4,5

Веса = значимость

- Воспользуемся первым правилом и преобразуем таблицу из примера:

$\tilde{x}_1$	$\tilde{x}_2$	y
0,25	0,5	2,2
0,5	0,75	3,3
1	1	4,5

- Новые веса: $\tilde{y}_0 = 0, \tilde{y}_1 = 0,4, \tilde{y}_2 = 4$.
- Вот теперь веса $\tilde{y}$ лучше отражают значимость признаков. Видно, что $\tilde{y}_2$ значительно больше $\tilde{y}_1$, что всецело коррелирует с его влиянием на итоговую метку y .

Веса = значимость

- Воспользуемся первым правилом и преобразуем таблицу из примера:

$\tilde{x}_1$	$\tilde{x}_2$	y
0,25	0,5	2,2
0,5	0,75	3,3
1	1	4,5

- Новые веса: $\tilde{w}_0 = 0$, $\tilde{w}_1 = 0,4$, $\tilde{w}_2 = 4$.
- Вот теперь веса $\tilde{w}$ лучше отражают значимость признаков. Видно, что $\tilde{w}_2$ значительно больше $\tilde{w}_1$, что всецело коррелирует с его влиянием на итоговую метку y .
- В машинном обучении часто y так же является признаком и его можно преобразовывать аналогичным образом.
- Кроме приведенного примера существует масса других классических подходов.

Веса: больше предобработок

- Например, давайте потребуем:

$$\frac{1}{n} \sum_{i=1}^n \tilde{x}^i = 0, \quad \frac{1}{n} \sum_{i=1}^n \tilde{y}^i = 0.$$

- **Вопрос:** как такое осуществить?

Веса: больше предобработок

- Например, давайте потребуем:

$$\frac{1}{n} \sum_{i=1}^n \tilde{x}^i = 0, \quad \frac{1}{n} \sum_{i=1}^n \tilde{y}^i = 0.$$

- **Вопрос:** как такое осуществить? Посчитаем $\bar{x} = \frac{1}{n} \sum_{i=1}^n x^i$ и положим $\tilde{x}^i = x^i - \bar{x}$, аналогично для y .

Веса: больше предобработок

- Например, давайте потребуем:

$$\frac{1}{n} \sum_{i=1}^n \tilde{x}^i = 0, \quad \frac{1}{n} \sum_{i=1}^n \tilde{y}^i = 0.$$

- Вопрос:** как такое осуществить? Посчитаем $\bar{x} = \frac{1}{n} \sum_{i=1}^n x^i$ и положим $\tilde{x}^i = x^i - \bar{x}$, аналогично для y .
- Утверждается, что $\tilde{y}_0 = 0$ для таких $\tilde{x}^i$ и $\tilde{y}^i$, если используется квадратичная функция потерь (MSE).

Веса: больше предобработок

- Например, давайте потребуем:

$$\frac{1}{n} \sum_{i=1}^n \tilde{x}^i = 0, \quad \frac{1}{n} \sum_{i=1}^n \tilde{y}^i = 0.$$

- Вопрос:** как такое осуществить? Посчитаем $\bar{x} = \frac{1}{n} \sum_{i=1}^n x^i$ и положим $\tilde{x}^i = x^i - \bar{x}$, аналогично для y .
- Утверждается, что $\tilde{w}_0 = 0$ для таких $\tilde{x}^i$ и $\tilde{y}^i$, если используется квадратичная функция потерь (MSE). Докажем этот факт:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n (\tilde{w}_0 + \langle \tilde{x}^i, \tilde{w} \rangle)^2 &= \frac{1}{n} \sum_{i=1}^n \left[\tilde{w}_0^2 + \sum_{j=1}^d (\tilde{x}_j^i \cdot \tilde{w}_j)^2 \right] \\ &\quad + \frac{2}{n} \sum_{i=1}^n \left[\tilde{w}_0 \cdot \sum_{j=1}^d (\tilde{x}_j^i \cdot \tilde{w}_j) \right] \end{aligned}$$

+ плюс другие удвоенные без $\tilde{w}_0$

Веса: больше предобработок

- Рассмотрим:

$$\begin{aligned} \frac{2}{n} \sum_{i=1}^n \left[\tilde{w}_0 \cdot \sum_{j=1}^d (\tilde{x}_j^i \cdot \tilde{w}_j) \right] &= \frac{2}{n} \cdot \tilde{w}_0 \cdot \left[\sum_{i=1}^n \sum_{j=1}^d (\tilde{x}_j^i \cdot \tilde{w}_j) \right] \\ &= 2\tilde{w}_0 \cdot \left[\sum_{j=1}^d \frac{1}{n} \sum_{i=1}^n (\tilde{x}_j^i \cdot \tilde{w}_j) \right] \\ &= 2\tilde{w}_0 \cdot \left[\sum_{j=1}^d \left(\frac{1}{n} \sum_{i=1}^n \tilde{x}_j^i \right) \cdot \tilde{w}_j \right] \\ &= 0 \end{aligned}$$

Весы: больше предобработок

- Поэтому исходная задача

$$\frac{1}{n} \sum_{i=1}^n (w_0 + \langle x^i, w \rangle - y^i)^2$$

с точки зрения оптимизации по w_0 есть просто $\min_{x_0 \in \mathbb{R}^d} w_0^2$.

- Получается, что при такой предобработке, не нужно искать w_0 . Но такое преобразование справедливо только для квадратичной функции потерь.

Весы: больше предобработок

- Поэтому исходная задача

$$\frac{1}{n} \sum_{i=1}^n (w_0 + \langle x^i, w \rangle - y^i)^2$$

с точки зрения оптимизации по w_0 есть просто $\min_{x_0 \in \mathbb{R}^d} w_0^2$.

- Получается, что при такой предобработке, не нужно искать w_0 . Но такое преобразование справедливо только для квадратичной функции потерь.
- Существуют и другие классические техники. Например, вместо того, чтобы загонять каждый признак в отрезок длины 1 можно сделать похожий трюк, называемый нормализацией.
- Потребуем, чтобы $\frac{1}{n} \sum_{i=1}^n (x_j^i)^2 = 1$. Так будет, если умножим x_j^i на $s(j) = \sqrt{n / \sum_{i=1}^n (x_j^i)^2}$.

Теорема: напоминание

Theorem

Теорема Пусть X - случайная величина с функцией распределения $F_X(t)$. $F_X(t)$ непрерывна. Тогда случайная величина $Z = F_X(X)$ имеет равномерное распределение на отрезке $[0, 1]$.

Теорема: напоминание

Theorem

Теорема Пусть X - случайная величина с функцией распределения $F_X(t)$. $F_X(t)$ непрерывна. Тогда случайная величина $Z = F_X(X)$ имеет равномерное распределение на отрезке $[0, 1]$.

Доказательство. Из определения функции распределения $F_X(a) = P(X \leq a)$. Понятно, что $F_X(a)$ принимает значения от 0 до 1, поэтому для $c \leq 0$ $F_Z(c) = 0$ и для $c \geq 1$ $F_Z(c) = 1$.
При $c \in [0; 1]$ $F_Z(c) = P(Z \leq c) = P(F_X(X) \leq c)$. Заметим, что $F_X(t)$ непрерывная и неубывающая, значит, у неё есть обратная функция:
 $F_X(t) \leq c \iff t \leq F_X^{-1}(c)$.
Получаем $F_Z(c) = P(F_X(X) \leq c) = P(X \leq F_X^{-1}(c)) = F_X(F_X^{-1}(c)) = c$
Это функция распределения равномерного распределения на отрезке $[0; 1]$.

Веса: важность предобработки

Название	Формула	Эффект
-	$\tilde{x}_j^i = \frac{x_j^i}{\max_{k \in [n]} x_j^k }$	Преобразует выборку в диапазон $[-1, 1]$
MinMax	$\tilde{x}_j^i = \frac{x_j^i - \min_{k \in [n]} x_j^k}{\max_{k \in [n]} x_j^k - \min_{k \in [n]} x_j^k}$	Преобразует выборку в диапазон $[0, 1]$
Стандартизация	$\tilde{x}_j^i = \frac{x_j^i - \frac{1}{n} \sum_{k \in [n]} x_j^k}{Var(x_j)}$	Делает среднее 0 и дисперсию 1
Квантильная нормализация	$\tilde{x}_j = F^{-1}(G(x_j)), \text{ где}$ G - эмпирическое распр. каждой с.в., F - эмпирическое распр. усреднённой с.в.	Делает одинаковыми эмпирические распределения с.в.

Максимум правдоподобия

- Но кажется, мы слишком усложняем. Предположим, что некоторая переменная y зависит от переменных $x_1, x_2, x_3, \dots, x_d$ линейным образом:

$$y(x_1, \dots, x_d) = w_0 + w_1x_1 + w_2x_2 + \dots + w_dx_d,$$

где коэффициенты $w_0, \dots, w_d$ нам неизвестны. Предположим, что мы хотим найти эти коэффициенты, измеряя переменную y при различных значениях $x_1, \dots, x_d$. Казалось бы, в этом нет ничего сложного, ведь для решения системы достаточно провести $d + 1$ измерений (как в примере из трех строк выше).

Вопрос: Какая проблема?

Максимум правдоподобия

В действительности может все быть значительно сложнее. Например,

- 1 в реальности зависимость далеко не линейная, но мы просто пытаемся приблизить ее линейной;
- 2 измерения производятся с некоторой погрешностью.

Максимум правдоподобия

- Рассмотрим вторую постановку. В частности, предположим, что для заданного набора $x_1^i, x_2^i, \dots, x_d^i$ мы измеряем

$$y^i = w_0 + x_1^i w_1 + \dots + x_d^i w_d + \xi_i,$$

где $\xi_i \sim \mathcal{N}(0, \sigma^2)$.

Максимум правдоподобия

- Рассмотрим вторую постановку. В частности, предположим, что для заданного набора $x_1^i, x_2^i, \dots, x_d^i$ мы измеряем

$$y^i = w_0 + x_1^i w_1 + \dots + x_d^i w_d + \xi_i,$$

где $\xi_i \sim \mathcal{N}(0, \sigma^2)$.

- Другими словами, мы предполагаем, что

$$y^i \sim \mathcal{N}(w_0 + x_1^i w_1 + \dots + x_d^i w_d, \sigma^2),$$

где параметры $w = (w_0, \dots, w_d)^\top$ должны быть найдены по выборке $\{y^i\}_{i=1}^n$ (мы будем считать, что $y^1, \dots, y^n$ – независимые случайные величины).

Вопрос: Как лучше выбрать параметры $w_0, \dots, w_d$?

Статистический подход: линейная регрессия

- Можно, например, рассмотреть оценку максимального правдоподобия:

$$\begin{aligned}\hat{w} &= \operatorname{argmax}_{w \in \mathbb{R}^{d+1}} \prod_{i=1}^n \frac{1}{\sigma \sqrt{2\pi}} \exp \left(-\frac{1}{2\sigma^2} (y^i - \langle x^i, w \rangle)^2 \right) \\ &= \operatorname{argmax}_{w \in \mathbb{R}^{d+1}} \left[\ln \left(\prod_{i=1}^n \frac{1}{\sigma \sqrt{2\pi}} \exp \left(-\frac{1}{2\sigma^2} (y^i - \langle x^i, w \rangle)^2 \right) \right) \right].\end{aligned}$$

Максимум правдоподобия

- Поскольку логарифм произведения равен сумме логарифмов, а аддитивные и мультипликативные константы не меняют точку оптимума, получаем:

$$\begin{aligned}\hat{w} &= \operatorname{argmax}_{w \in \mathbb{R}^{d+1}} \left\{ \text{Const} + \sum_{i=1}^n -\frac{1}{2\sigma^2} (y^i - \langle x^i, w \rangle)^2 \right\} \\ &= \operatorname{argmin}_{w \in \mathbb{R}^{d+1}} \sum_{i=1}^n (y^i - \langle x^i, w \rangle)^2 \\ &= \operatorname{argmin}_{w \in \mathbb{R}^{d+1}} \frac{1}{n} \|Xw - y\|_2^2,\end{aligned}$$

где X составлена из строк $(x^i)^\top$, y - вектор из y^i .

- Обнаружили связь минимизации эмпирического риска и статистического подхода.

Функции потерь: MSE

Полученная задача минимизации также называется задачей минимизации **квадратичных потерь** (Mean Squared Error, MSE).

MSE

Квадратичной функцией потерь (MSE) называется функция вида

$$\begin{aligned}\mathcal{L}_{\text{MSE}} &= \frac{1}{2} \|Xw - y\|_2^2 \\ &= \frac{1}{2n} \sum_{i=1}^n (y^i - \langle x^i, w \rangle)^2.\end{aligned}$$

Функции потерь: MSE

В случае переопределенной системы (когда $\min \mathcal{L}_{\text{MSE}} = 0$) имеется явный вид решения $\hat{w}$. Это следует напрямую из условий оптимума:

$$\begin{aligned}\nabla_w \mathcal{L}_{\text{MSE}} \Big|_{\hat{w}} &= 0, \\ \nabla_w \left[\frac{1}{2} \|Xw - y\|_2^2 \right] \Big|_{\hat{w}} &= 0, \\ X^\top (X\hat{w} - y) &= 0, \\ \hat{w} &= (X^\top X)^{-1} X^\top y.\end{aligned}$$

Однако, несмотря на распространенность, MSE далеко не единственный способ измерения расстояния.

Функции потерь: MAE

Если MSE, по сути, является евклидовым расстоянием, то MAE (Mean Absolute Error) – это расстояние по ℓ_1 -норме.

MAE

Абсолютной функцией потерь (MAE) называется функция вида

$$\begin{aligned}\mathcal{L}_{\text{MAE}} &= \|Xw - y\|_1 \\ &= \frac{1}{n} \sum_{i=1}^n |y^i - \langle x^i, w \rangle|.\end{aligned}$$

Функции потерь: иные



Есть и другие широко используемые функции потерь:

$$\mathcal{L}_{\text{HUBER}} = \begin{cases} \frac{1}{2n} \sum_{i=1}^n (y^i - \langle x^i, w \rangle)^2, & \text{if } y^i - \langle x^i, w \rangle \leq \delta, \\ \delta \cdot \left(\frac{1}{n} \sum_{i=1}^n |y^i - \langle x^i, w \rangle| - \frac{1}{2}\delta \right), & \text{else.} \end{cases}$$

$$\mathcal{L}_{\text{LOGCOSH}} = \frac{1}{n} \sum_{i=1}^n \log [\cosh(y^i - \langle x^i, w \rangle)]$$

$$\mathcal{L}_{\text{MAPE}} = \frac{1}{n} \sum_{i=1}^n \frac{y^i - \langle x^i, w \rangle}{y^i} \cdot 100\%$$

Функции потерь: значения и градиенты



Напоминание из математической статистики

Пусть есть параметрическое семейство распределений вероятностей $F(t, \theta)$, θ - некий неизвестный нам параметр. Хотим оценить его с помощью выборки $X = \{x^i\}_{i=1}^n$.


Мы можем оценить θ некоторой функцией от выборки ($\hat{\theta}_n = \hat{\theta}_n(\{x^i\}_{i=1}^n)$). По определению такая функция называется **статистикой**.

Оценка $\hat{\theta}_n$ параметра θ называется **несмещённой**, если $\mathbb{E}\hat{\theta}_n = \theta$

Напоминание из математической статистики - 2

Мы можем оценивать не значение параметра, а интервал по выборке (верхняя и нижняя границы такого интервала будут статистиками), в который будет попадать истинное значение параметра с вероятностью не меньше α (уровня доверия). Такой интервал **доверительный**.

Предсказательный интервал - это диапазон значений, в который, как ожидается, попадет новое наблюдение, основанное на предыдущих данных и модели. По своей сути это доверительный интервал для прогноза значения случайной величины.



Напоминание из математической статистики - 3

Статистическая гипотеза — это определённое предположение о распределении вероятностей, лежащем в основе наблюдаемой выборки данных.

Пример: Длина хвостов у котиков имеет нормальное распределение. Проверка гипотезы — это процесс принятия решения о том, противоречит ли рассматриваемая статистическая гипотеза наблюдаемой выборке данных.

Статистический критерий — строгое математическое правило, по которому принимается или отвергается статистическая гипотеза. Гипотезу, которую мы рассматриваем (хотим принять или отвергнуть) называют **нулевой** - H_0 . Параллельно рассматривается противоречащая ей гипотеза H_1 , называемая конкурирующей или альтернативной.

Метод наименьших квадратов

Рассмотрим задачу квадратичной минимизации MSE:

$$\min_{w \in \mathbb{R}^d} \|Xw - y\|_2^2$$

Метод наименьших квадратов

Рассмотрим задачу квадратичной минимизации MSE:

$$\min_{w \in \mathbb{R}^d} \|Xw - y\|_2^2$$

Асимптотическое решение: $\hat{w} = (X^T X)^{-1} X^T y$
Предсказание для объекта x^0 : $\hat{y}(x^0) = (x^0)^T \hat{w}$.

Метод наименьших квадратов

Рассмотрим задачу квадратичной минимизации MSE:

$$\min_{w \in \mathbb{R}^d} \|Xw - y\|_2^2$$

Асимптотическое решение: $\hat{w} = (X^T X)^{-1} X^T y$

Предсказание для объекта x^0 : $\hat{y}(x^0) = (x^0)^T \hat{w}$.

Предположения и следствия:

- 1 $\mathbb{E}\varepsilon = 0$, где $\varepsilon = \hat{y} - y$ — несмещенность:
 - $\hat{w}$ — несмещенная оценка w ,
 - $\hat{y}(x^0)$ — несмещенная оценка $y(x^0)$.
- 2 $\mathbb{E}\varepsilon = 0$ и $\mathbb{D}\varepsilon = \sigma^2 I_n$
 - $\mathbb{D}\hat{w} = \sigma^2 (X^T X)^{-1}$, $\mathbb{D}\hat{y}(x^0) = \sigma^2 (x^0)^T (X^T X)^{-1} x^0$;
 - $\hat{\sigma}^2 = \frac{1}{n-d} \|y - X\hat{w}\|_2^2$ — несмещенная оценка σ^2 .
- 3 $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$ — гауссовская линейная модель:
 - МНК совпадает с ОМП для w .

Доверительные интервалы при $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$

Дов. интервал для размера шума предсказанного значения:

$$\sigma \in \left(\sqrt{\|y - X\hat{w}\|^2 / \chi_{n-d, \frac{1+\alpha}{2}}^2}, \sqrt{\|y - X\hat{w}\|^2 / \chi_{n-d, \frac{1-\alpha}{2}}^2} \right)$$

Дов. интервал для коэффициента перед j -м признаком:

$$w_j \in (\hat{w}_j \pm T_{n-d, \frac{1+\alpha}{2}} \cdot \hat{\sigma} \sqrt{(X^T X)^{-1}_{jj}})$$

Дов. интервал для среднего предсказанного значения на

объекте x^0 : $(x^0)^T w \in \left((x^0)^T \hat{w} \pm T_{n-d, \frac{1+\alpha}{2}} \cdot \hat{\sigma} \sqrt{(x^0)^T (X^T X)^{-1} x^0} \right)$

Предск. интервал для предсказанного значения на объекте x^0

$$(x^0)^T w + \varepsilon \in \left((x^0)^T \hat{w} \pm T_{n-d, \frac{1+\alpha}{2}} \cdot \hat{\sigma} \sqrt{1 + (x^0)^T (X^T X)^{-1} x^0} \right)$$

$T_{n-d, \frac{1+\alpha}{2}}$ - это $\frac{1+\alpha}{2}$ квантиль с $n - d$ степенями свободы, соответствующее верхней границе доверительного интервала для уровня доверия α . Обычно $\alpha = 0.95$


Распределение Стьюдента

Обозначение: T_k — распределение Стьюдента с k степенями свободы

- Параметр k — кол-во степеней свободы;
- T_1 — распределение Коши, $T_\infty = \mathcal{N}(0, 1)$
- Плотность

$$p(x) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\sqrt{\pi k} \Gamma(k/2)} \left(1 + \frac{x^2}{k}\right)^{-\frac{k+1}{2}};$$

- Если $\xi \sim \mathcal{N}(0, 1)$ и $\eta \sim \chi_k^2$ независимы, то $\zeta = \frac{\xi}{\sqrt{\eta/k}} \sim T_k$
- Если $\zeta \sim T_k$, то $E\zeta = 0$ при $k > 1$
- Если $\zeta \sim T_k$, то $D\zeta = \frac{k}{k-2}$ при $k > 2$
- $T_{k,p}$ — p -квантиль распределения T_k
- `scipy.stats.t(df=k)`



Значим ли признак x_j ?

Гипотеза о незначимости коэффициента w_j

$H_0 : w_j = 0$ vs. $H_1 : w_j (<, \neq, >) 0$

Критерий Стьюдента (t-test)

$$T_j(X, Y) = \frac{\hat{w}_j}{\hat{\sigma} \sqrt{(X^T X)^{-1}_{jj}}} \underset{H_0}{\sim} T_{n-d},$$

где $T_j(X, Y)$ — t-статистика критерия.

Для $H_1 : w_j \neq 0$ критерий имеет вид

$$\{|T_j(X, y)| > T_{n-d, 1-\alpha/2}\},$$

где число α — уровень значимости, обычно $\alpha = 0.05$.

Если H_0 не отвергается, то можно считать, что w_j отклоняется от нуля статистически незначимо.

Вырожденность матрицы

Для формулы $w = (X^T X)^{-1} X^T y$ нам важно, чтобы матрица $X^T X$ не была вырожденной.

Вопрос: может ли эта матрица быть вырожденной?

Вырожденность матрицы

Для формулы $w = (X^T X)^{-1} X^T y$ нам важно, чтобы матрица $X^T X$ не была вырожденной.

Вопрос: может ли эта матрица быть вырожденной?

В теории в линеале это не такая частая проблема. На практике же точности вычислений может не хватать и аналитически не вырожденная матрица может стать вырожденной.

Вырожденность матрицы

Для формулы $w = (X^T X)^{-1} X^T y$ нам важно, чтобы матрица $X^T X$ не была вырожденной.

Вопрос: может ли эта матрица быть вырожденной?

В теории в линеале это не такая частая проблема. На практике же точности вычислений может не хватать и аналитически не вырожденная матрица может стать вырожденной.

Решения:

① **Регуляризация**

$$\arg \min_w (\|Xw - y\|_2^2 + \lambda \|w\|_2^2) = (X^T X + \lambda I)^{-1} X^T y$$

② **Селекция (отбор) признаков**

③ **Уменьшение размерности (в том числе, PCA)**

④ **Увеличение выборки**

Классификация

Перейдем к теперь постановки задачи бинарной классификации ($|\mathcal{Y}| = 2$) с метками классов $\{-1, +1\}$.

Вопрос. Как перейти от результатов регрессии с квадратичной функцией потерь к получению предсказания меток классов?

Классификация

Перейдем к теперь постановки задачи бинарной классификации ($|\mathcal{Y}| = 2$) с метками классов $\{-1, +1\}$.

Вопрос. Как перейти от результатов регрессии с квадратичной функцией потерь к получению предсказания меток классов?

Нетрудно догадаться, что используя функцию sign (взятие знака), мы можем преобразовать наше непрерывное предсказание в дискретное:

$$\text{sign} \left(w_0 + \sum_{j=1}^d x_j w_j \right) \rightarrow \{-1, +1\}.$$

Классификация

Перейдем к теперь постановки задачи бинарной классификации ($|\mathcal{Y}| = 2$) с метками классов $\{-1, +1\}$.

Вопрос. Как перейти от результатов регрессии с квадратичной функцией потерь к получению предсказания меток классов?


Нетрудно догадаться, что используя функцию sign (взятие знака), мы можем преобразовать наше непрерывное предсказание в дискретное:

$$\text{sign} \left(w_0 + \sum_{j=1}^d x_j w_j \right) \rightarrow \{-1, +1\}.$$

В качестве threshold -а (разделяющего параметра) здесь используется 0, однако, мы вольны выбирать его произвольно (например, положив равным 0.5).


Геометрический смысл линейного классификатора

Пример некоторой гиперплоскости



Accuracy: 0.5

Пример гиперплоскости с лучшим разбиением



Accuracy: 0.73

Разделяющие классификаторы (margin-based classifiers)

Разделяющий классификатор: $g(x, w) = \text{sign } g(x, w)$


$g(x, w)$ — разделяющая (дискриминантная) функция;

$g(x, w) = 0$ — уравнение разделяющей поверхности;

$M_i(w) = g(x^i, w)y^i$ - отступ (margin) объекта x^i ;

$M_i(w) < 0 \iff$ алгоритм $a(x, w)$ ошибается на x^i .

Таким образом, M_i отражает уверенность модели.



Вопрос: А почему нам тогда сразу не минимизировать функции вида

$$\frac{1}{n} \sum_{i=1}^n \mathbb{I} [\text{sign} (w_0 + \langle x^i, w \rangle) \neq y^i]?$$

Классификация

Вопрос: А почему нам тогда сразу не минимизировать функции вида

$$\frac{1}{n} \sum_{i=1}^n \mathbb{I} [\text{sign} (w_0 + \langle x^i, w \rangle) \neq y^i]?$$

Такую задачу сложно решать численными методами (о них на следующей лекции): считать градиент, а значит в качестве функции потерь ее использовать проблематично. Однако, если мы немного изменим ее вид на $1 - \frac{1}{n} \sum_{i=1}^n \mathbb{I} [\text{sign} (w_0 + \langle x^i, w \rangle) \neq y^i] \rightarrow \max_w$, то получим крайне интуитивно понятную структуру. Мы пытаемся максимизировать нашу точность предсказаний, уменьшая количество неверно предсказанных меток. Данная функция является *метрикой* качества нашего предсказания и называется **accuracy**.

Классификация

Рассмотрим различные значения threshold-а на синтетическом датасете для бинарной классификации. Зависимости от выбранного значения сильно меняются предсказания меток классов. На примерах ниже предпочтителен $t = 0$.

