Субградиентный спуск. AdaGrad, Adam, DoG. Регуляризация ℓ_1, ℓ_2. AdamW

Александр Безносиков

ФПМИ МФТИ

5 октября 2026

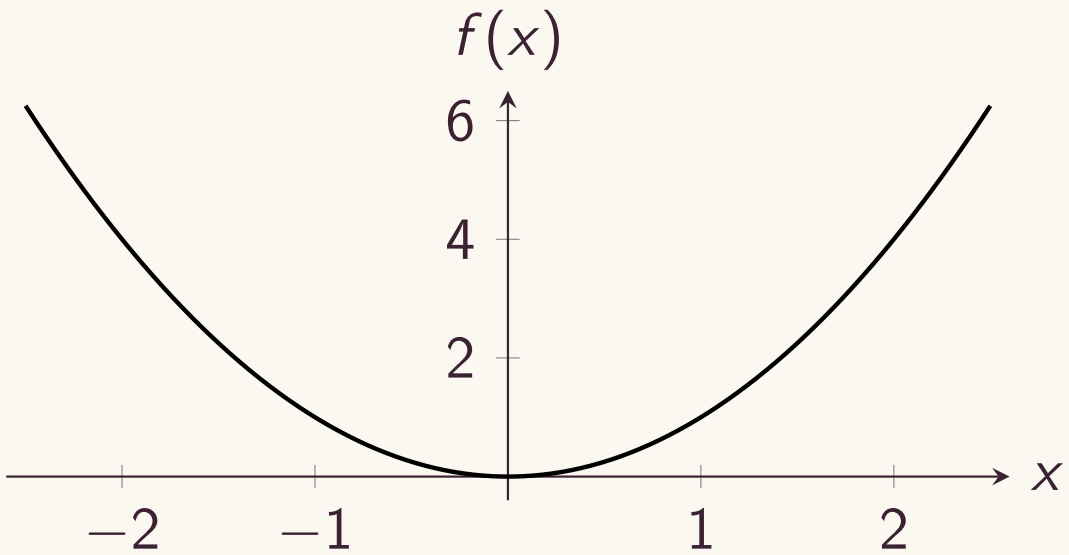


Негладкие задачи

Напомним, что содержательную теорию сходимости часто строят для выпуклых функций.

Определение выпуклости

Пусть дана непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \to \mathbb{R}$. Будем говорить, что она является *выпуклой*, если для любых $v, w \in \mathbb{R}^d$ выполнено $f(w) \geq f(v) + \langle \nabla f(v), w - v \rangle$.



Негладкие задачи

- **Вопрос:** функция $f(w) = |w|$ выпукла?

Негладкие задачи

- **Вопрос:** функция $f(w) = |w|$ выпукла? Безусловно. А дифференцируемая и гладкая?

Негладкие задачи

- **Вопрос:** функция $f(w) = |w|$ выпукла? Безусловно. А дифференцируемая и гладкая? Нет.
- Получается, что даже довольно простые выпуклые функции могут быть негладким. До этого мы смотрели только на задачи с гладкими функциями.

Негладкие задачи

Будем рассматривать следующее предположение вместо гладкости (Липшицевости градиента):

Определение M-Липшецевой функции

Пусть дана функция $f : \mathbb{R}^d \to \mathbb{R}$. Будем говорить, что она является M-Липшицева, если для любых $w, v \in \mathbb{R}^d$ выполнено

$$|f(w) - f(v)| \leq M\|w - v\|_2.$$

Негладкие задачи

Будем рассматривать следующее предположение вместо гладкости (Липшицевости градиента):

Определение M-Липшецевой функции

Пусть дана функция $f : \mathbb{R}^d \to \mathbb{R}$. Будем говорить, что она является M-Липшицева, если для любых $w, v \in \mathbb{R}^d$ выполнено

$$|f(w) - f(v)| \leq M\|w - v\|_2.$$

Вопрос: почему те же функции не могут быть сильно выпуклыми?

Негладкие задачи

Будем рассматривать следующее предположение вместо гладкости (Липшицевости градиента):

Определение M-Липшецевой функции

Пусть дана функция $f : \mathbb{R}^d \to \mathbb{R}$. Будем говорить, что она является M-Липшицева, если для любых $w, v \in \mathbb{R}^d$ выполнено

$$|f(w) - f(v)| \leq M\|w - v\|_2.$$

Вопрос: почему те же функции не могут быть сильно выпуклыми? Физический смысл сильной выпуклости — рост функции на бесконечности не медленнее квадратичного.

Негладкие задачи

Будем рассматривать следующее предположение вместо гладкости (Липшицевости градиента):

Определение M-Липшецевой функции

Пусть дана функция $f : \mathbb{R}^d \to \mathbb{R}$. Будем говорить, что она является M-Липшицева, если для любых $w, v \in \mathbb{R}^d$ выполнено

$$|f(w) - f(v)| \leq M\|w - v\|_2.$$

Вопрос: почему те же функции не могут быть сильно выпуклыми? Физический смысл сильной выпуклости — рост функции на бесконечности не медленнее квадратичного.
При этом, физический смысл L-липшицевости — рост функции на бесконечности не быстрее линейного. Поэтому на $\mathbb{R}^d$ таких функций нет.

Субградиент и субдифференциал

Если функция не дифференцируема в точке, а значит градиента нет.
Что может существовать вместо градиента?

Субградиент и субдифференциал

Если функция не дифференцируема в точке, а значит градиента нет. Что может существовать вместо градиента?

Субградиент и субдифференциал

Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. Вектор g будем называть субградиентом этой функции f в точке $w \in \mathbb{R}^d$, если для любого $v \in \mathbb{R}^d$ выполняется:

$$f(v) \geq f(w) + \langle g, v - w \rangle.$$

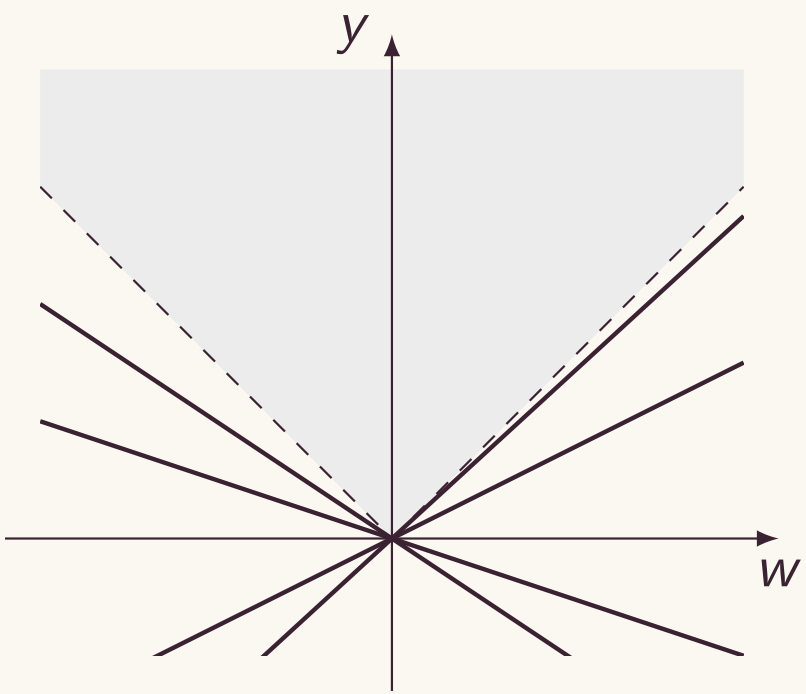
Множество $\partial f(w)$ всех субградиентов f в w будем называть субдифференциалом.

Поиск субдифференциала

Найдем субдифференциал функции $f(w) = |w|$ в $w = 0$.
По определению, вектор $g \in \mathbb{R}$ является субградиентом для функции $f(w) = |w|$ в точке 0, если $\forall w \in \mathbb{R}\ |w| \geq gw$.
Решая данное неравенство, мы получаем, что оно выполняется для всех $g \in [-1, 1]$ и только для таких g.

Поиск субдифференциала

Найдем субдифференциал функции $f(w) = |w|$ в $w = 0$.
По определению, вектор $g \in \mathbb{R}$ является субградиентом для функции $f(w) = |w|$ в точке 0, если $\forall w \in \mathbb{R}\ |w| \geq gw$.
Решая данное неравенство, мы получаем, что оно выполняется для всех $g \in [-1, 1]$ и только для таких g.



$y \geq |w|$
$y = |w|$
$y = \alpha w, \alpha \in [-1, 1]$

Также субдифференциал можно найти графически. Заметим, что при $\alpha \in [-1, 1]$ прямая $y = \alpha w$ пересекает график в точке (0, 0), а в

Условие оптимальности

Теорема (условие оптимальности)

w^* – минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f(w^*).$$

Условие оптимальности

Теорема (условие оптимальности)

w^* – минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f(w^*).$$

Теорема является обобщением условия оптимальности гладких выпуклых функций.

Теорема (условие оптимальности, частный случай)

w^* — минимум выпуклой функции f тогда и только тогда, когда

$$\nabla f(x^*) = 0.$$

Свойство M-Липшицевой функции

Лемма (свойство M-Липшицевой функции)

Пусть дана выпуклая функция $f : \mathbb{R}^d \to \mathbb{R}$. Тогда функция f является M-Липшицевой тогда и только тогда, когда для любого $w \in \mathbb{R}^d$ и $g \in \partial f(w)$ имеем $\|g\|_2 \leq M$.

Субградиентный метод

- Рассматриваем задачу:

$$\min_{w \in \mathbb{R}^d} f(w),$$

где f выпуклая и M-Липшицева.

Субградиентный метод

- Рассматриваем задачу:

$$\min_{w \in \mathbb{R}^d} f(w),$$

  где f выпуклая и M-Липшицева.
- Простая идея – вместо градиента использовать какой-то субградиент в текущей точке:

Algorithm Субградиентный метод

Input: размеры шага $\gamma > 0$, стартовая точка $w^0 \in \mathbb{R}^d$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(w^k)$
3: $w^{k+1} = w^k - \gamma g^k$
4: **end for**

Output: $\frac{1}{K} \sum_{k=0}^{K-1} w^k$

Сходимость

Теорема (сходимость субградиентного спуска для M-Липшицевых и выпуклых функций)

Пусть задача безусловной оптимизации с M-Липшицевой, выпуклой целевой функцией f решается с помощью субградиентного спуска. Тогда при $\gamma_k = \gamma$ справедлива следующая оценка сходимости

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} w^k\right) - f(w^*) \leq \frac{\|w^0 - w^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}$$

Сходимость

Теорема (сходимость субградиентного спуска для M-Липшицевых и выпуклых функций)

Пусть задача безусловной оптимизации с M-Липшицевой, выпуклой целевой функцией f решается с помощью субградиентного спуска. Тогда при $\gamma_k = \gamma$ справедлива следующая оценка сходимости

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} w^k\right) - f(w^*) \leq \frac{\|w^0 - w^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}$$

Минимизируя правую часть по $\gamma > 0$ получаем оптимальное значение шага:

$$\gamma^* = \frac{\|w^0 - w^*\|_2^2}{M\sqrt{K}}$$

Для оптимального шага можем получить следующее утверждение:

Сходимость

Утверждение (сходимость субградиентного спуска для M-липшицевых и выпуклых функций)

Пусть задача удовлетворяет условиям предыдущей теоремы и выбрано значение шага $\gamma = \frac{\|w^0 - w^*\|_2^2}{M\sqrt{K}}$. Тогда справедлива оценка сходимости:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} w^k\right) - f(w^*) \leq \frac{M\|w^0 - w^*\|_2^2}{\sqrt{K}}$$

Более того, чтобы добиться точности ε по функции ($f(\frac{1}{K}\sum_{k=1}^{K-1} w^k) - f(w^*) \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{M^2\|w^0 - w^*\|_2^2}{\varepsilon^2}\right) \quad \text{итераций}$$

Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.

Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае?

Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость в негладком случае медленнее.

Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость в негладком случае медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум.

Субградиентный метод: итог

- Обобщение градиентного спуска на негладкие задачи.
- Оценки сходимости в выпуклом случае: $\sim \frac{1}{\sqrt{K}}$, в сильно выпуклом случае: $\sim \frac{1}{K}$. **Вопрос:** какие были у градиентного спуска в гладком случае? $\sim \frac{1}{K}$ и линейная соответственно. Сходимость в негладком случае медленнее.
- Может возможно улучшить результат? Например, улучшить анализ или использовать моментум. В общем случае результат для субградиентного метода является неулучшаемым для выпуклых и сильно-выпуклых задач, т.е. он оптимален.

AdaGradNorm

- В Утверждении был взят шаг $\gamma = \frac{\|w^0 - w^*\|_2}{M\sqrt{K}}$.
- **Вопрос:** Какие есть проблемы в таком подходе?

AdaGradNorm

- В Утверждении был взят шаг $\gamma = \frac{\|w^0 - w^*\|_2}{M\sqrt{K}}$.
- **Вопрос:** Какие есть проблемы в таком подходе? Зависимость от $K, M, \|w^0 - w^*\|_2$.

AdaGradNorm

- В Утверждении был взят шаг $\gamma = \frac{\|w^0 - w^*\|_2}{M\sqrt{K}}$.
- **Вопрос:** Какие есть проблемы в таком подходе? Зависимость от $K, M, \|w^0 - w^*\|_2$.
- Можно взять $\gamma_k = \frac{\|w^0 - w^*\|_2}{M\sqrt{k+1}}$ и избавиться от K.

AdaGradNorm

- Как было сказано ранее, M – ограничение нормы (суб)градиента, тогда можно использовать сам (суб)градиент в качестве этого ограничения. Получим:

$$\sum_{t=0}^{k} \left\|g^t\right\|_2^2 \approx M^2 k.$$

- Кроме этого, пусть $\|w^0 - w^*\|_2 \leq D$. Можем переписать оптимальный шаг:

$$\gamma_k = \frac{\|w^0 - w^*\|_2}{M\sqrt{k}+1} \approx \frac{\|w^0 - w^*\|_2}{\sqrt{\sum_{t=0}^{k} \left\|g^t\right\|_2^2}} \approx \frac{D}{\sqrt{\sum_{t=0}^{k} \left\|g^t\right\|_2^2}}.$$

AdaGradNorm

- Получился метод AdaGradNorm. Ada – адаптивность под локальные свойства задачи (в данном случае локальные значения M).

Algorithm AdaGradNorm

Input: $D > 0$, стартовая точка $w^0 \in \mathbb{R}^d$, сумма квадратов норм градиентов $G^0 = 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(w^k)$
3: Вычислить $G^{k+1} = G^k + \|g^k\|_2^2$
4: $w^{k+1} = w^k - \frac{D}{\sqrt{G^{k+1}}} g^k$
5: **end for**

Output: $\frac{1}{K} \sum_{k=0}^{K-1} w^k$

AdaGradNorm

- На практике AdaGradNorm не даёт выигрыша по сравнению с обычным подбором γ — мы просто получаем ещё один параметр D, который тоже нужно как-то выбирать.
- А вот с точки зрения теории он полезен: если искать минимум на компакте C, за D можно взять диаметр этого множества, $D = \operatorname{diam}(C)$.

AdaGrad

- Пойдем дальше и сделаем адаптивность по каждой координате (индивидуальный шаг). Получится AdaGrad:

$$\gamma_{k,i} = \frac{\tilde{D}}{\sqrt{\sum_{t=0}^{k} (g_i^t)^2}}, \quad \text{где} \quad \sup_i \|w_i - w_i^*\|_2 \leq \tilde{D}.$$

- Исторически этот метод появился раньше AdaGradNorm.
- Обычно $\tilde{D}$ подбирают, но в этом случае подбор более обоснованный: шаг индивидуален по каждой координате, но $\tilde{D}$ единая для каждой координаты.

AdaGrad

Algorithm AdaGrad

Input: $\tilde{D} > 0$, стартовая точка $w^0 \in \mathbb{R}^d$, сумма квадратов градиентов $G_i^0 = 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**

2: Вычислить $g^k \in \partial f(w^k)$

3: Для каждой координаты: $G_i^{k+1} = G_i^k + (g_i^k)^2$

4: Для каждой координаты: $w_i^{k+1} = w_i^k - \dfrac{\tilde{D}}{\sqrt{G_i^{k+1}}} g_i^k$

5: **end for**

Output: $\frac{1}{K} \sum_{k=0}^{K-1} w^k$

Сходимость AdaGrad

Теорема сходимость AdaGrad для M-Липшицевых и выпуклых функций

Пусть задача оптимизации с M-Липшицевой, выпуклой целевой функцией f решается с помощью AdaGrad на ограниченном множестве. Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} w^k\right) - f(w^*) \leq \frac{3Md\tilde{D}}{2\sqrt{K}}.$$

Более того, чтобы добиться точности ε по функции, необходимо

$$K = O\left(\frac{9M^2(d\tilde{D})^2}{4\varepsilon^2}\right) \text{ итераций.}$$

RMSProp

- Проблема AdaGrad, что старые градиенты в шаге могут быть уже не особо релевантны. Информация о $\|g\|_2$ может быть далека от локальных свойств фукнции на текущей итерации.
  Вопрос: как можно попробовать их «забывать»?

RMSProp

- Проблема AdaGrad, что старые градиенты в шаге могут быть уже не особо релевантны. Информация о $\|g\|_2$ может быть далека от локальных свойств фукнции на текущей итерации.
  Вопрос: как можно попробовать их «забывать»?
- Может помочь техника моментума с $\beta_2 \in (0, 1)$ (вспомните, как она работала в случае тяжелого шарика):

$$G_i^{k+1} = \beta_2 G_i^k + (1 - \beta_2)(g_i^k)^2,$$

$$\gamma_{k,i} = \frac{\tilde{D}}{\sqrt{G_i^{k+1}}} g_i^k.$$

Получился метод RMSProp.

RMSProp

Algorithm RMSProp

Input: $\tilde{D} > 0$, моментум $\beta_2 \in (0, 1)$, стартовая точка $w^0 \in \mathbb{R}^d$, сглаженная сумма квадратов градиентов $G_i^0 = 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(w^k)$
3: Для каждой координаты: $G_i^{k+1} = \beta_2 G_i^k + (1 - \beta_2)(g_i^k)^2$
4: Для каждой координаты: $w_i^{k+1} = w_i^k - \frac{\tilde{D}}{\sqrt{G_i^{k+1}}} g_i^k$
5: **end for**

Output: $\frac{1}{K} \sum_{k=0}^{K-1} w^k$

Adam

- Почему бы не добавить и классический моментум вида тяжелого шарика для ускорения? Получится метод Adam:

$$\text{тяжелый шарик: } v^{k+1} = \beta_1 v^k + (1-\beta_1) g^k,$$

$$\text{RMSProp: } G_i^{k+1} = \beta_2 G_i^k + (1-\beta_2)(g_i^k)^2,$$

$$w_i^{k+1} = w_i^k - \frac{\tilde{D}}{\sqrt{G_i^{k+1}}} v_i^{k+1}.$$

Adam

- Почему бы не добавить и классический моментум вида тяжелого шарика для ускорения? Получится метод Adam:

$$\text{тяжелый шарик: } v^{k+1} = \beta_1 v^k + (1-\beta_1) g^k,$$

$$\text{RMSProp: } G_i^{k+1} = \beta_2 G_i^k + (1-\beta_2)(g_i^k)^2,$$

$$w_i^{k+1} = w_i^k - \frac{\tilde{D}}{\sqrt{G_i^{k+1}}} v_i^{k+1}.$$

- Можно еще доработать – например, менять коэффициенты β_1, β_2 в зависимости от шага: β_1^k, β_2^k, чтобы избежать избыточно большого шага.

Adam

- Почему бы не добавить и классический моментум вида тяжелого шарика для ускорения? Получится метод Adam:

$$\text{тяжелый шарик: } v^{k+1} = \beta_1 v^k + (1-\beta_1) g^k,$$

$$\text{RMSProp: } G_i^{k+1} = \beta_2 G_i^k + (1-\beta_2)(g_i^k)^2,$$

$$w_i^{k+1} = w_i^k - \frac{\tilde{D}}{\sqrt{G_i^{k+1}}} v_i^{k+1}.$$

- Можно еще доработать – например, менять коэффициенты β_1, β_2 в зависимости от шага: β_1^k, β_2^k, чтобы избежать избыточно большого шага.
- Ещё можно обезопасить себя от деления на 0 с помощью небольшой добавки $e \sim 10^{-6} - 10^{-8}$:

$$w_i^{k+1} = w_i^k - \frac{D}{\sqrt{G_i^{k+1} + e}} v_i^{k+1}$$

Adam

Algorithm Adam

Input: $\tilde{D} > 0$, моментумы $\{\beta_1^k\} \in (0,1)$ и $\{\beta_2^k\} \in (0,1)$, стартовая точка $w^0 \in \mathbb{R}^d$, сглаженная сумма квадратов градиентов $G_i^0 = 0$, сглаженная сумма градиентов $v^0 = 0$, добавка $e > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(w^k)$
3: Вычислить $v^{k+1} = \beta_1^k v^k + (1 - \beta_1^k) g^k$
4: Для каждой координаты: $G_i^{k+1} = \beta_2^k G_i^k + (1 - \beta_2^k)(g_i^k)^2$
5: Для каждой координаты: $w_i^{k+1} = w_i^k - \dfrac{\tilde{D}}{\sqrt{G_i^{k+1} + e}} v_i^{k+1}$
6: **end for**

Output: $\frac{1}{K} \sum_{k=0}^{K-1} w^k$

DoG

- Ситуация в общем случае даже ухудшилась по сравнению с AdaGrad: кроме шага $\tilde{D}$, нужно подбирать еще моментумы β_1, β_2.

DoG

- Ситуация в общем случае даже ухудшилась по сравнению с AdaGrad: кроме шага $\tilde{D}$, нужно подбирать еще моментумы β_1, β_2.
- Часто рекомендуют брать $\beta_1 = 0.9$, а $\beta_2 = 0.99$, но все равно нужно подбирать $\tilde{D}$.

DoG

- Ситуация в общем случае даже ухудшилась по сравнению с AdaGrad: кроме шага $\tilde{D}$, нужно подбирать еще моментумы β_1, β_2.
- Часто рекомендуют брать $\beta_1 = 0.9$, а $\beta_2 = 0.99$, но все равно нужно подбирать $\tilde{D}$.
- Проблема поиска $\tilde{D}$ исконно пришла от того, что мы не знали $\|w^0 - w^*\|_2$. **Вопрос:** мы знаем w^0, какая точка (в некотором смысле) является хорошим выбором в качестве приближения w^*?

DoG

- Можно предположить, что $w^k \approx w^*$ (метод приближается к решению):

$$\|w^0 - w^*\|_2 \to \|w^0 - w^k\|_2 \quad \to \quad d_k = \max_{t \in [k-1]} \|w^0 - w^t\|_2.$$

или

$$|w_i^0 - w_i^*| \to |w_i^0 - w_i^k| \quad \to \quad d_{k,i} = \max_{t \in [k-1]} |w_i^0 - w_i^t|.$$

DoG

- Можно предположить, что $w^k \approx w^*$ (метод приближается к решению):

$$\|w^0 - w^*\|_2 \to \|w^0 - w^k\|_2 \quad \to \quad d_k = \max_{t \in [k-1]} \|w^0 - w^t\|_2.$$

или

$$|w_i^0 - w_i^*| \to |w_i^0 - w_i^k| \quad \to \quad d_{k,i} = \max_{t \in [k-1]} |w_i^0 - w_i^t|.$$

- Имеем метод DoG:

$$\gamma_k = \frac{d_k}{\sqrt{\sum_{t=0}^{k} \|g^t\|_2^2}} \quad \text{или} \quad \gamma_{k,i} = \frac{d_{k,i}}{\sqrt{\sum_{t=0}^{k} (g_i^t)^2}}.$$

DoG

Метод DoG:

$$\gamma_k = \frac{d_k}{\sqrt{\sum\limits_{t=0}^{k} \|g^t\|_2^2}} \quad \text{или} \quad \gamma_{k,i} = \frac{d_{k,i}}{\sqrt{\sum\limits_{t=0}^{k} (g_i^t)^2}}.$$

Вопрос: Почему DoG?

DoG

Метод DoG:

$$\gamma_k = \frac{d_k}{\sqrt{\sum\limits_{t=0}^{k} \|g^t\|_2^2}} \quad \text{или} \quad \gamma_{k,i} = \frac{d_{k,i}}{\sqrt{\sum\limits_{t=0}^{k} (g_i^t)^2}}.$$

Вопрос: Почему DoG? Distance over Gradients:

$$d_k = \max_{t \in [k-1]} \| \sum_{\tau=0}^{t} \gamma_\tau \nabla f(w^\tau) \|_2.$$

DoG

Algorithm DoG v1

Input: стартовая точка $w^0 \in \mathbb{R}^d$, сумма квадратов норм градиентов $G^0 = 0$, расстояние от точки старта $d_0 = 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(w^k)$
3: Вычислить $G^{k+1} = G^k + \|g^k\|_2^2$
4: Вычислить $d_{k+1} = \max\{d_k; \|w^0 - w^k\|\}$
5: $w^{k+1} = w^k - \frac{d_{k+1}}{\sqrt{G^{k+1}}} g^k$
6: **end for**

Output: $\frac{1}{K}\sum_{k=0}^{K-1} w^k$

DoG

Algorithm DoG v2

Input: стартовая точка $w^0 \in \mathbb{R}^d$, сумма квадратов градиентов $G_i^0 = 0$, координатные расстояния от точки старта $d_{0,i}$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(w^k)$
3: Для каждой координаты: $G_i^{k+1} = G_i^k + (g_i^k)^2$
4: Вычислить $d_{k+1,i} = \max\{d_{k,i}; |w_i^0 - w_i^k|\}$
5: Для каждой координаты: $w_i^{k+1} = w_i^k - \frac{d_{k,i}}{\sqrt{G_i^{k+1}}} g_i^k$
6: **end for**

Output: $\frac{1}{K}\sum_{k=0}^{K-1} w^k$

Регуляризация

- Вспомним: точный минимум функции потерь не нужен. **Вопрос:** Почему?

Регуляризация

- Вспомним: точный минимум функции потерь не нужен. **Вопрос:** Почему?
- Модель переобучится под тестовую выборку.
- Вспомним про регуляризацию, как способ борьбы с переобучением:

$$\min_{w \in \mathbb{R}^d} \left[\tilde{f}(w) = f(w) + \frac{\lambda}{2} \|w\|_2^2 \right]$$

- Таким образом мы модифицируем целевую функцию. Как это влияет на адаптивные методы?

Регуляризация

- Посмотрим на итерацию метода Adam :
  1: Вычислить $g^k \in \partial \tilde{f}(w^k)$
  2: Вычислить $v^{k+1} = \beta_1^k v^k + (1 - \beta_1^k) g^k$
  3: Для каждой координаты: $G_i^{k+1} = \beta_2^k G_i^k + (1 - \beta_2^k)(g_i^k)^2$
  4: Для каждой координаты: $w_i^{k+1} = w_i^k - \frac{D}{\sqrt{G_i^{k+1} + e}} v_i^{k+1}$
- Вслед за целевой функцией меняется субградиент, а значит и аккумулируемые величины.

Регуляризация

- Посмотрим на итерацию метода Adam :
  1: Вычислить $g^k \in \partial \tilde{f}(w^k)$
  2: Вычислить $v^{k+1} = \beta_1^k v^k + (1 - \beta_1^k) g^k$
  3: Для каждой координаты: $G_i^{k+1} = \beta_2^k G_i^k + (1 - \beta_2^k)(g_i^k)^2$
  4: Для каждой координаты: $w_i^{k+1} = w_i^k - \frac{D}{\sqrt{G_i^{k+1} + e}} v_i^{k+1}$
- Вслед за целевой функцией меняется субградиент, а значит и аккумулируемые величины.
- Не будем менять целевую функцию, а просто добавим градиент регуляризационного члена в обновление переменной w^k. Получим метод AdamW:

AdamW

Algorithm AdamW

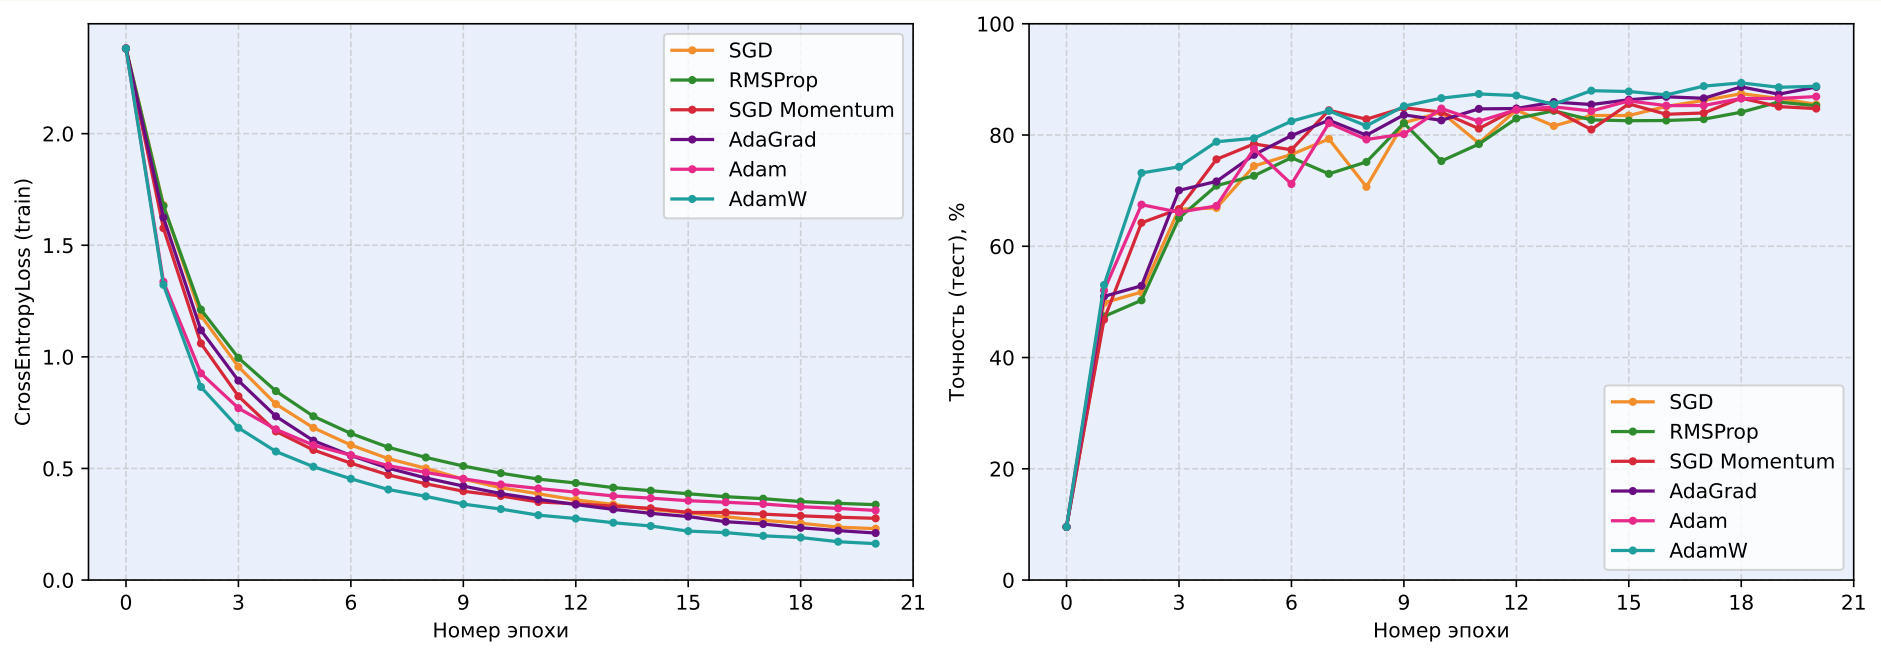
Input: $D > 0$, моментумы $\{\beta_1^k\} \in (0,1)$ и $\{\beta_2^k\} \in (0,1)$, стартовая точка $w^0 \in \mathbb{R}^d$, параметр регуляризации $\lambda > 0$, сглаженная сумма квадратов градиентов $G_i^0 = 0$, сглаженная сумма градиентов $v^0 = 0$, добавка $e > 0$, количество итераций K

1: **for** $k = 0, 1, \ldots, K-1$ **do**
2: Вычислить $g^k \in \partial f(w^k)$
3: Вычислить $v^k = \beta_1^k v^k + (1 - \beta_1^k) g^k$
4: Для каждой координаты: $G_i^k = \beta_2^k G_i^k + (1 - \beta_2^k)(g_i^k)^2$
5: Для каждой координаты: $w_i^{k+1} = w_i^k - \frac{D}{\sqrt{G_i^k + e}} v_i^{k+1} - \lambda D w_i^k$
6: **end for**

Output: $\frac{1}{K} \sum_{k=0}^{K-1} w^k$

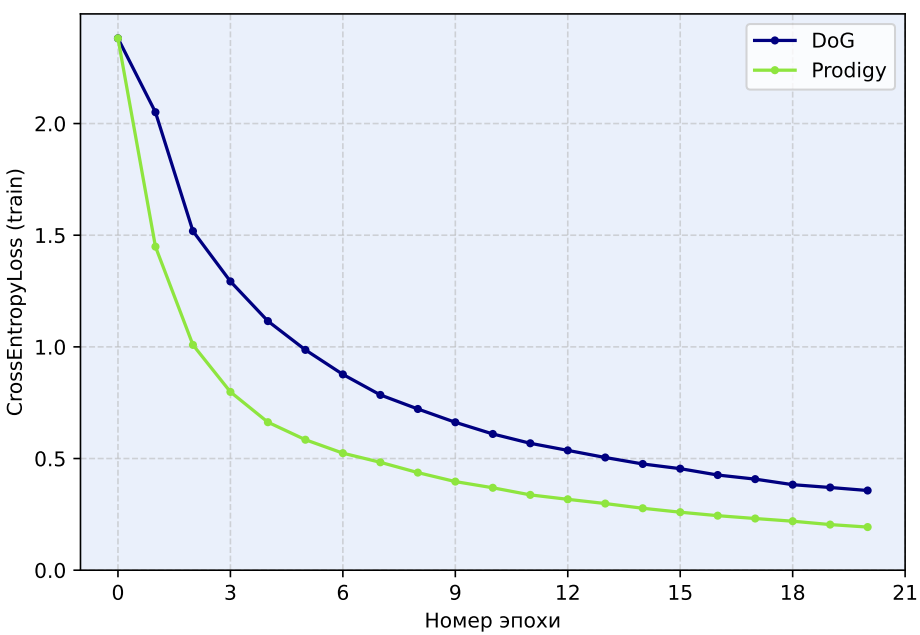
Адаптивные методы: сравнение на практике

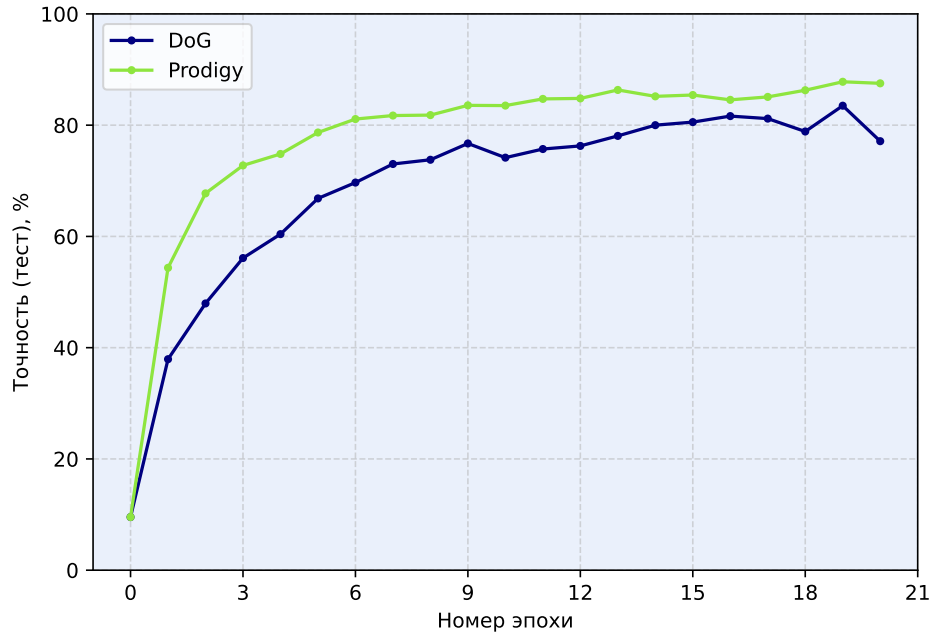
- Для наглядности мы поставили эксперименты для задачи классификации на датасете CIFAR10 на модели ResNet18 (популярная модель глубокого обучения).



Parameter-free методы: сравнение на практике

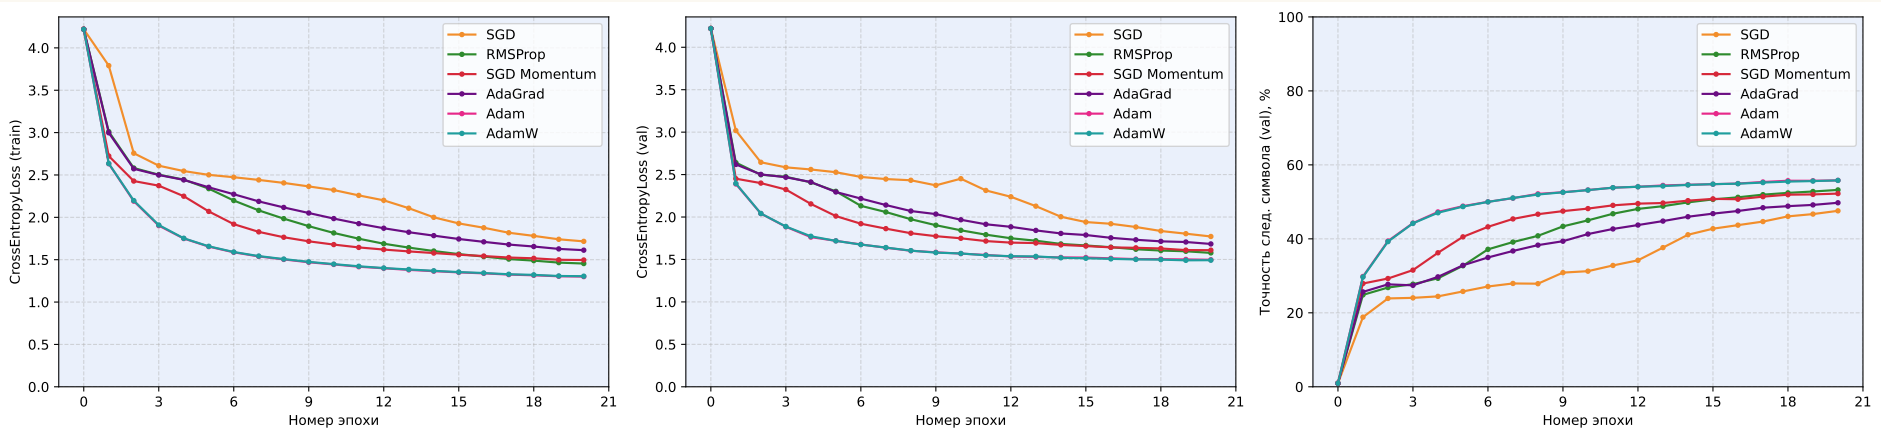
- Аналогично сравним результаты работы DoG, рассмотренного ранее с одним из топовых беспараметрических методов – Prodigy.





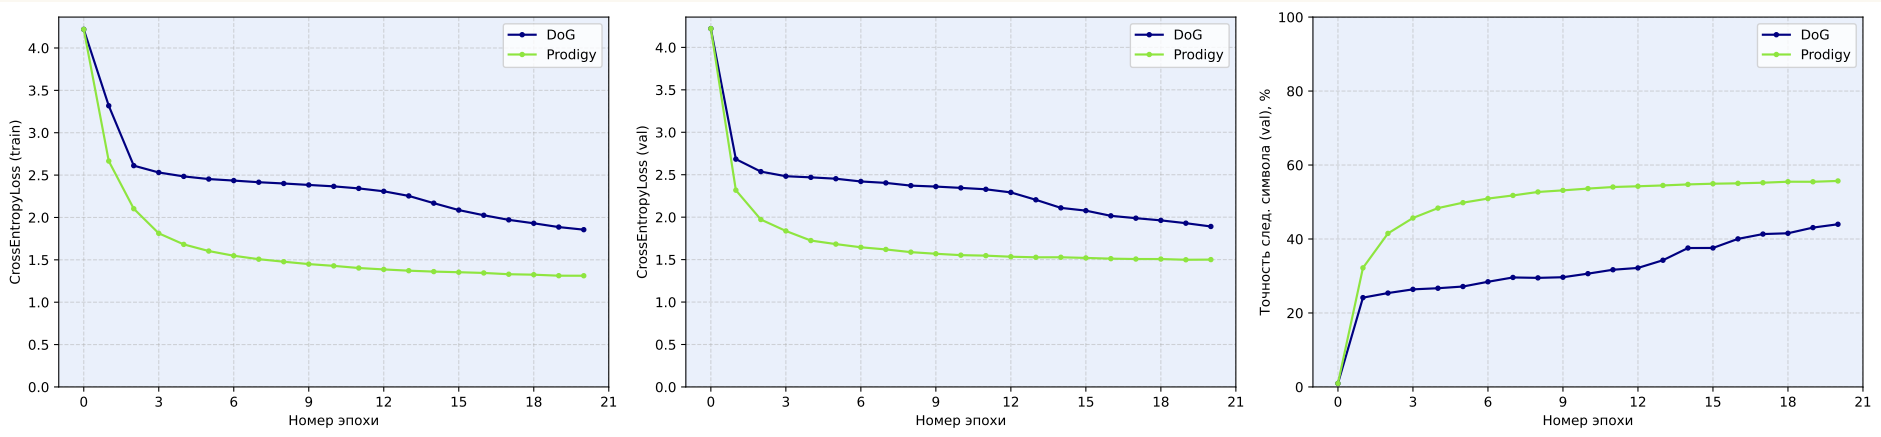
Адаптивные методы: сравнение на текстовой задаче

- Сравним также работу методов на датасете Tiny Sheakspeare с задачей предсказания следующего токена при помощи небольшого трансформера.



Parameter-free методы: сравнение на текстовой задаче

- Также сравним работу DoG и Prodigy на задаче предсказания следующего токена.



Адаптивные методы: итог

- Суть – подбирать шаг, исходя из локальных свойств задачи, что кажется более эффективным и удобным подходом.
- Adam и его модификации являются самым популярным методами решения задач оптимизации, лежащих в основе обучения нейронных сетей. Но в нем подбор параметров все еще нужен.
- Эта проблема сейчас пытается быть решена в так называемых parameter-free методах.