Логистическая регрессия

Машинное обучение

Наиль Баширов

Московский физико-технический институт

12 октября 2026



Напоминание: линейная модель и предсказание

Ранее мы уже использовали линейную модель

$$g(x, w) = w_0 + \langle w, x \rangle.$$

Её вещественный, или сырой, прогноз равен

$$\widehat{y}(x, w) = g(x, w)$$

и может принимать любое вещественное значение.
Вопрос: как получить из него метку бинарного класса?

Напоминание: линейная модель и предсказание

Ранее мы уже использовали линейную модель

$$g(x, w) = w_0 + \langle w, x \rangle.$$

Её вещественный, или сырой, прогноз равен

$$\widehat{y}(x, w) = g(x, w)$$

и может принимать любое вещественное значение.
Вопрос: как получить из него метку бинарного класса?

$$\widehat{c}(x, w) = \begin{cases} +1, & g(x, w) \geq 0, \\ -1, & g(x, w) < 0. \end{cases}$$

Граница между классами задаётся уравнением $g(x, w) = 0$.
Далее включим сдвиг в вектор признаков и будем писать $g(x, w) = \langle w, x \rangle$.

Напоминание: как измерять качество?

Для выборки $\{(x^i, y^i)\}_{i=1}^n$, где $y^i \in \{-1, +1\}$, определим предсказанные классы $\widehat{c}^i = \widehat{c}(x^i, w)$.

Вопрос: какие две естественные метрики получаем?

Напоминание: как измерять качество?

Для выборки $\{(x^i, y^i)\}_{i=1}^n$, где $y^i \in \{-1, +1\}$, определим предсказанные классы $\widehat{c}^i = \widehat{c}(x^i, w)$.

Вопрос: какие две естественные метрики получаем?

$$\text{acc}(w) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}[\widehat{c}^i = y^i],$$

$$\text{err_rate}(w) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}[\widehat{c}^i \neq y^i] = 1 - \text{acc}(w).$$

Обучение можно было бы записать как $\text{err_rate}(w) \to \min_w$.

Осталось понять, подходит ли такая задача для численной оптимизации.

Почему err_rate неудобна для обучения?

Вопрос: что увидит градиентный метод при оптимизации err_rate(w)?

Почему err_rate неудобна для обучения?

Вопрос: что увидит градиентный метод при оптимизации err_rate(w)?

- Пока предсказанные классы не меняются, значение метрики постоянно.
- При пересечении границы класса значение меняется скачком.
- Поэтому градиент почти везде равен нулю, а на границе не существует.

Почему err_rate неудобна для обучения?

Вопрос: что увидит градиентный метод при оптимизации err_rate(w)?

- Пока предсказанные классы не меняются, значение метрики постоянно.
- При пересечении границы класса значение меняется скачком.
- Поэтому градиент почти везде равен нулю, а на границе не существует.

Что теряет индикатор ошибки?

Он показывает только правильность ответа, но не учитывает запас до границы классов.

Значит, для обучения нужен более информативный критерий.

Напоминание: отступ объекта

Для линейного классификатора уже был введён отступ

$$M_i = y^i g(x^i, w).$$

Вопрос: что означают знак и величина M_i?

Напоминание: отступ объекта

Для линейного классификатора уже был введён отступ

$$M_i = y^i g(x^i, w).$$

Вопрос: что означают знак и величина M_i?

- $M_i > 0$ — предсказание верно;
- $M_i < 0$ — модель ошиблась;
- $|M_i|$ показывает запас относительно границы.

При этом отступ ещё не является вероятностью: масштаб весов меняет M_i, но не меняет предсказанный класс.
Зато теперь потерю можно определить как функцию одного числа M_i.

Заменяем индикатор ошибки

При $M_i < 0$ модель ошибается. Поэтому err_rate(w) оценивается сверху:

$$\text{err_rate}(w) \leq \frac{1}{n} \sum_{i=1}^{n} \mathbb{I}[M_i \leq 0].$$

Вопрос: чем заменить индикатор, чтобы появилась производная?

Заменяем индикатор ошибки

При $M_i < 0$ модель ошибается. Поэтому $\text{err_rate}(w)$ оценивается сверху:

$$\text{err_rate}(w) \leq \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}[M_i \leq 0].$$

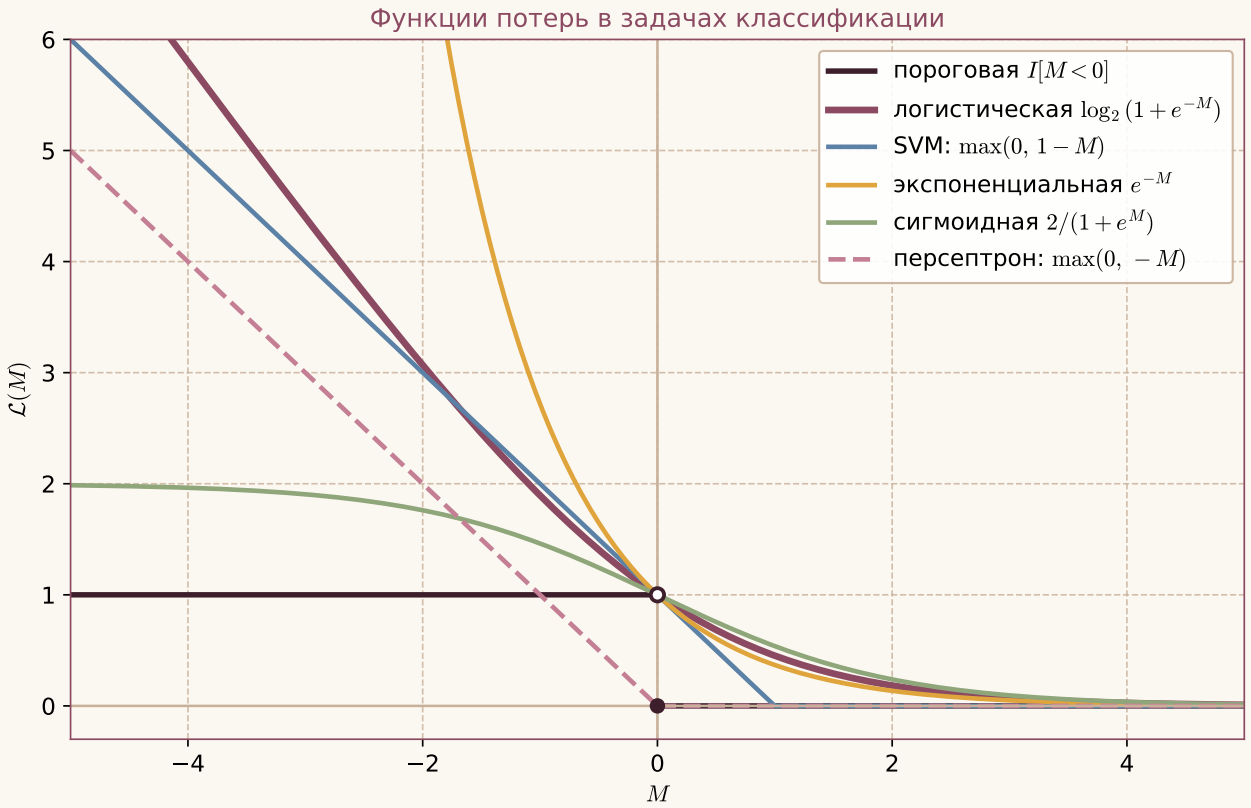
Вопрос: чем заменить индикатор, чтобы появилась производная?
Заменим индикатор гладкой суррогатной потерей $\ell(M)$, например

$$\ell_{\log}(M) = \log\left(1 + e^{-M}\right), \qquad \ell_{\exp}(M) = e^{-M}.$$

Суррогат не обязан оценивать индикатор сверху: он должен гладко штрафовать малые отступы. Средняя суррогатная потеря на выборке равна

$$\mathcal{L}(w) = \frac{1}{n}\sum_{i=1}^{n} \ell(M_i).$$

Примеры функций потерь



Логистическая потеря

Выберем потерю одного объекта

$$\ell_{\log}(M) = \log\left(1 + e^{-M}\right).$$

Получаем задачу обучения

$$\boxed{\mathcal{L}_{\log}(w) = \frac{1}{n}\sum_{i=1}^{n} \log\left(1 + e^{-y^i g(x^i, w)}\right) \longrightarrow \min_w.}$$

Вопрос: это только удобная гладкая замена err_rate?

Логистическая потеря

Выберем потерю одного объекта

$$\ell_{\log}(M) = \log\left(1 + e^{-M}\right).$$

Получаем задачу обучения

$$\boxed{\mathcal{L}_{\log}(w) = \frac{1}{n}\sum_{i=1}^{n} \log\left(1 + e^{-y^i g(x^i, w)}\right) \longrightarrow \min_w.}$$

Вопрос: это только удобная гладкая замена err_rate?
Нет. Та же потеря возникает из вероятностной модели ответа.
Сначала мы получили её как удобный критерий оптимизации. Теперь получим её ещё раз из статистики.

Зачем классификатору вероятность?

Прогнозы модели $\widehat{y}(x_1, w) = g(x_1, w) = 0.02$ и $\widehat{y}(x_2, w) = g(x_2, w) = 8$ дают один класс: $\widehat{c}(x_1, w) = \widehat{c}(x_2, w) = +1$.

Вопрос: одинаково ли модель уверена в этих ответах?

Зачем классификатору вероятность?

Прогнозы модели $\widehat{y}(x_1, w) = g(x_1, w) = 0.02$ и $\widehat{y}(x_2, w) = g(x_2, w) = 8$ дают один класс: $\widehat{c}(x_1, w) = \widehat{c}(x_2, w) = +1$.

Вопрос: одинаково ли модель уверена в этих ответах?

Будем обозначать через $p_w(x)$ численную оценку, которая дополняет предсказанную метку:

$$p_w(x) \in [0, 1],$$

и должна оценивать вероятность положительного класса:

$$p_w(x) \approx \mathbb{P}(Y = +1 \mid X = x).$$

Это вероятностная оценка, дополняющая предсказанную метку класса.

Уверенность в выбранной метке равна $\max\{p_w(x), 1 - p_w(x)\}$.

Но сначала нужно понять, какая функция потерь действительно заставляет модель оценивать вероятность.

Напоминание: схема Бернулли

Для отступов были удобны метки $\{-1, +1\}$. Для вероятностного вывода используем знакомую кодировку Бернулли:

$$Y \in \{0, 1\}, \qquad \begin{aligned} 1 &\leftrightarrow \text{положительный класс}, \\ 0 &\leftrightarrow \text{отрицательный класс}. \end{aligned}$$

Это те же два класса, меняются только их числовые обозначения. В этом разделе и предсказанная метка кодируется как $\widehat{c} \in \{0, 1\}$. Если $Y \sim \text{Bernoulli}(p)$, то

$$\mathbb{P}(Y = y) = p^y (1 - p)^{1-y}, \qquad y \in \{0, 1\}.$$

Вопрос: что означает параметр p?

Напоминание: схема Бернулли

Для отступов были удобны метки $\{-1, +1\}$. Для вероятностного вывода используем знакомую кодировку Бернулли:

$$Y \in \{0, 1\}, \qquad \begin{aligned} 1 &\leftrightarrow \text{положительный класс}, \\ 0 &\leftrightarrow \text{отрицательный класс}. \end{aligned}$$

Это те же два класса, меняются только их числовые обозначения. В этом разделе и предсказанная метка кодируется как $\widehat{c} \in \{0, 1\}$.
Если $Y \sim \text{Bernoulli}(p)$, то

$$\mathbb{P}(Y = y) = p^y (1 - p)^{1-y}, \qquad y \in \{0, 1\}.$$

Вопрос: что означает параметр p?
$p = \mathbb{P}(Y = 1)$ — вероятность положительного класса.

Квадратичная потеря оценивает вероятность

Зафиксируем x, обозначим $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$ и рассмотрим вероятностный прогноз $q \in [0, 1]$. Для квадратичной потери условный риск равен

$$\begin{aligned} R_{\mathrm{MSE},x}(q) &= \mathbb{E}[(Y - q)^2 \mid X = x] \\ &= \eta(x)(1 - q)^2 + (1 - \eta(x))q^2 \\ &= (q - \eta(x))^2 + \eta(x)(1 - \eta(x)). \end{aligned}$$

Вопрос: какое значение оптимально при фиксированном x?

Квадратичная потеря оценивает вероятность

Зафиксируем x, обозначим $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$ и рассмотрим вероятностный прогноз $q \in [0, 1]$. Для квадратичной потери условный риск равен

$$\begin{aligned} R_{\mathrm{MSE},x}(q) &= \mathbb{E}[(Y - q)^2 \mid X = x] \\ &= \eta(x)(1 - q)^2 + (1 - \eta(x))q^2 \\ &= (q - \eta(x))^2 + \eta(x)(1 - \eta(x)). \end{aligned}$$

Вопрос: какое значение оптимально при фиксированном x?

$$\operatorname*{argmin}_{q \in [0,1]} R_{\mathrm{MSE},x}(q) = \eta(x) = \mathbb{P}(Y = 1 \mid X = x).$$

Второе слагаемое от q не зависит, а квадрат единственным образом минимизируется при $q = \eta(x)$. Значит, MSE побуждает модель выдавать условную вероятность.

Абсолютная потеря не оценивает вероятность

Для абсолютной потери и $q \in [0, 1]$ условный риск равен

$$\begin{aligned} R_{\mathrm{MAE},x}(q) &= \mathbb{E}[|Y - q| \mid X = x] \\ &= \eta(x)|1 - q| + (1 - \eta(x))|q| \\ &= \eta(x) + (1 - 2\eta(x))q. \end{aligned}$$

Это линейная функция q, поэтому

$$\operatorname*{argmin}_{q \in [0,1]} R_{\mathrm{MAE},x}(q) = \begin{cases} \{0\}, & \eta(x) < 1/2, \\ [0, 1], & \eta(x) = 1/2, \\ \{1\}, & \eta(x) > 1/2. \end{cases}$$

Вопрос: что получится при $\eta(x) = 0.7$?

Абсолютная потеря не оценивает вероятность

Для абсолютной потери и $q \in [0, 1]$ условный риск равен

$$\begin{aligned} R_{\text{MAE},x}(q) &= \mathbb{E}[|Y - q| \mid X = x] \\ &= \eta(x)|1 - q| + (1 - \eta(x))|q| \\ &= \eta(x) + (1 - 2\eta(x))q. \end{aligned}$$

Это линейная функция q, поэтому

$$\operatorname*{argmin}_{q \in [0,1]} R_{\text{MAE},x}(q) = \begin{cases} \{0\}, & \eta(x) < 1/2, \\ [0, 1], & \eta(x) = 1/2, \\ \{1\}, & \eta(x) > 1/2. \end{cases}$$

Вопрос: что получится при $\eta(x) = 0.7$?
Коэффициент при q равен -0.4, поэтому минимум достигается при $q = 1$, а не при $q = 0.7$. MAE выбирает наиболее вероятный класс, но не восстанавливает саму вероятность.

Определяем вероятностную модель

Сначала вычислим линейную оценку

$$\widehat{y}(x, w) = g(x, w) = \langle w, x \rangle.$$

Затем определим модельную вероятность положительного класса:

Определение

$$p_w(x) := \mathbb{P}_w(Y = 1 \mid X = x) = \sigma(g(x, w)), \qquad \sigma(t) = \frac{1}{1 + e^{-t}}.$$

Вопрос: как теперь получить предсказанную метку?

Определяем вероятностную модель

Сначала вычислим линейную оценку

$$\widehat{y}(x, w) = g(x, w) = \langle w, x \rangle.$$

Затем определим модельную вероятность положительного класса:

Определение

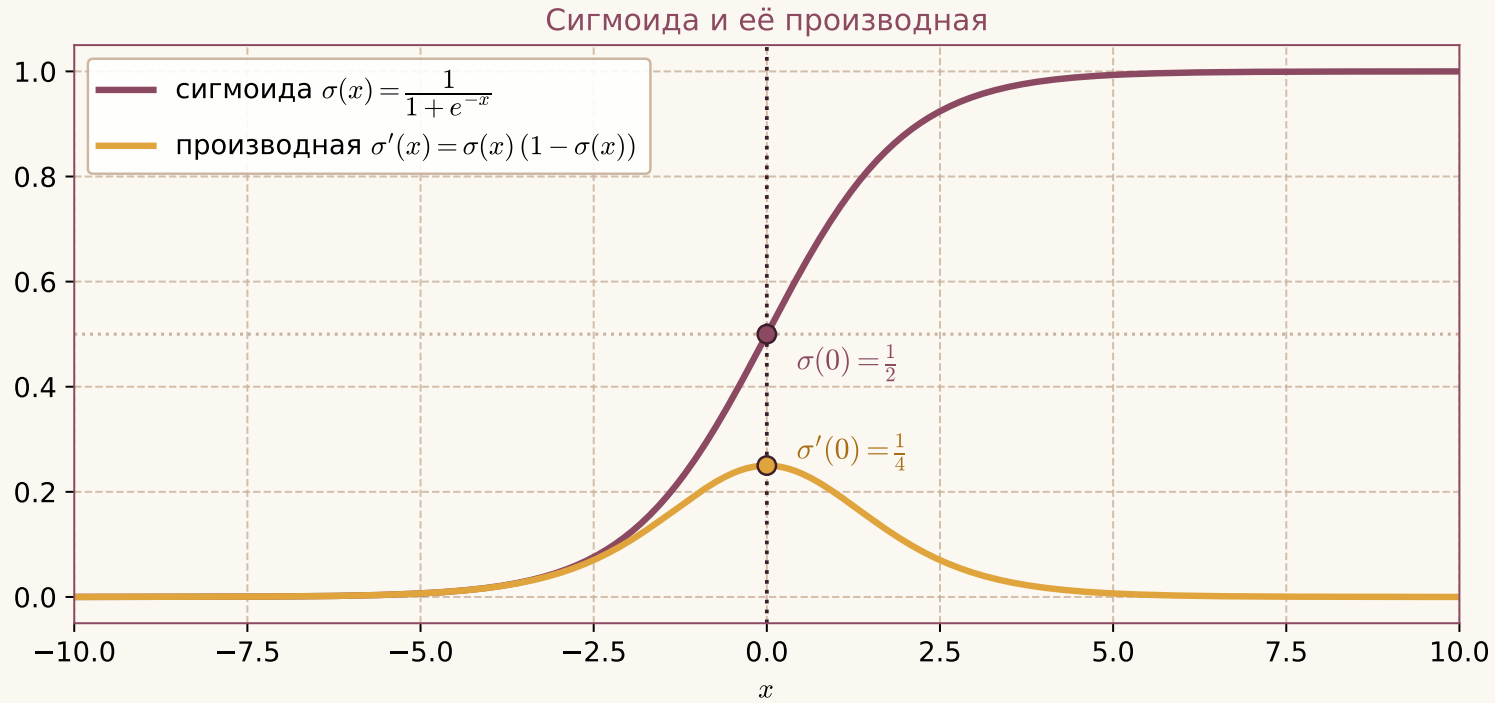
$$p_w(x) := \mathbb{P}_w(Y = 1 \mid X = x) = \sigma(g(x, w)), \qquad \sigma(t) = \frac{1}{1 + e^{-t}}.$$

Вопрос: как теперь получить предсказанную метку?

$$\widehat{c}(x, w) = \mathbb{I}[p_w(x) \geq 1/2].$$

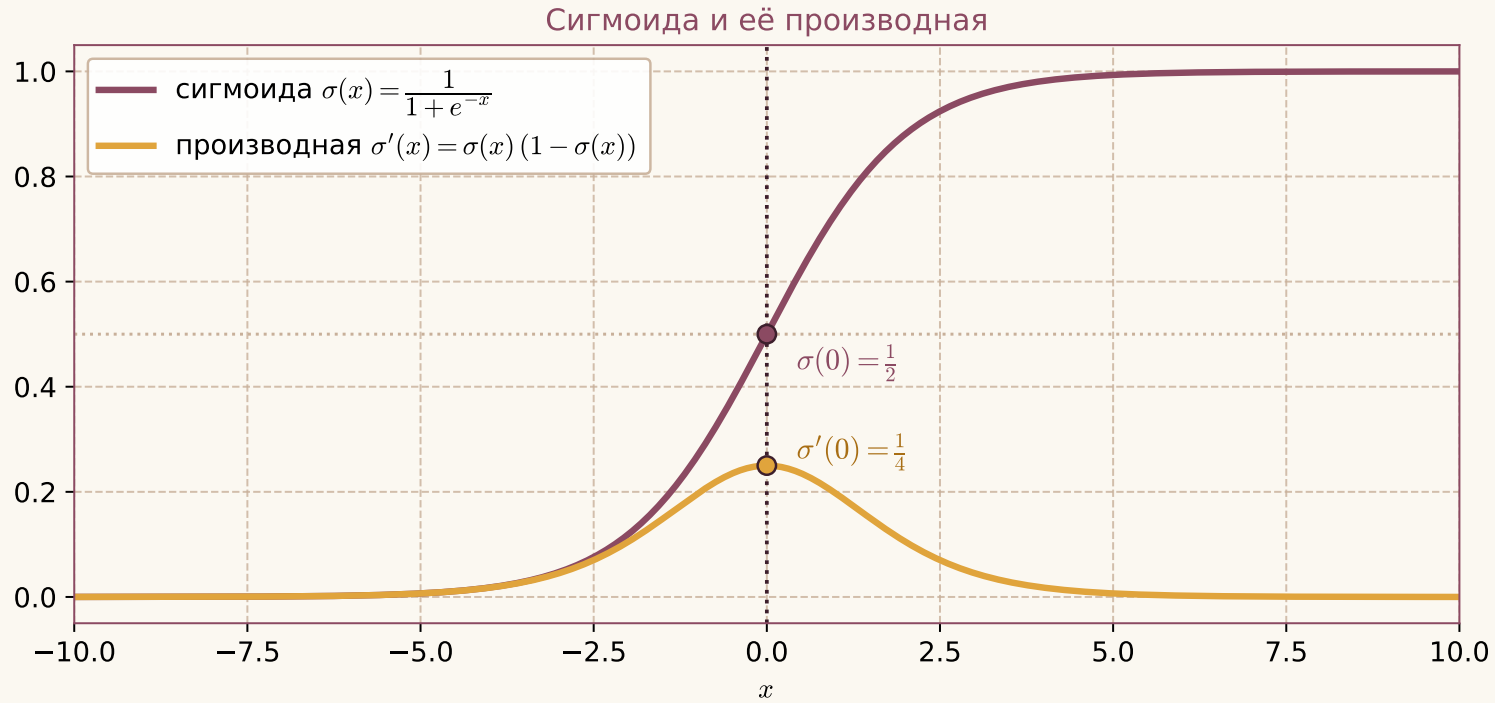
Порог $1/2$ соответствует условию $g(x, w) \geq 0$.

Сигмоида и уверенность модели



Вопрос: чем отличаются прогнозы $p_w(x) = 0.51$ и $p_w(x) = 0.99$?

Сигмоида и уверенность модели

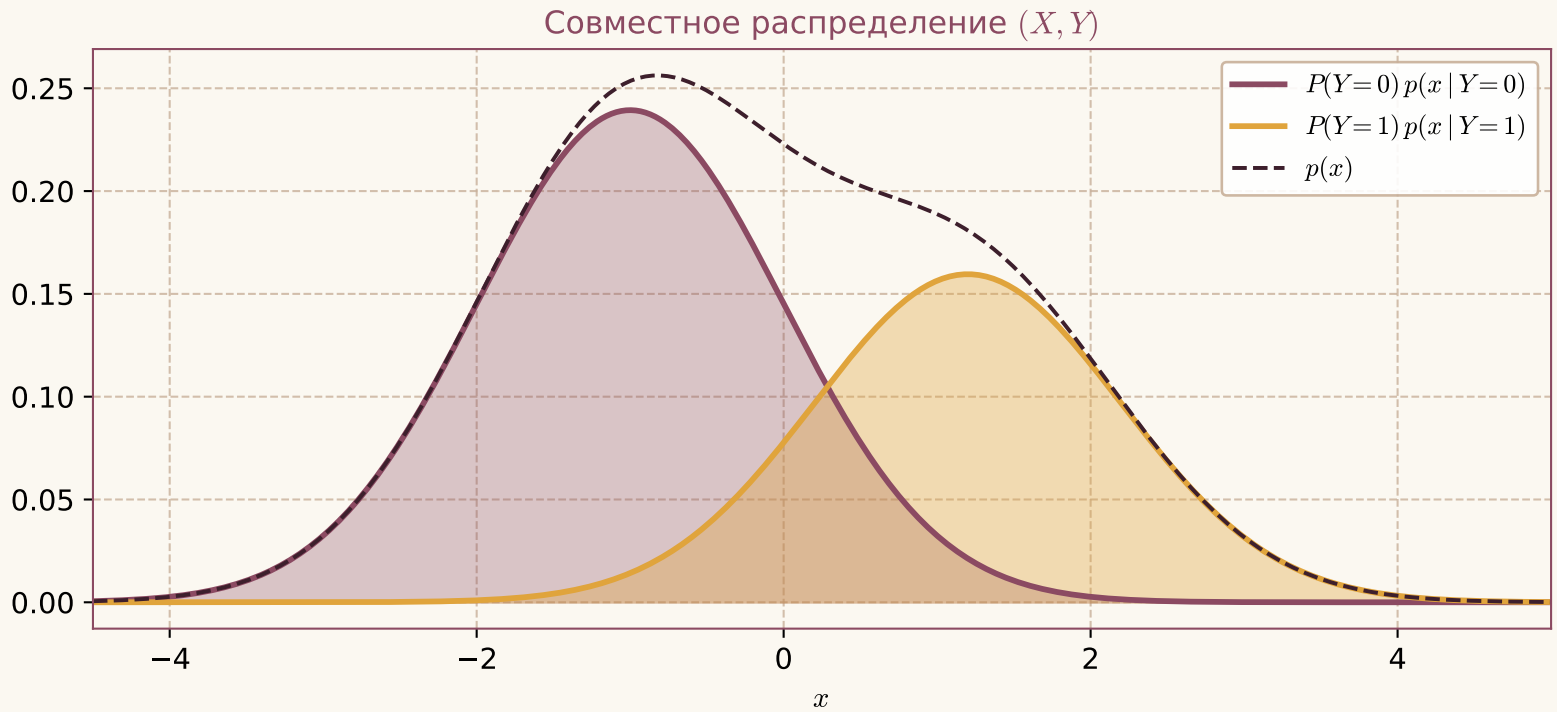


Вопрос: чем отличаются прогнозы $p_w(x) = 0.51$ и $p_w(x) = 0.99$?

Предсказанный класс одинаков, но уверенность в нём различна. Для положительного ответа она равна $p_w(x)$, для отрицательного — $1 - p_w(x)$.

Таким образом, $p_w(x)$ дополняет дискретное предсказание $\widehat{c}$.

Совместное распределение



Правдоподобие модели Бернулли

Для каждого объекта

$$Y^i \mid X^i = x^i \sim \text{Bernoulli}(p_w(x^i)).$$

Поэтому вероятность наблюдаемой метки $y^i \in \{0, 1\}$ равна

$$\mathbb{P}_w(Y^i = y^i \mid X^i = x^i) = p_w(x^i)^{y^i} \big(1 - p_w(x^i)\big)^{1-y^i}.$$

Вопрос: как выглядит правдоподобие независимых ответов?

Правдоподобие модели Бернулли

Для каждого объекта

$$Y^i \mid X^i = x^i \sim \text{Bernoulli}(p_w(x^i)).$$

Поэтому вероятность наблюдаемой метки $y^i \in \{0, 1\}$ равна

$$\mathbb{P}_w(Y^i = y^i \mid X^i = x^i) = p_w(x^i)^{y^i} \big(1 - p_w(x^i)\big)^{1-y^i}.$$

Вопрос: как выглядит правдоподобие независимых ответов?

$$L(w) = \prod_{i=1}^{n} p_w(x^i)^{y^i} \big(1 - p_w(x^i)\big)^{1-y^i}.$$

Веса выбираются так, чтобы наблюдаемые ответы имели как можно большую вероятность.

От правдоподобия к логарифмической потере

Отрицательный логарифм вероятности одного ответа задаёт ту же логарифмическую потерю, теперь записанную через вероятность:

$$\ell_{\log}(p_w(x^i), y^i) = -y^i \log p_w(x^i) - (1 - y^i) \log\bigl(1 - p_w(x^i)\bigr).$$

Средняя потеря выборки равна

$$\mathcal{L}_{\log}(w) = \frac{1}{n} \sum_{i=1}^{n} \ell_{\log}(p_w(x^i), y^i).$$

Вопрос: что получится после подстановки $p_w(x) = \sigma(g(x, w))$?

От правдоподобия к логарифмической потере

Отрицательный логарифм вероятности одного ответа задаёт ту же логарифмическую потерю, теперь записанную через вероятность:

$$\ell_{\log}(p_w(x^i), y^i) = -y^i \log p_w(x^i) - (1 - y^i) \log\bigl(1 - p_w(x^i)\bigr).$$

Средняя потеря выборки равна

$$\mathcal{L}_{\log}(w) = \frac{1}{n} \sum_{i=1}^{n} \ell_{\log}(p_w(x^i), y^i).$$

Вопрос: что получится после подстановки $p_w(x) = \sigma(g(x, w))$?

$$\ell_{\log}(p_w(x^i), y^i) = \log\Bigl(1 + e^{g(x^i, w)}\Bigr) - y^i g(x^i, w).$$

Два вывода приводят к одной потере

Для меток $y^i \in \{0, 1\}$ верно

$$\log(1 + e^{g_i}) - y^i g_i = \log\left(1 + e^{-(2y^i - 1)g_i}\right), \qquad g_i = g(x^i, w).$$

Величина $(2y^i - 1)g_i$ — тот же отступ, только записанный через кодировку $\{0, 1\}$.

Главная связка

Гладкая потеря, которой мы заменили индикатор ошибки, совпала с отрицательным логарифмом правдоподобия модели Бернулли.

Два вывода приводят к одной потере

Для меток $y^i \in \{0, 1\}$ верно

$$\log(1 + e^{g_i}) - y^i g_i = \log\left(1 + e^{-(2y^i - 1)g_i}\right), \qquad g_i = g(x^i, w).$$

Величина $(2y^i - 1)g_i$ — тот же отступ, только записанный через кодировку $\{0, 1\}$.

Главная связка

Гладкая потеря, которой мы заменили индикатор ошибки, совпала с отрицательным логарифмом правдоподобия модели Бернулли.

Оптимизация объясняет, почему эту функцию удобно минимизировать. Статистика объясняет, почему результат можно интерпретировать как оценку вероятности.

Почему логарифмическая потеря оценивает вероятность?

Зафиксируем объект x, обозначим $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$ и рассмотрим прогноз $q \in (0, 1)$. Его условный риск равен

$$R_x(q) = -\eta(x) \log q - (1 - \eta(x)) \log(1 - q).$$

Вопрос: при каком q он минимален?

Почему логарифмическая потеря оценивает вероятность?

Зафиксируем объект x, обозначим $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$ и рассмотрим прогноз $q \in (0, 1)$. Его условный риск равен

$$R_x(q) = -\eta(x) \log q - (1 - \eta(x)) \log(1 - q).$$

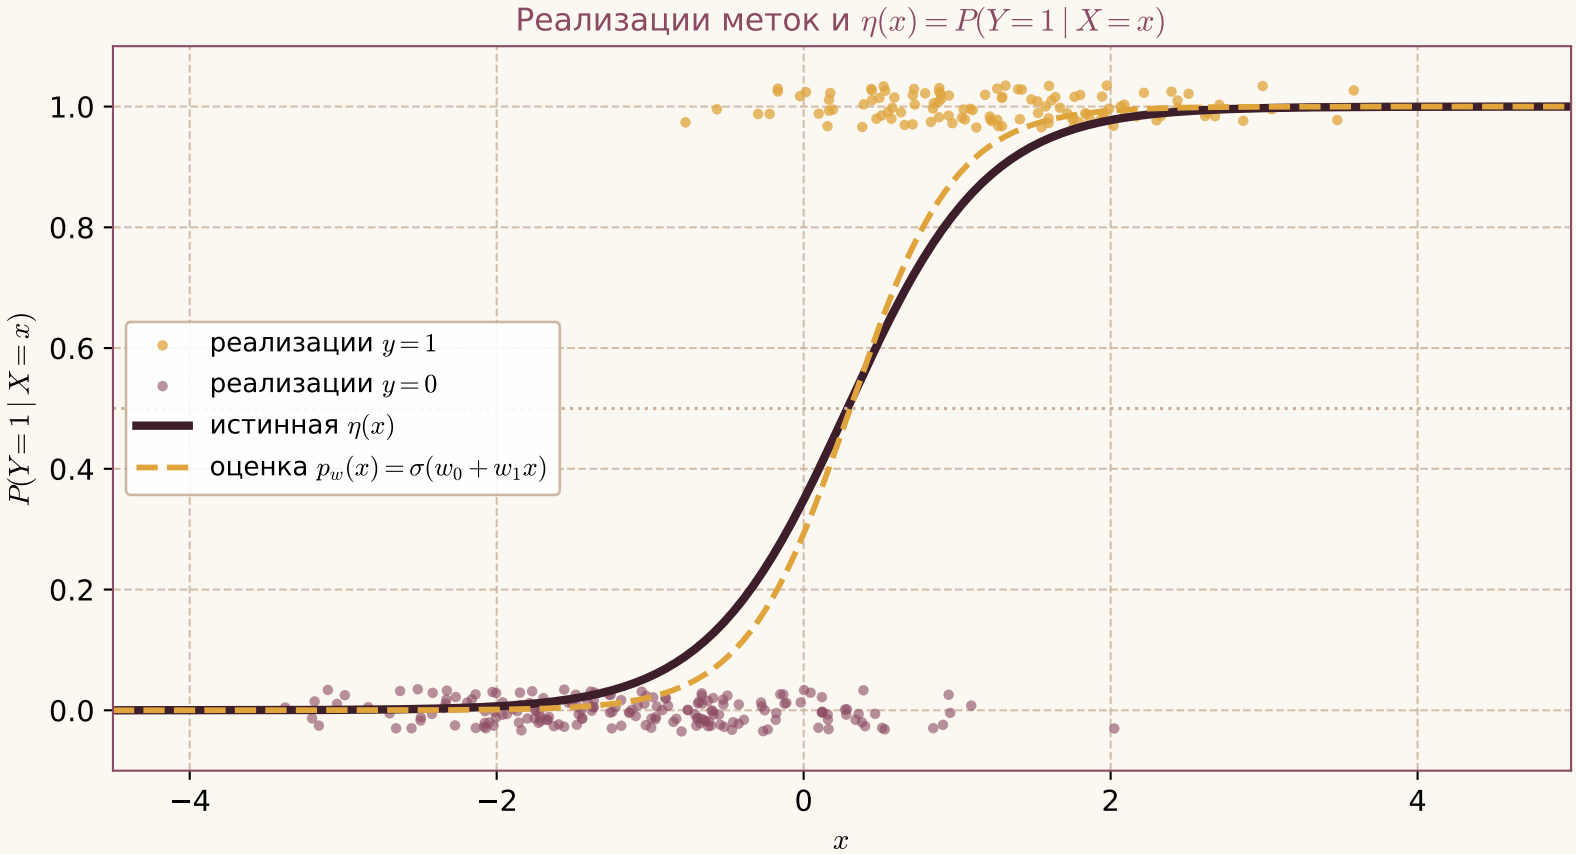
Вопрос: при каком q он минимален?

$$R'_x(q) = \frac{q - \eta(x)}{q(1 - q)}.$$

При $0 < \eta(x) < 1$ знаменатель положителен, поэтому

$$\operatorname*{argmin}_{q \in (0,1)} R_x(q) = \eta(x).$$

При $\eta(x) \in \{0, 1\}$ тот же вывод понимается как предел $q \to \eta(x)$. Логарифмическая потеря действительно обучает вероятностный прогноз.


Реализации меток и $\eta(x) = P(Y=1 \mid X=x)$
реализации $y=1$
реализации $y=0$
истинная $\eta(x)$
оценка $p_w(x) = \sigma(w_0 + w_1 x)$
$P(Y=1 \mid X=x)$
x
1.0
0.8
0.6
0.4
0.2
0.0
−4
−2
0
2
4

Вероятность — оценка, а не гарантия

Значение $p_w(x) = 0.99$ означает высокую уверенность модели, но не гарантирует правильность конкретного ответа.
Вопрос: когда число 0.99 можно считать содержательным?

Вероятность — оценка, а не гарантия

Значение $p_w(x) = 0.99$ означает высокую уверенность модели, но не гарантирует правильность конкретного ответа.

Вопрос: когда число 0.99 можно считать содержательным?

Если модель хорошо откалибрована: среди объектов с прогнозом около 0.99 положительный класс действительно встречается примерно в 99% случаев.

Вероятность позволяет

- менять порог при разной цене ошибок;
- ранжировать объекты;
- передавать неуверенные случаи на дополнительную проверку.

Качество этих оценок необходимо проверять на новых данных.

Разделимые данные: неожиданная проблема

Вернёмся к кодировке $\{-1, +1\}$ и отступам $M_i = y^i g(x^i, w)$. Пусть все объекты классифицированы верно: $M_i > 0$. Для любого $c > 1$

$$\ell_{\log}(cM_i) < \ell_{\log}(M_i).$$

Вопрос: где окажется минимум логистической потери?

Разделимые данные: неожиданная проблема

Вернёмся к кодировке $\{-1, +1\}$ и отступам $M_i = y^i g(x^i, w)$. Пусть все объекты классифицированы верно: $M_i > 0$. Для любого $c > 1$

$$\ell_{\log}(cM_i) < \ell_{\log}(M_i).$$

Вопрос: где окажется минимум логистической потери?
При масштабировании разделяющего вектора $w \mapsto cw$ его норма растёт, а $\mathcal{L}_{\log}(cw)$ уменьшается. Поэтому конечной оценки максимального правдоподобия может не существовать: веса стремятся к бесконечности, а вероятности — к 0 и 1.
Идеальная асс на обучении не означает, что задача оценивания параметров хорошо поставлена.

Регуляризация делает задачу устойчивее

Добавим к средней потере уже знакомый квадратичный штраф:

$$\mathcal{L}_\lambda(w) = \mathcal{L}_{\log}(w) + \frac{\lambda}{2}\|w\|_2^2, \qquad \lambda > 0.$$

Вопрос: что меняется после добавления штрафа?

Регуляризация делает задачу устойчивее

Добавим к средней потере уже знакомый квадратичный штраф:

$$\mathcal{L}_\lambda(w) = \mathcal{L}_{\log}(w) + \frac{\lambda}{2}\|w\|_2^2, \qquad \lambda > 0.$$

Вопрос: что меняется после добавления штрафа?

- слишком большие веса становятся невыгодными;
- на разделимых данных появляется конечное решение;
- при штрафе на все веса задача становится сильно выпуклой.

Со статистической точки зрения квадратичный штраф соответствует гауссовскому априорному распределению на веса.

Что меняется, если классов больше двух?

Теперь $y^i \in \{1, \ldots, K\}$. Вероятностная модель должна возвращать распределение

$$p_{W,1}(x), \ldots, p_{W,K}(x), \qquad p_{W,k}(x) \geq 0, \qquad \sum_{k=1}^{K} p_{W,k}(x) = 1,$$

где $W = (w_1, \ldots, w_K)$ — параметры всех классов.
Предсказанная метка определяется одинаково для любой модели:

$$\widehat{c}(x, W) \in \operatorname*{argmax}_{k=1,\ldots,K} p_{W,k}(x).$$

Вопрос: можно ли использовать уже построенный бинарный алгоритм?

Один класс против остальных

Для каждого класса k строим бинарную задачу: «класс k» против «все остальные». Модель выдаёт линейную оценку

$$g_k(x, w_k) = \langle w_k, x \rangle.$$

Вопрос: как объединить K бинарных моделей?

Один класс против остальных

Для каждого класса k строим бинарную задачу: «класс k» против «все остальные». Модель выдаёт линейную оценку

$$g_k(x, w_k) = \langle w_k, x \rangle.$$

Вопрос: как объединить K бинарных моделей?

$$\widehat{c}(x, W) \in \operatorname*{argmax}_{k=1,\ldots,K} g_k(x, w_k).$$

Метод прост, но вероятности $\sigma(g_k)$ обучаются независимо и не обязаны суммироваться в 1.
Поэтому он даёт единое предсказание класса, но не единое распределение вероятностей.

Один класс против остальных: иллюстрация

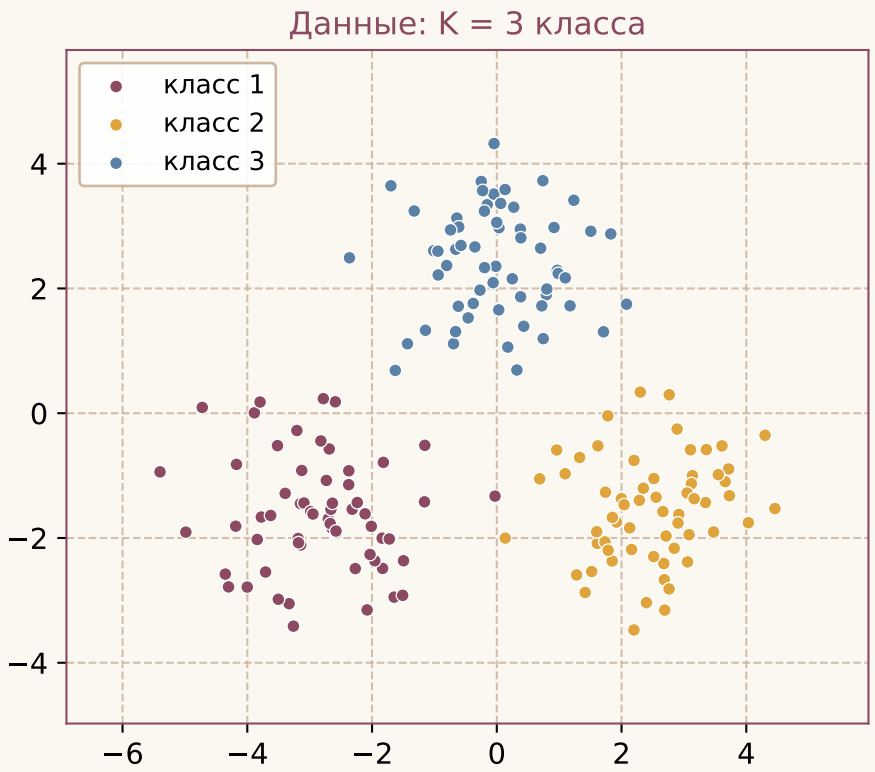


Рис. 1: Данные для классификации

Один класс против остальных: иллюстрация

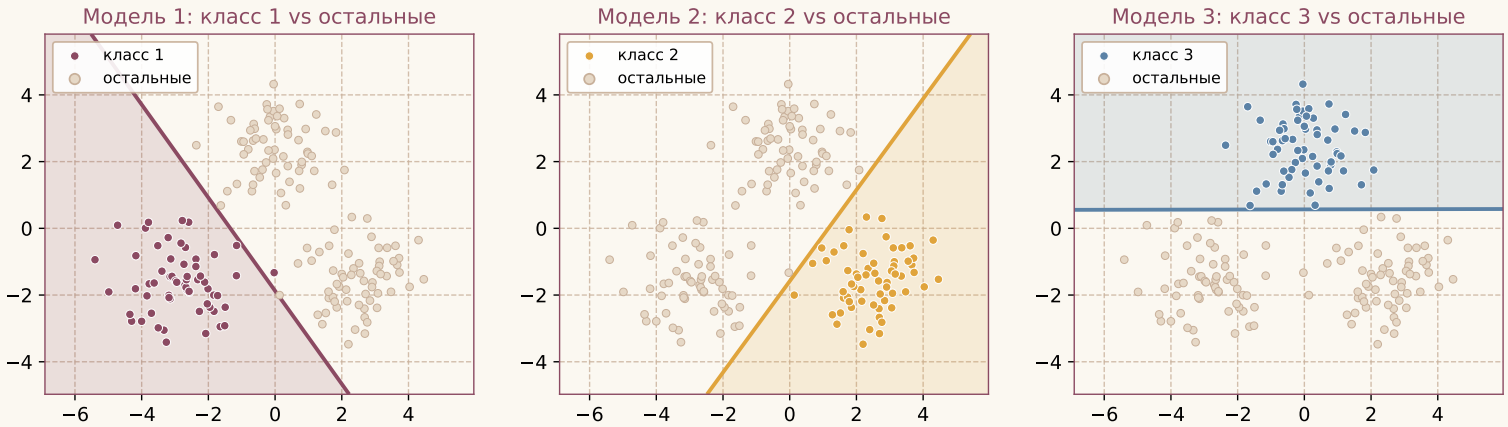


Рис. 2: Обучаем K моделей

Один класс против остальных: иллюстрация

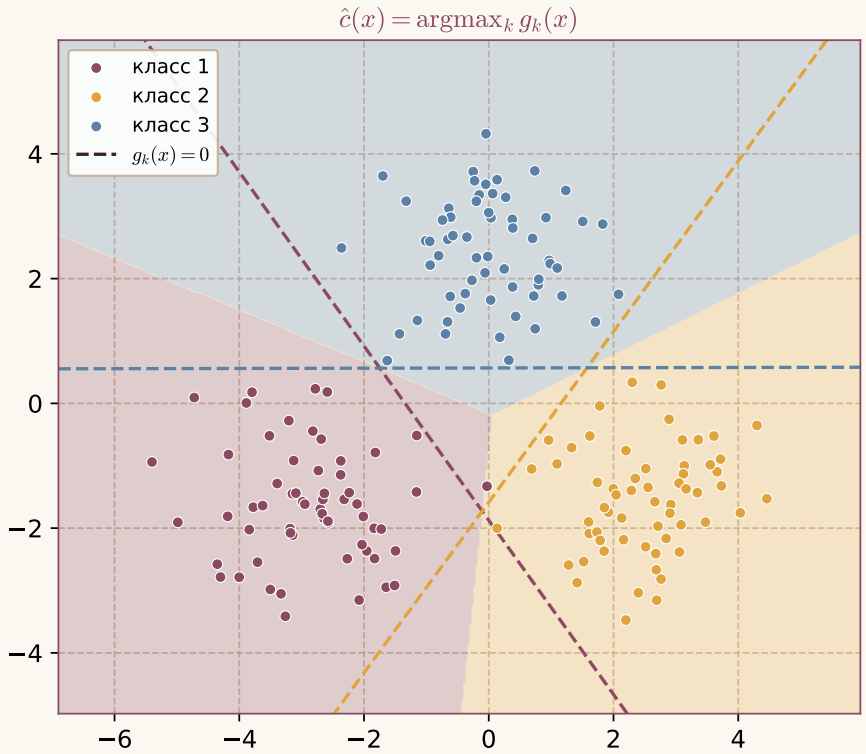


Рис. 3: Итоговая классификация

Попарная классификация

Для каждой пары классов $k < j$ обучим отдельную бинарную модель.
Для её обучения используются только объекты этих двух классов.
Вопрос: сколько потребуется моделей?

Попарная классификация

Для каждой пары классов $k < j$ обучим отдельную бинарную модель.
Для её обучения используются только объекты этих двух классов.
Вопрос: сколько потребуется моделей?

$$\binom{K}{2} = \frac{K(K-1)}{2}.$$

Каждая модель голосует за один из двух классов, а $\widehat{c}(x, W)$ определяется большинством голосов.
Этот подход также не строит непосредственно распределение вероятностей по всем классам. Для этого нужна совместная модель.

Попарная классификация: иллюстрация

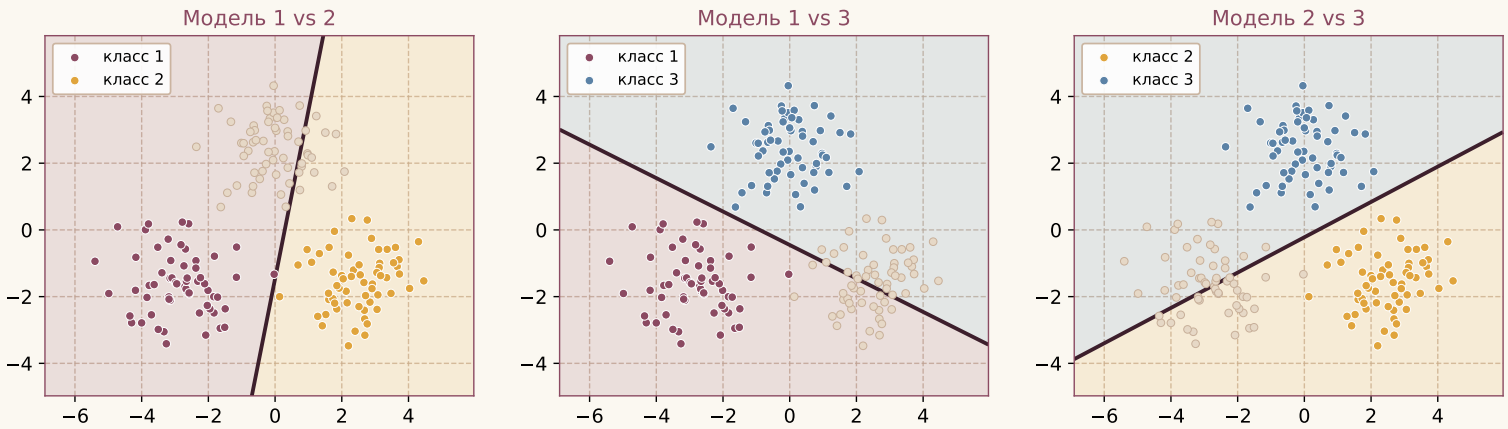


Рис. 4: $\binom{K}{2} = 3$ моделей

Попарная классификация: иллюстрация

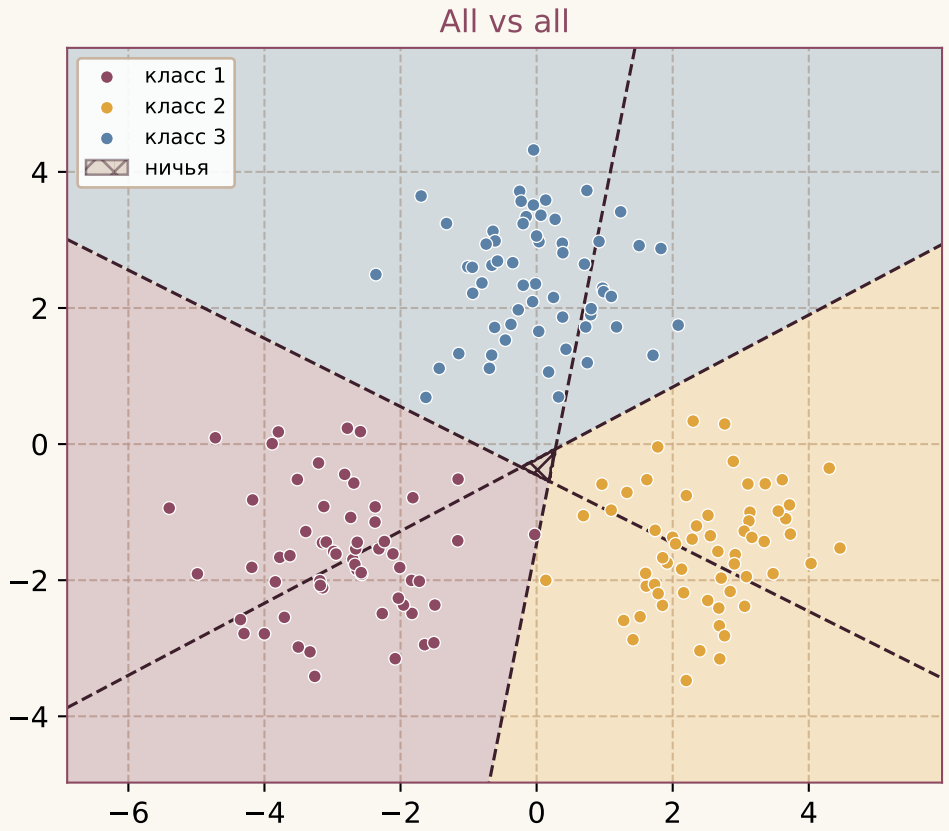


Рис. 5: Итоговая классификация

Softmax: совместная вероятностная модель

Построим линейную оценку для каждого класса:

$$g_k(x, w_k) = \langle w_k, x \rangle.$$

Затем определим вероятности

Softmax

$$p_{W,k}(x) := \mathbb{P}_W(Y = k \mid X = x) = \frac{e^{g_k(x,w_k)}}{\sum_{j=1}^{K} e^{g_j(x,w_j)}}.$$

Теперь $\sum_k p_{W,k}(x) = 1$, а предсказание равно

$$\widehat{c}(x, W) \in \operatorname*{argmax}_k p_{W,k}(x) = \operatorname*{argmax}_k g_k(x, w_k).$$

Обучение многоклассовой модели

Вероятность наблюдаемой метки y^i равна $p_{W,y^i}(x^i)$. Поэтому потеря одного объекта имеет вид

$$\ell_i(W) = -\log p_{W,y^i}(x^i) = \log \sum_{j=1}^{K} e^{g_j(x^i, w_j)} - g_{y^i}(x^i, w_{y^i}).$$

Средняя потеря выборки:

$$\mathcal{L}(W) = \frac{1}{n} \sum_{i=1}^{n} \ell_i(W).$$

Вопрос: откуда снова появилась эта функция?

Обучение многоклассовой модели

Вероятность наблюдаемой метки y^i равна $p_{W,y^i}(x^i)$. Поэтому потеря одного объекта имеет вид

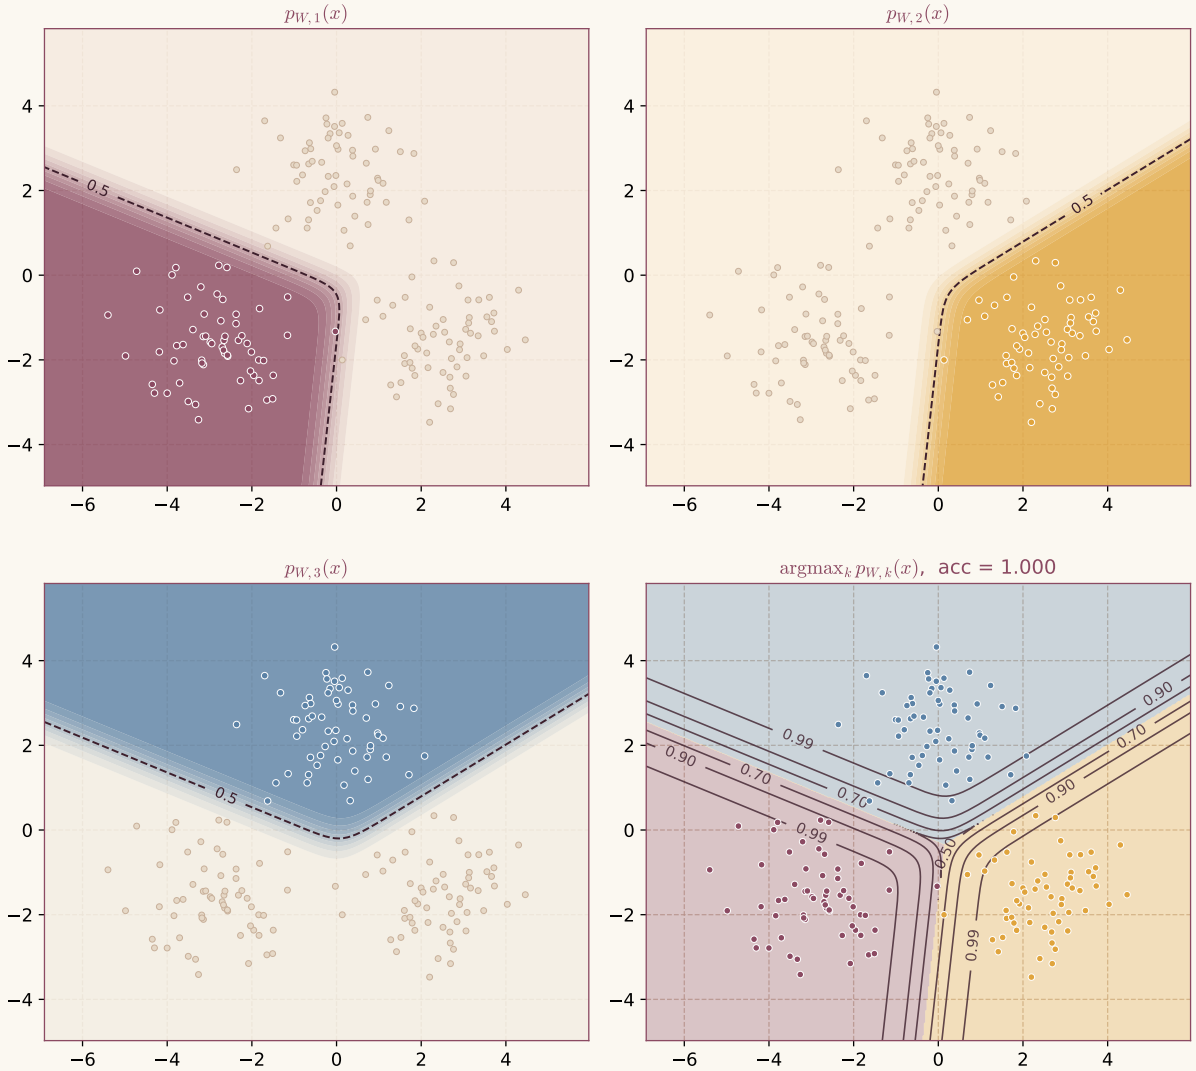
$$\ell_i(W) = -\log p_{W,y^i}(x^i) = \log \sum_{j=1}^{K} e^{g_j(x^i, w_j)} - g_{y^i}(x^i, w_{y^i}).$$

Средняя потеря выборки:

$$\mathcal{L}(W) = \frac{1}{n} \sum_{i=1}^{n} \ell_i(W).$$

Вопрос: откуда снова появилась эта функция?
Это отрицательный логарифм правдоподобия категориального распределения.
Многоклассовая модель продолжает ту же статистическую конструкцию, что и бинарная логистическая регрессия.

SoftMax: иллюстрация



Возвращаемся к бинарной задаче

Используем кодировку $y^i \in \{0, 1\}$ и обозначим $g_i = g(x^i, w)$, $p_w(x^i) = \sigma(g_i)$. Регуляризованная средняя потеря равна

$$\mathcal{L}_\lambda(w) = \frac{1}{n} \sum_{i=1}^{n} \left[\log(1 + e^{g_i}) - y^i g_i\right] + \frac{\lambda}{2} \|w\|_2^2.$$

Вопрос: как выглядит её градиент?

Возвращаемся к бинарной задаче

Используем кодировку $y^i \in \{0, 1\}$ и обозначим $g_i = g(x^i, w)$, $p_w(x^i) = \sigma(g_i)$. Регуляризованная средняя потеря равна

$$\mathcal{L}_\lambda(w) = \frac{1}{n} \sum_{i=1}^{n} \left[\log(1 + e^{g_i}) - y^i g_i\right] + \frac{\lambda}{2}\|w\|_2^2.$$

Вопрос: как выглядит её градиент?

$$\nabla \mathcal{L}_\lambda(w) = \frac{1}{n} \sum_{i=1}^{n} \big(p_w(x^i) - y^i\big) x^i + \lambda w.$$

Новых обозначений для меток не требуется.

Гессиан логистической регрессии

Поскольку $\sigma'(t) = \sigma(t)(1 - \sigma(t))$, ещё одно дифференцирование даёт

$$\nabla^2 \mathcal{L}_\lambda(w) = \frac{1}{n} \sum_{i=1}^{n} p_w(x^i)\big(1 - p_w(x^i)\big) x^i (x^i)^\top + \lambda I.$$

Вопрос: что можно сказать об этой матрице?

Гессиан логистической регрессии

Поскольку $\sigma'(t) = \sigma(t)(1 - \sigma(t))$, ещё одно дифференцирование даёт

$$\nabla^2 \mathcal{L}_\lambda(w) = \frac{1}{n} \sum_{i=1}^{n} p_w(x^i)\big(1 - p_w(x^i)\big) x^i (x^i)^\top + \lambda I.$$

Вопрос: что можно сказать об этой матрице?
Она положительно определена при $\lambda > 0$. Следовательно, регуляризованная задача сильно выпукла и имеет единственный минимум.
Гессиан описывает локальную кривизну функции потерь. Именно эту информацию использует метод Ньютона.

Метод Ньютона

В точке w^k заменим $\mathcal{L}_\lambda$ квадратичной моделью:

$$\mathcal{L}_\lambda(w^k + s) \approx \mathcal{L}_\lambda(w^k) + \nabla\mathcal{L}_\lambda(w^k)^\top s + \frac{1}{2}s^\top H_k s,$$

где $H_k = \nabla^2\mathcal{L}_\lambda(w^k)$.
Вопрос: какой шаг минимизирует эту модель?

Метод Ньютона

В точке w^k заменим $\mathcal{L}_\lambda$ квадратичной моделью:

$$\mathcal{L}_\lambda(w^k + s) \approx \mathcal{L}_\lambda(w^k) + \nabla\mathcal{L}_\lambda(w^k)^\top s + \frac{1}{2}s^\top H_k s,$$

где $H_k = \nabla^2\mathcal{L}_\lambda(w^k)$.
Вопрос: какой шаг минимизирует эту модель?

$$H_k s_k = -\nabla\mathcal{L}_\lambda(w^k), \qquad w^{k+1} = w^k + s_k.$$

Это шаг Ньютона. На практике решают линейную систему, не вычисляя обратную матрицу явно.

Почему используют демпфирование?

Вблизи минимума квадратичная модель точна, поэтому полный шаг Ньютона сходится очень быстро.

Вопрос: что делать вдали от минимума?

Почему используют демпфирование?

Вблизи минимума квадратичная модель точна, поэтому полный шаг Ньютона сходится очень быстро.

Вопрос: что делать вдали от минимума?

Использовать шаг

$$w^{k+1} = w^k + \alpha_k s_k, \qquad 0 < \alpha_k \leq 1,$$

где s_k — направление Ньютона.

Начинаем с $\alpha_k = 1$ и уменьшаем его, пока $\mathcal{L}_\lambda$ не начнёт достаточно убывать. Вблизи решения снова принимаем полный шаг.

Цена информации второго порядка

Для плотной матрицы признаков одна итерация градиентного спуска требует порядка $O(nd)$ операций. Для Ньютона необходимо построить гессиан и решить систему:

$$O(nd^2 + d^3) \quad \text{операций}, \qquad O(d^2) \quad \text{памяти}.$$

Вопрос: когда эта цена оправданна?

Цена информации второго порядка

Для плотной матрицы признаков одна итерация градиентного спуска требует порядка $O(nd)$ операций. Для Ньютона необходимо построить гессиан и решить систему:

$$O(nd^2 + d^3) \quad \text{операций}, \qquad O(d^2) \quad \text{памяти}.$$

Вопрос: когда эта цена оправданна?

- число признаков сравнительно невелико;
- гессиан можно вычислить или хорошо приблизить;
- требуется решение высокой точности.

При большой размерности обычно выгоднее методы первого порядка.