Метрические методы

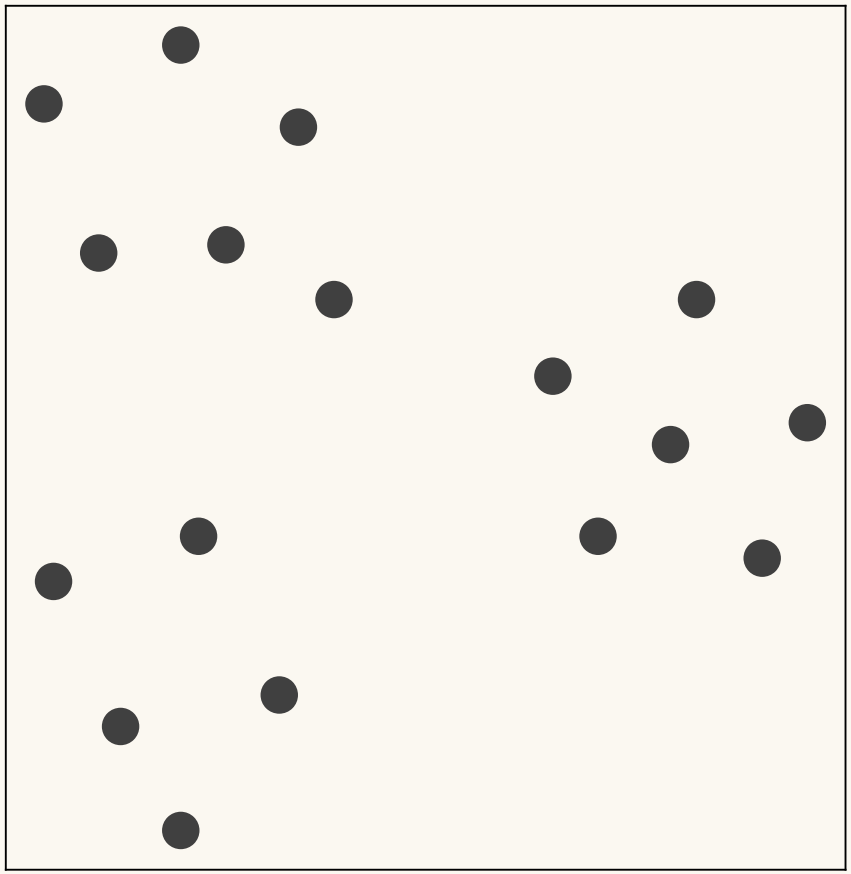
Александр Безносиков

Московский физико-технический институт

19 октября 2026

ФПМИ

Неформальная постановка



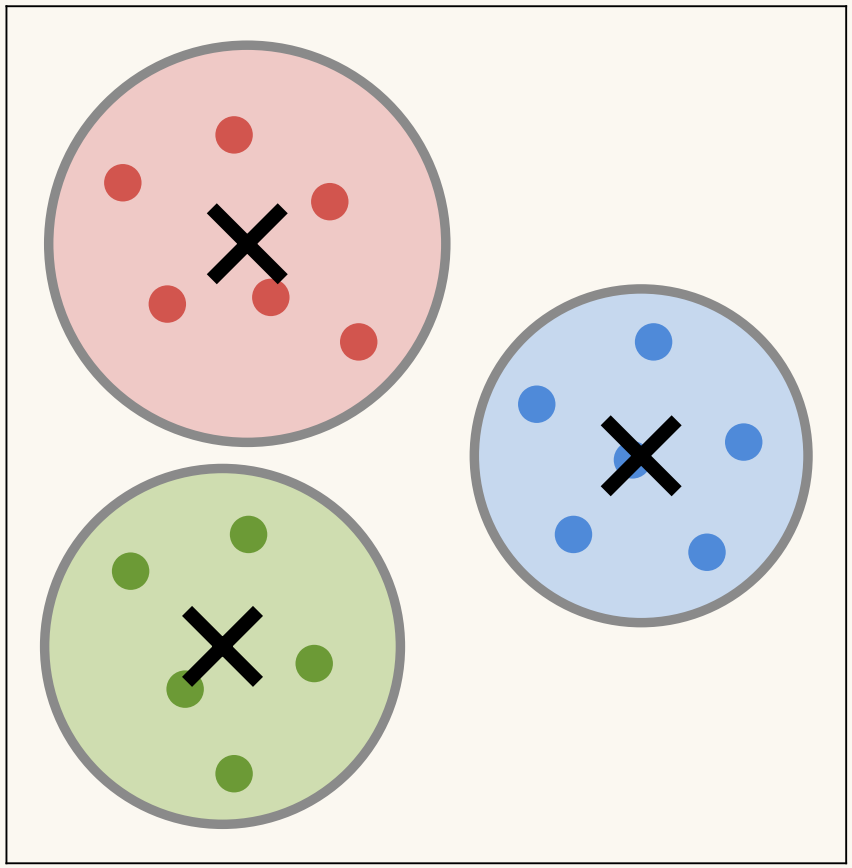


Рис. 1: Разделение неразмеченных точек на кластеры

Формальная постановка

- Вход: $S \subset \mathbb{R}^d, |S| = n$ – множество точек; $k \in \mathbb{N}$ – число кластеров.
- Выход: $T \subset \mathbb{R}^d, |T| = k$ – точки центров кластеров.
- T – решение задачи оптимизации:

$$\min_{\substack{T \subset \mathbb{R}^d \\ |T|=k}} \left\{ \text{cost}(S, T) = \sum_{x \in S} \min_{z \in T} \|x - z\|_2^2 \right\}$$

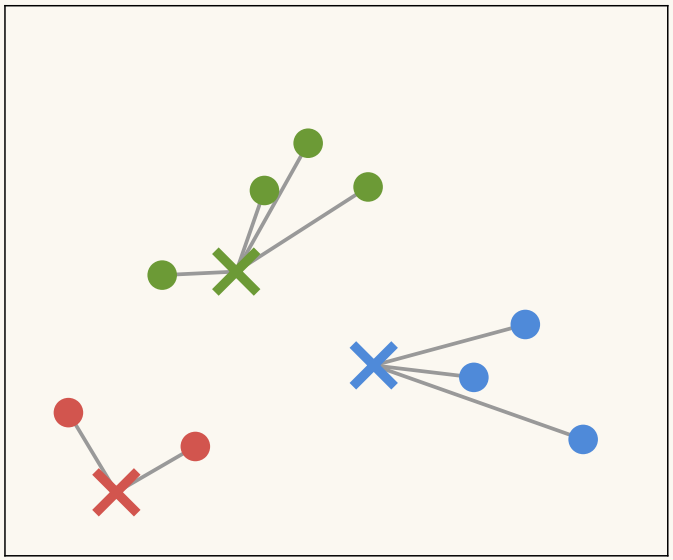
.

- В зависимости от постановки задачи евклидова метрика может быть заменена на другую.

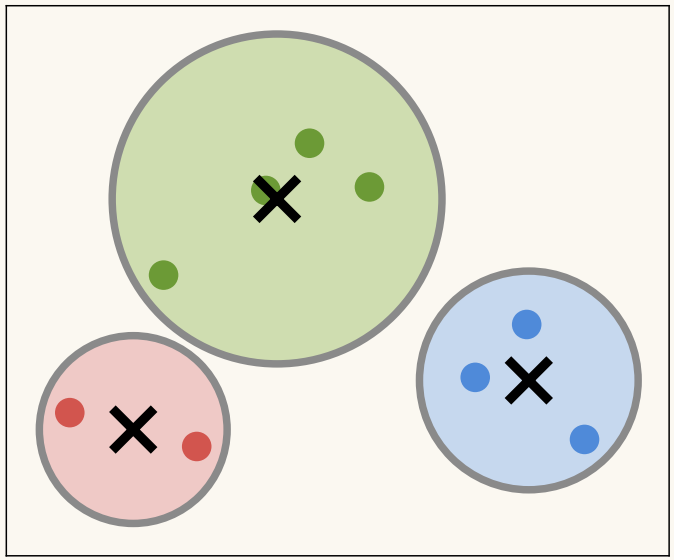
Обозначения

- $\text{cost}(S, T) = \sum\limits_{x \in S} \min\limits_{z \in T} \|x - z\|_2^2 = \sum\limits_{z \in T} \sum\limits_{x \in C_z} \|x - z\|_2^2$, где C_z – кластер с объектами, ближайшими к z.
- $\text{cost}(C, T) = \sum\limits_{x \in C} \min\limits_{z \in T} \|x - z\|_2^2$, где $C \subset S$.
- $\text{cost}(C, z) = \sum\limits_{x \in C} \|x - z\|_2^2$, где $z \in \mathbb{R}^d$.

Идея алгоритма



Назначение точек



Пересчёт центров

Рис. 2: Схема работы алгоритма

Доказательство I

Сначала докажем вспомогательную лемму.

Лемма 1.

$$\forall C \subset \mathbb{R}^d, \forall z \in \mathbb{R}^d \hookrightarrow \text{cost}(C, z) = \text{cost}(C, \text{mean}(C)) +$$
$$+|C| \cdot \|z - \text{mean}(C)\|_2^2.$$

Доказательство. По определению:

$$\text{cost}(C, z) = \left(\frac{1}{|C|} \sum_{x \in C} \|x - z\|_2^2 \right) \cdot |C| = \mathbb{E}_{x \sim U(C)} \|x - z\|_2^2 \cdot |C|.$$

Можем переписать исходное утверждение:

$$|C| \cdot \mathbb{E}\|x - z\|_2^2 = |C| \cdot \mathbb{E}\|x - \mathbb{E}(x)\|_2^2 + |C| \cdot \|z - \mathbb{E}(x)\|_2^2.$$

Доказательство II

Сократим на $|C|$ и распишем правую часть:

$$\mathbb{E}\|x\|_2^2 + \|\mathbb{E}(x)\|_2^2 - 2\mathbb{E}[x \cdot \mathbb{E}(x)] + \|z\|_2^2 + \|\mathbb{E}(x)\|_2^2 - 2z\mathbb{E}(x)$$
$$= \mathbb{E}\|x\|_2^2 + \|z\|_2^2 - 2z\mathbb{E}(x) = \mathbb{E}\|x - z\|_2^2.$$

□

Алгоритм K-means

Алгоритм k-means

Вход: $c_1^0, \ldots, c_k^0$ — начальная инициализация центроидов, $t = 0$.

1: **while** не выполнены условия останова **do**

2: $\quad \forall i \in \{1, \ldots, k\} : z_i^{t+1} = \text{mean}(C_i^t)$.

3: $\quad \forall i \in \{1, \ldots, k\} : C_i^{t+1} = \{x \in S | i = \underset{j \in \{1,\ldots,k\}}{\text{argmin}} \left\| z_j^{t+1} - x \right\|_2^2\}$.

4: **end while**

Выход: $T_1, \ldots, T_k; C_1^T, \ldots, C_k^T$.

Доказательство сходимости

Теорема.

K-means монотонно сходится.

Доказательство. Перепишем:

$$\text{cost}(S, T) = \sum_{z \in T} \sum_{x \in S} \|x - z\|_2^2 = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - z_i\|_2^2.$$

По лемме:

$$\text{cost}(C_i^t, z_i^{t+1}) \leq \text{cost}(C_i^t, z_i^t) \Rightarrow \sum_{i=1}^{k} \text{cost}(C_i^t, z_i^{t+1}) \leq \sum_{i=1}^{k} \text{cost}(C_i^t, z_i^t).$$

Доказательство сходимости

Теорема.

K-means монотонно сходится.

Доказательство. Перепишем:

$$\text{cost}(S, T) = \sum_{z \in T} \sum_{x \in S} \|x - z\|_2^2 = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - z_i\|_2^2.$$

По лемме:

$$\text{cost}(C_i^t, z_i^{t+1}) \leq \text{cost}(C_i^t, z_i^t) \Rightarrow \sum_{i=1}^{k} \text{cost}(C_i^t, z_i^{t+1}) \leq \sum_{i=1}^{k} \text{cost}(C_i^t, z_i^t).$$

Из сути выбора C_i^{t+1}:

$$\text{cost}(C_i^{t+1}, z_i^{t+1}) \leq \text{cost}(C_i^t, z_i^{t+1}) \leq \text{cost}(C_i^t, z_i^t).$$

Доказательство сходимости

Просуммируем по k:

$$\text{cost}(C_i^{t+1}, z_i^{t+1}) \leq \text{cost}(C_i^t, z_i^{t+1}) \leq \text{cost}(C_i^t, z_i^t) \Rightarrow$$

$$\text{cost}(S, T^{t+1}) = \sum_{i=1}^{k} \text{cost}(C_i^{t+1}, z_i^{t+1}) \leq \sum_{i=1}^{k} \text{cost}(C_i^t, z_i^t) = \text{cost}(S, T^t).$$

□

Пример работы алгоритма

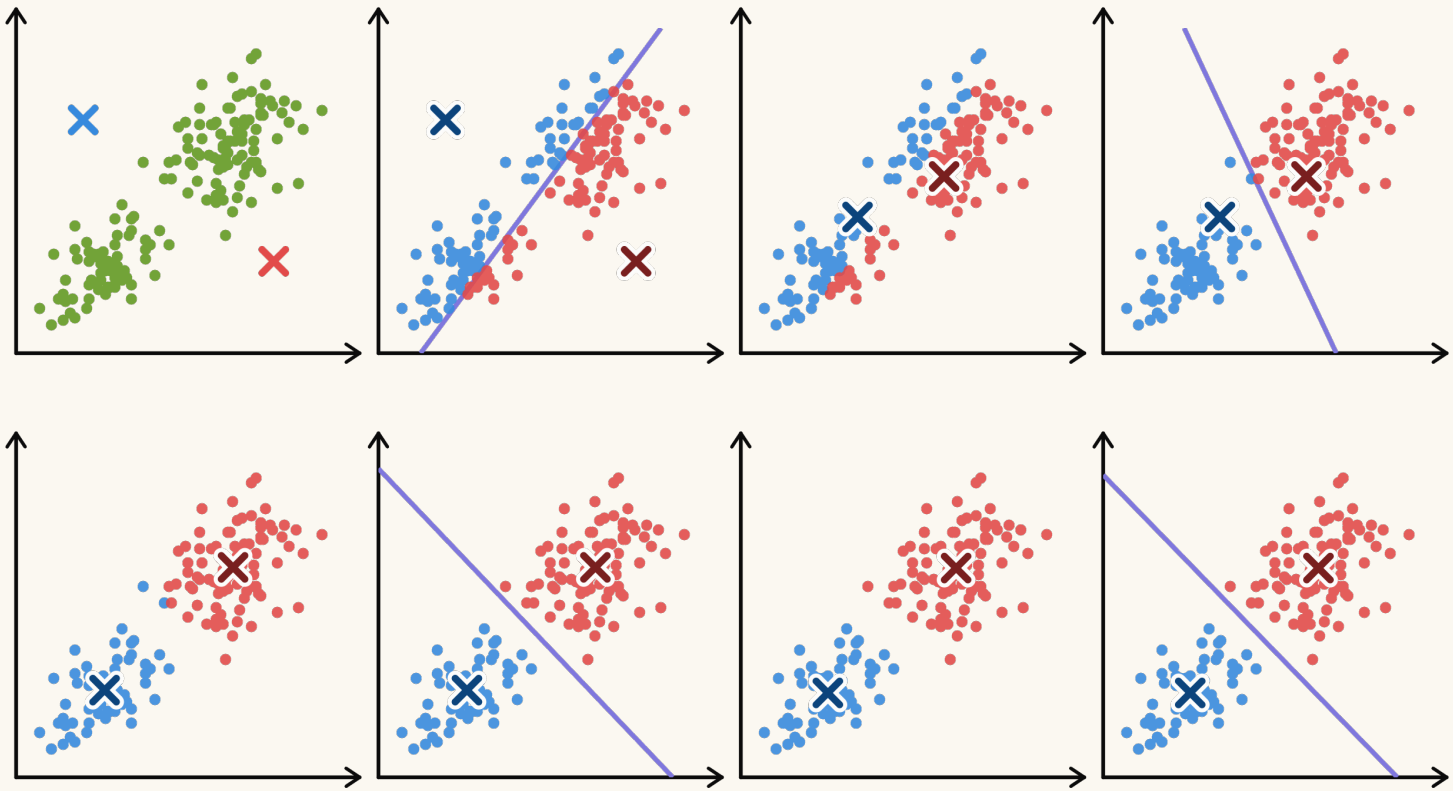
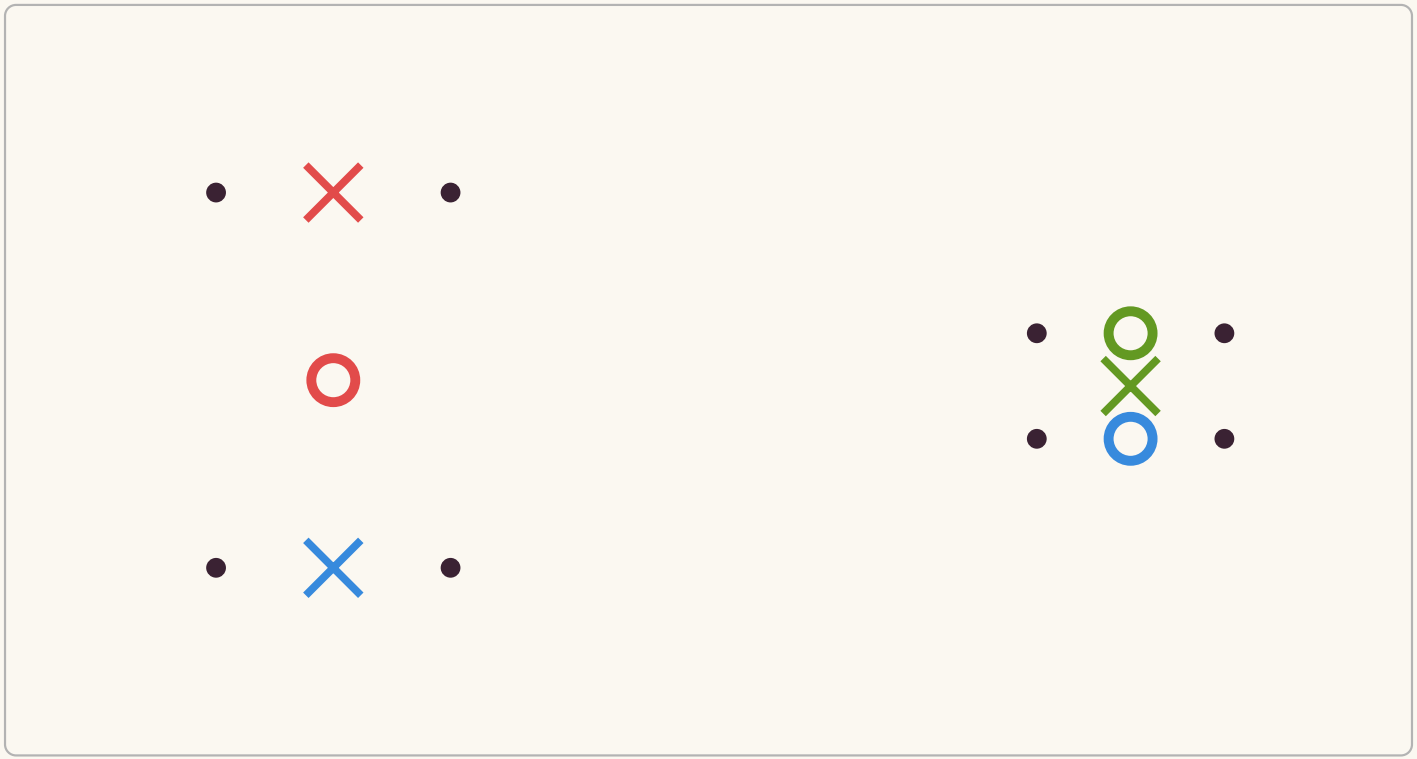


Рис. 3: Итерации алгоритма k-means

Пример плохой инициализации



результат k-means

оптимальная кластеризация

Проблема инициализации в k-means

- Монотонная сходимость k-means не гарантирует оптимальные результаты.
- Неудачный выбор начальных центроидов приводит к плохой кластеризации.
- Хочется выбирать их «по-умному»: чтобы они были подальше друг от друга.
- Так получается k-means++ —тот же алгоритм, но с другой инициализацией.

k-means++

Алгоритм Инициализация k-means++

Вход: множество точек S, число кластеров k

1: выбрать $z^1 \in S$ равномерно.
2: $T^1 \leftarrow \{z^1\}$.
3: **for** $i = 1, \ldots, k-1$ **do**
4: выбрать случайную точку $z^{i+1} \in S$ с вероятностью $\mathbb{P}\{z^{i+1} = x\} \sim \text{cost}(x, T^i) = \min\limits_{z \in T^i} \|x - z\|_2^2$.
5: $T^{i+1} \leftarrow T^i \cup \{z^{i+1}\}$.
6: **end for**

Выход: начальные центроиды T^k.

Сходимость k-means++

Лемма 2.

$\forall C \subset \mathbb{R}^d, z \sim U(C)$ — случайно равеновероятная точка из C. Тогда $\mathbb{E}[\text{cost}(C, z)] = 2\text{cost}(C, \text{mean}(C))$.

Доказательство.

$$\mathbb{E}[\text{cost}(C, z)] = \frac{1}{|C|} \sum_{z' \in C} \text{cost}(C, z').$$

По Лемме 1, можем выразить:

$$\begin{aligned}\mathbb{E}[\text{cost}(C, z)] &= \frac{1}{|C|} \sum_{z' \in C} \left(\text{cost}(C, \text{mean}(C)) + |C| \cdot \left\|z' - \text{mean}(C)\right\|_2^2\right) = \\ &= \text{cost}(C, \text{mean}(C)) + \sum_{z' \in C} \left\|z' - \text{mean}(C)\right\|_2^2 = \\ &= 2\text{cost}(C, \text{mean}(C)).\end{aligned}$$

Сходимость k-means++

Лемма 3.

Пусть T^i — текущие центры. Пусть добавляется $z^{i+1} \in C^{i+1}$, где C^{i+1} — идеальный кластер. Тогда:

$$\mathbb{E}[\text{cost}(C_*^{i+1}, T^i \cup \{z^{i+1}\})] \leq 8 \cdot \text{cost}(C_*^{i+1}, z_*^{i+1}) = \\ = 8 \cdot \text{cost}(C_*^{i+1}, \text{mean}(C_*^{i+1})).$$

Теорема.

Пусть T — центры для k-means++. T^* — идеальные центры, $\text{cost}(S, T^*)$ — цель. Тогда:

$$\mathbb{E}[\text{cost}(S, T)] \leq 8 \cdot (1 + mk)\text{cost}(S, T_*).$$

Как выбрать число кластеров?

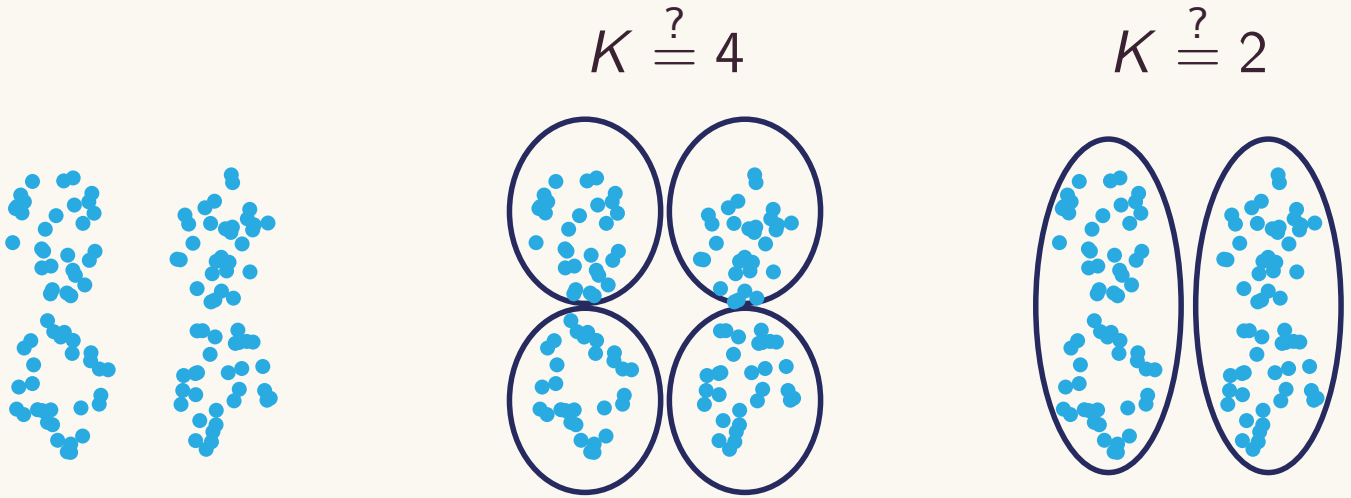
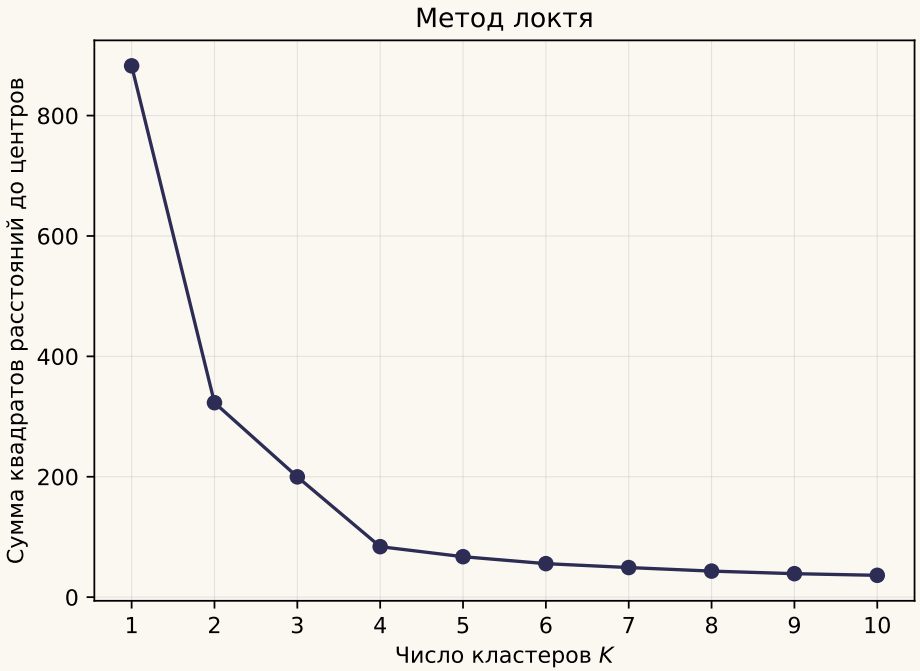


Рис. 4: Разбиение на различное число кластеров.

Метод локтя



На этом графике изломов два, при $K = 2$ и при $K = 4$, так что метод не всегда даёт однозначный ответ.

- Для каждого $k = 1, 2, \ldots, k_{\max}$ запускаем k-means и получаем центры T_k.
- Считаем $\text{cost}(S, T_k) = \sum_{x \in S} \min_{z \in T_k} \|x - z\|_2^2$.
- Строим график $\text{cost}(S, T_k)$ в зависимости от k.
- Выбираем k в точке «локтя», где убывание резко замедляется: дальнейшее увеличение k почти не улучшает разбиение.

Метод силуэтов

- Для каждой точки $x^i \in S$ считаем величины:

$$a(x^i) = \frac{1}{|C(x^i)| - 1}\text{cost}(C(x^i), x^i),$$
$$b(x^i) = \frac{1}{\left|\hat{C}(x^i)\right|}\text{cost}(\hat{C}(x^i), x^i),$$

  где $C(x^i)$ — кластер, где лежит x^i, $\hat{C}(x^i)$ — ближайших кластер без x^i.

- Для каждой точки $x^i \in S$ считаем величину:

$$s(x^i) = \frac{b(x^i) - a(x^i)}{\max(a(x^i), b(x^i))} \in (-1, 1)$$

Метод силуэтов

- Классифицируем точку:

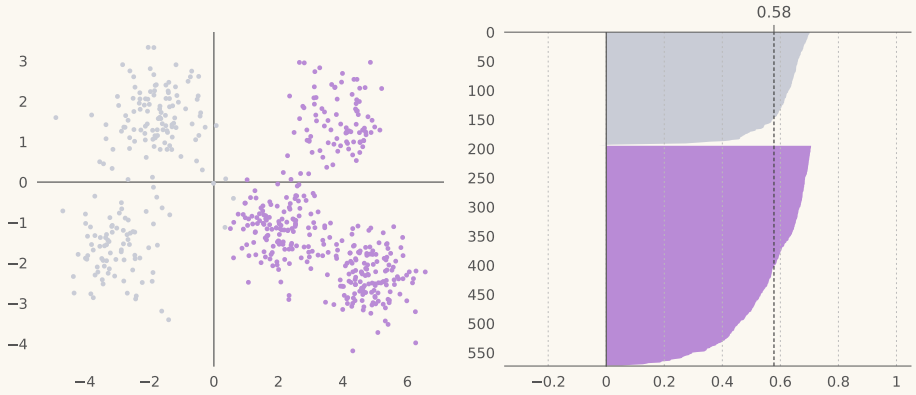
$b(x^i) \gg a(x^i), s(x^i) > 0$ – хорошая кластеризация

$b(x^i) \approx a(x^i),\ s(x^i) \approx 0$ – неуверенная кластеризация

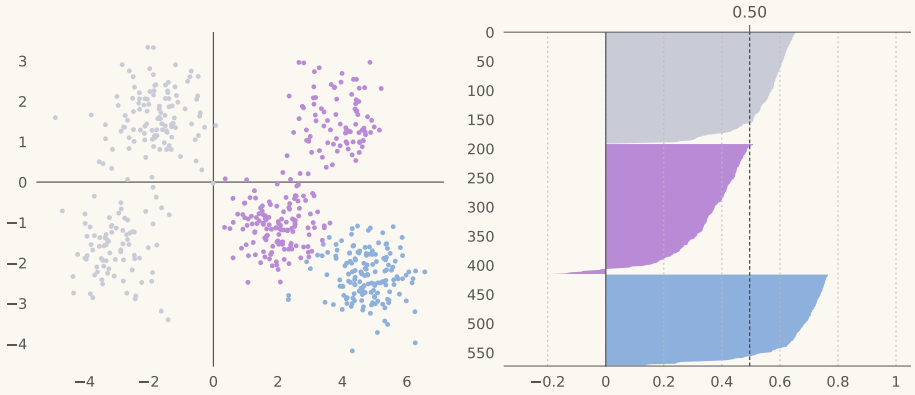
$b(x^i) \ll a(x^i), s(x^i) < 0$ – плохая кластеризация

- Изменяем число кластеров в зависимости от получившихся результатов.
- Наилучшая кластеризация наблюдается при наилучшем среднем $s(x^i)$ и отсутствии отрицательных $s(x^i)$.

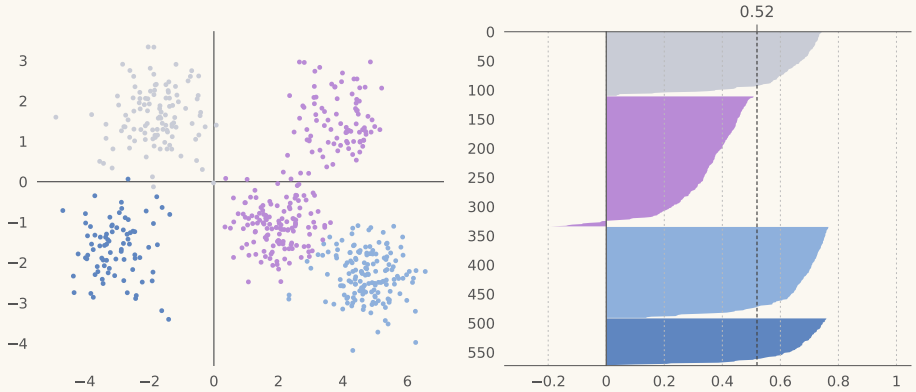
Метод силуэтов: подбор k



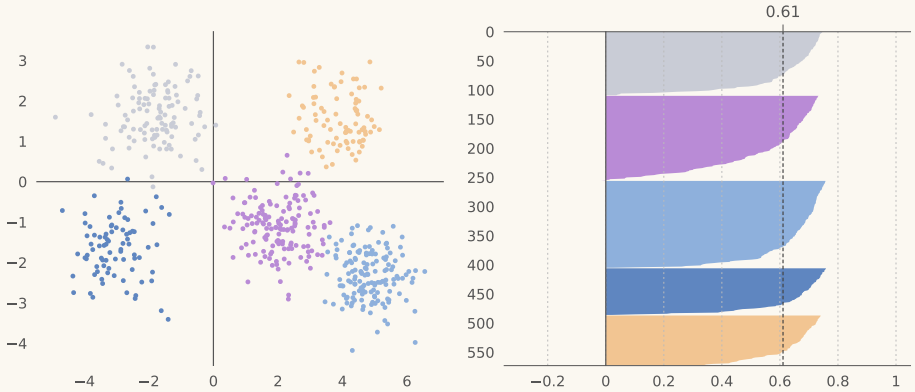
$k = 2$



$k = 3$



$k = 4$



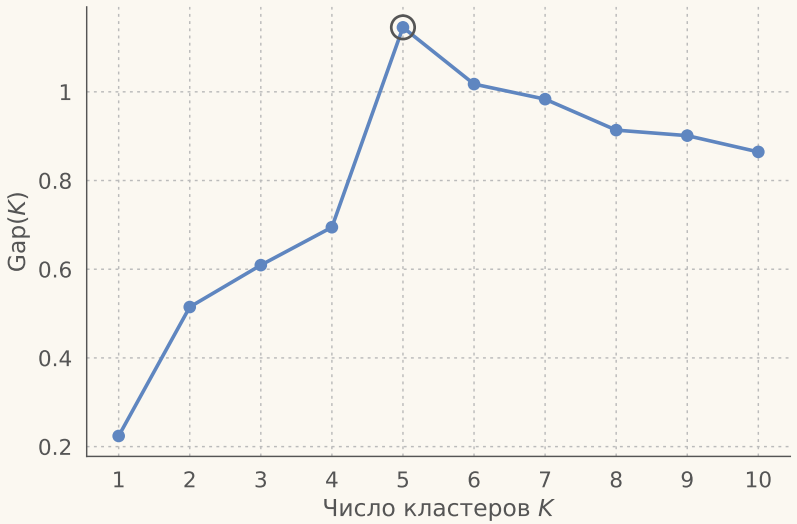
$k = 5$

Метод зазора статистик

- Для каждого k считаем $\text{cost}(S, T_k)$.
- Генерируем B – произвольное количество равномерных выборок S_b^* того же размера вокруг S и так же считаем $\text{cost}(S_b^*, T_{k,b}^*)$.
- Считаем метрику Gap:

$$\text{Gap}(k) = \frac{1}{B}\sum_b \log \text{cost}(S_b^*, T_{k,b}^*) - \log \text{cost}(S, T_k).$$

- Выбираем наименьшее k, для которого $\text{Gap}(k) \geq \text{Gap}(k+1) - s_{k+1}$, где $s_k = \sqrt{\mathbb{D} \log \text{cost}(S^*, T_k^*)}$ по случайным выборкам S^*.



Здесь $\text{Gap}(k)$ максимален при $k = 5$, и правило выбора тоже даёт $k = 5$.

Выбор количества кластеров: итоги

- Метод локтя и метод силуэтов помогают визуально оценить качество кластеризации при выбранном количестве центров.
- Метод зазора статистик позволяет найти количественно наилучшее число кластеров для кластеризации.
- Методы могут давать не один корректный вариант разбиения и выбор зависит от постановки задачи.