

Градиентный бустинг - 1

Александр Безносиков

ФПМИ МФТИ

25 ноября 2025



Идея бустинга

Пусть $(x^1, y^1), \dots, (x^n, y^n)$ — обучающая выборка.

$\mathcal{G}$ — семейство базовых моделей.

Рассматриваем модели вида

$$\hat{y}(x) = \sum_{t=1}^T g_t(x) = \sum_{t=1}^T g(w_t, x), \quad \text{где } g_t \in \mathcal{G}.$$

Идея бустинга:

Идея бэггинга:

Строим каждую модель **независимо** на случайной подвыборке и различными случайными факторами.

- 1 Строим модель
- 2 Оцениваем её ошибки
- 3 Строим новую модель, которая компенсирует ошибки предыдущей
- 4 Повторить T раз

Бустинг в задаче регрессии с MSE

Оптимизируем MSE (Mean Squared Error, $\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y^i - \hat{y}^i)^2$).

- 1 Построим первую базовую модель:

$$w_1 = \underset{w \in \mathbb{R}^d}{\operatorname{argmin}} \frac{1}{n} \sum_{i=1}^n (g(w, x^i) - y^i)^2.$$

Бустинг в задаче регрессии с MSE

Оптимизируем MSE (Mean Squared Error, $\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y^i - \hat{y}^i)^2$).

- 1 Построим первую базовую модель:

$$w_1 = \underset{w \in \mathbb{R}^d}{\operatorname{argmin}} \frac{1}{n} \sum_{i=1}^n (g(w, x^i) - y^i)^2.$$

- 2 Посчитаем разницу между y и предсказанием $g(w_1, x)$ первой модели: $e_1^i = y^i - g(w_1, x^i)$.

Бустинг в задаче регрессии с MSE

Оптимизируем MSE (Mean Squared Error, $\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y^i - \hat{y}^i)^2$).

- 1 Построим первую базовую модель:

$$w_1 = \underset{w \in \mathbb{R}^d}{\operatorname{argmin}} \frac{1}{n} \sum_{i=1}^n (g(w, x^i) - y^i)^2.$$

- 2 Посчитаем разницу между y и предсказанием $g(w_1, x)$ первой модели: $e_1^i = y^i - g(w_1, x^i)$.

- 3 Построим вторую базовую модель так, чтобы её ответы как можно лучше приближали e_1 :

$$w_2 = \underset{w \in \mathbb{R}^d}{\operatorname{argmin}} \frac{1}{n} \sum_{i=1}^n (g(w, x^i) - e_1^i)^2.$$

Бустинг в задаче регрессии с MSE

Оптимизируем MSE (Mean Squared Error, $\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y^i - \hat{y}^i)^2$).

- ① Построим первую базовую модель:

$$w_1 = \underset{w \in \mathbb{R}^d}{\operatorname{argmin}} \frac{1}{n} \sum_{i=1}^n (g(w, x^i) - y^i)^2.$$

- ② Посчитаем разницу между y и предсказанием $g(w_1, x)$ первой модели: $e_1^i = y^i - g(w_1, x^i)$.

- ③ Построим вторую базовую модель так, чтобы её ответы как можно лучше приближали e_1 :

$$w_2 = \underset{w \in \mathbb{R}^d}{\operatorname{argmin}} \frac{1}{n} \sum_{i=1}^n (g(w, x^i) - e_1^i)^2.$$

- ④ Следующие модели обучаем на e_{t-1} :

$$e_{t-1}^i = y^i - \hat{y}_{t-1}(x^i) = y^i - \sum_{k=1}^{t-1} g(w_k, x^i),$$
$$w_t = \underset{w \in \mathbb{R}^d}{\operatorname{argmin}} \frac{1}{n} \sum_{i=1}^n (g(w, x^i) - e_{t-1}^i)^2.$$

Бустинг в задаче регрессии

- 1 Разность после $t - 1$ шага (остаток): $e_{t-1}^i = y^i - \hat{y}_{t-1}(x^i)$
- 2 Задача оптимизации t -й модели:
$$w_t = \operatorname{argmin}_{w \in \mathbb{R}^d} \frac{1}{2} \sum_{i=1}^n (g(w, x^i) - e_{t-1}^i)^2.$$
- 3 Предсказание t -й модели: $\hat{y}_t(x) = \hat{y}_{t-1}(x) + g(w_t, x).$

Бустинг в задаче регрессии

- 1 Разность после $t - 1$ шага (остаток): $e_{t-1}^i = y^i - \hat{y}_{t-1}(x^i)$
- 2 Задача оптимизации t -й модели:
$$w_t = \operatorname{argmin}_{w \in \mathbb{R}^d} \frac{1}{2} \sum_{i=1}^n (g(w, x^i) - e_{t-1}^i)^2.$$
- 3 Предсказание t -й модели: $\hat{y}_t(x) = \hat{y}_{t-1}(x) + g(w_t, x)$.

Таким образом:

- g_1 обучается на выборке $\{(x^i, y^i)\}_{i=1}^n$,
- g_2 обучается на выборке $\{(x^i, e_1^i)\}_{i=1}^n$,
- ...
- g_T обучается на выборке $\{(x^i, e_{T-1}^i)\}_{i=1}^n$.

Бустинг в задаче регрессии





- 1 Разность после $t - 1$ шага (остаток): $e_{t-1}^i = y^i - \hat{y}_{t-1}(x^i)$
- 2 Задача оптимизации t -й модели:
$$w_t = \operatorname{argmin}_{w \in \mathbb{R}^d} \frac{1}{2} \sum_{i=1}^n (g(w, x^i) - e_{t-1}^i)^2.$$
- 3 Предсказание t -й модели: $\hat{y}_t(x) = \hat{y}_{t-1}(x) + g(w_t, x)$.

Таким образом:

- g_1 обучается на выборке $\{(x^i, y^i)\}_{i=1}^n$,
- g_2 обучается на выборке $\{(x^i, e_1^i)\}_{i=1}^n$,
- ...
- g_T обучается на выборке $\{(x^i, e_{T-1}^i)\}_{i=1}^n$.

Замечание: Модели g_t не обязаны быть одинаковыми, но на практике это работает редко.

Визуализация бустинга



Обучение бустинга

Вспомним, что мы оптимизируем:

$$\min_{\hat{y}} \mathcal{L}(y, \hat{y}) = \min_{\hat{y}} \frac{1}{n} \sum_{i=1}^n (\hat{y}(x^i) - y^i)^2.$$

Заметим, что производная $\mathcal{L}$ по ответу модели $\hat{y}_{t-1}$ на объекте x^i равна $\hat{y}_{t-1}(x^i) - y^i = -e_{t-1}^i$. Получаем:

$$\Rightarrow e_{t-1} = (e_{t-1}^1, \dots, e_{t-1}^n) = -\nabla \mathcal{L}(y, z) \big|_{z=\hat{y}_{t-1}}.$$

- Модель шагает в сторону антиградиента, т.е. направления наискорейшего спуска.
- Хотим выбрать такую модель, которая как можно сильнее уменьшит ошибку композиции.

Функция потерь у задачи с бустингом

Заметим, что на самом деле бустинг изменил задачу, которую мы решаем:

Функция ошибки

«Классическая» задача

$$\sum_{i=1}^n \mathcal{L}\left(\sum_{t=1}^{T-1} g_t(x^i) + g_T; y^i\right)$$

Бустинг

$$\sum_{i=1}^n \mathcal{L}\left(g_T; y^i - \sum_{t=1}^{T-1} g_t(x^i)\right)$$

Вопрос: Влияет ли это на решение?

Функция потерь у задачи с бустингом

Заметим, что на самом деле бустинг изменил задачу, которую мы решаем:

Функция ошибки

«Классическая» задача

$$\sum_{i=1}^n \mathcal{L}\left(\sum_{t=1}^{T-1} g_t(x^i) + g_T; y^i\right)$$

Бустинг

$$\sum_{i=1}^n \mathcal{L}\left(g_T; y^i - \sum_{t=1}^{T-1} g_t(x^i)\right)$$

Вопрос: Влияет ли это на решение?

Заметим, что для большинства функций потерь (в т.ч. MSE) это изменение не повлияет на значение функции.

Важные замечания

Кажется, подобная процедура слишком сложная и неоптимальная.

Оптимизируем

$$\min_{\hat{y}} \mathcal{L}(y, \hat{y}) = \min_{\hat{y}} \frac{1}{n} \sum_{i=1}^n (\hat{y}(x^i) - y^i)^2.$$

Решение задачи известно: $\mathcal{L}(y, \hat{y}) = 0$ при $\hat{y}(x^i) = y^i$.

Зачем выполнять сложную процедуру и обучать на остатках?

Важные замечания

Кажется, подобная процедура слишком сложная и неоптимальная.
Оптимизируем

$$\min_{\hat{y}} \mathcal{L}(y, \hat{y}) = \min_{\hat{y}} \frac{1}{n} \sum_{i=1}^n (\hat{y}(x^i) - y^i)^2.$$

Решение задачи известно: $\mathcal{L}(y, \hat{y}) = 0$ при $\hat{y}(x^i) = y^i$.

Зачем выполнять сложную процедуру и обучать на остатках?

1. Мы не можем в точности обеспечить условие $\hat{y}(x^i) = y^i$, т.к. ограничены только моделями g_t из класса $\mathcal{G}$.

Тогда у нас точно есть некоторая ошибка, и хочется «отталкиваясь» от неё понять, в какую сторону надо сдвинуться, чтобы улучшить предсказания.

2. Если и получается построить модель, которая обеспечивает выполнение $\hat{y}(x^i) = y^i$, то скорее всего она переобучилась.

Градиентный бустинг

В **бэггинге** мы усредняли ответы моделей: $\hat{y}_T(x) = \frac{1}{T} \sum_{t=0}^T g_t(x)$.

Давайте строить взвешенную сумму базовых моделей для **бустинга**:

$$\hat{y}_T(x) = \sum_{t=0}^T \gamma_t g_t(x).$$

Под индексом $t = 0$ обозначена начальная модель.

- Обычно $\gamma_0 = 1$.
- Сама g_0 обычно очень простая. Она может:
 - быть нулевой $g_0(x) = 0$;
 - возвращать самый популярный класс (для классификации):

$$g_0(x) = \operatorname{argmax}_{c \in \mathcal{Y}} \sum_{i=1}^n \mathbb{I}\{y^i = c\};$$

- возвращать среднее значение (для регрессии):

$$g_0(x) = \frac{1}{n} \sum_{i=1}^n y^i.$$

Построение модели

Функция ошибки: $\min_{\hat{y}} \mathcal{L}(y, \hat{y}) = \min_{\hat{y}} \sum_{i=1}^n \ell(y^i, \hat{y}(x^i))$,

где $\ell(y, z)$ — кусочно-гладкая функция потерь.

Замечание: Из-за того, что ℓ кусочно-гладкая, обычный градиентный спуск не работает.

Рассмотрим пространство $\mathbb{R}^n$, в котором решим задачу оптимизации

$$\min_{s \in \mathbb{R}^n} \mathcal{L}(y, s) = \min_{s \in \mathbb{R}^n} \sum_{i=1}^n \ell(y^i, s^i)$$

градиентным спуском

$$s_t = s_{t-1} - \eta \nabla_s \mathcal{L}(y, s_{t-1}) = s_{t-1} - \eta \left(\nabla_s \ell(y^i, s_{t-1}^i) \right)_{i=1}^n$$

Построение модели

Получается, в условиях нашей модели в идеале должно быть:

$$\hat{y}_t(x^i) = \hat{y}_{t-1}(x^i) - \eta \tilde{e}_t^i$$

$$\tilde{e}_t = \left(\nabla_s \ell(y^i, s) \Big|_{s=\hat{y}_{t-1}(x^i)} \right)_{i=1}^n$$

То есть модель должна выдавать $\tilde{e}_t^i$ на x^i .

Вопрос: Всегда ли можно найти такую модель?

Построение модели

Получается, в условиях нашей модели в идеале должно быть:

$$\hat{y}_t(x^i) = \hat{y}_{t-1}(x^i) - \eta \tilde{e}_t^i$$

$$\tilde{e}_t = \left(\nabla_s \ell(y^i, s) \Big|_{s=\hat{y}_{t-1}(x^i)} \right)_{i=1}^n$$

То есть модель должна выдавать $\tilde{e}_t^i$ на x^i .

Вопрос: Всегда ли можно найти такую модель?

Такая модель может и не существовать в $\mathcal{G}$.

Тогда просто обучим новую модель по выборке:

$(x^1, -\tilde{e}_t^1), \dots, (x^n, -\tilde{e}_t^n)$, оптимизируя MSE

$$g_t(x) = \operatorname{argmin}_{g \in \mathcal{G}} \sum_{i=1}^n (g(x^i) + \tilde{e}_t^i)^2.$$

Замечания

- ① Метод градиентного бустинга эффективно аппроксимирует сложные функции, и результирующая модель ансамбля может быть кусочно-линейной.
- ② Оптимизируем MSE независимо от функционала исходной задачи — вся информация о $\mathcal{L}$ находится в векторе $\tilde{e}^t$.
- ③ Можно использовать и другие функции потерь (MAE, Huber), но MSE обычно достаточно.

Выбор коэффициента в базовой модели

Коэффициент при g_t подберём без учёта шага обучения η :

$$\hat{\gamma}_t = \operatorname{argmin}_{\gamma \in \mathbb{R}} \sum_{i=1}^n \ell(y^i, \hat{y}_{t-1}(x^i) + \gamma g_t(x^i)).$$

Вопрос: Зачем нужен γ_t ?

Выбор коэффициента в базовой модели

Коэффициент при g_t подберём без учёта шага обучения η :

$$\hat{\gamma}_t = \operatorname{argmin}_{\gamma \in \mathbb{R}} \sum_{i=1}^n \ell(y^i, \hat{y}_{t-1}(x^i) + \gamma g_t(x^i)).$$

Вопрос: Зачем нужен γ_t ?

По своей сути градиент показывает направление, а γ_t позволяет «скорректировать» длину шага в этом направлении, мы можем снизить доверие к направлению.

Итог: $\hat{y}_t(x) = \hat{y}_{t-1}(x) + \eta \hat{\gamma}_t g_t(x)$

Итоговый алгоритм градиентного бустинга

1. Выбрать базовую модель $g_0(x)$, положить $\hat{y}_0(x) = g_0(x)$.
2. Повторять для $t = 1, \dots, T$:

1. Вычислить градиенты по обучающей выборке:

$$\tilde{e}_t = \left(\nabla_s \ell(y^i, s) \Big|_{s=\hat{y}_{t-1}(x^i)} \right)_{i=1}^n.$$

2. Обучить новую модель по MSE по выборке:

$$(x_1, -\tilde{e}_t^1), \dots, (x_n, -\tilde{e}_t^n).$$

3. Подобрать коэффициент при g_t :

$$\gamma_t = \operatorname{argmin}_{\gamma \in \mathbb{R}} \sum_{i=1}^n \ell(y^i, \hat{y}_{t-1}(x^i) + \gamma g_t(x^i)).$$

4. Добавить модель к композиции:

$$\hat{y}_t(x) = \hat{y}_{t-1}(x) + \eta \gamma_t g_t(x).$$

Сравнение идеи бустинга и градиентного бустинга

Бустинг

Ответы всех моделей g_t складываются с коэффициентом 1.

Обучаем g_t
на выборке $\{(x^i, e_{t-1}^i)\}_{i=1}^n$
 $= \{(x^i, y^i - \hat{y}_{t-1}(x^i))\}_{i=1}^n$

Градиентный бустинг

Ответы моделей g_t складываются с некоторым коэффициентом γ_t , который подбирается в процессе обучения.

Обучаем g_t
на выборке $\{(x^i, \tilde{e}_{t-1}^i)\}_{i=1}^n$
 $= \{(x^i, \nabla_s \ell(y^i, s)|_{s=\hat{y}_{t-1}(x^i)})\}_{i=1}^n$

Стохастический градиентный бустинг

Идея: Модель g_t обучается не по всей выборке X , а лишь по её случайному подмножеству $X_t^* \subset X$.

Подмножество X_t^* выбирается для каждой итерации заново.

Преимущества:

- Повышается уровень шума в обучении $\Rightarrow$ повышается обобщающая способность
- Повышается эффективность вычислений

Рекомендация: Брать подвыборки размером $\frac{1}{2}|X|$.

Какая интуиция стоит за этим?

Стохастический градиентный бустинг

Идея: Модель g_t обучается не по всей выборке X , а лишь по её случайному подмножеству $X_t^* \subset X$.

Подмножество X_t^* выбирается для каждой итерации заново.

Преимущества:

- Повышается уровень шума в обучении $\Rightarrow$ повышается обобщающая способность
- Повышается эффективность вычислений

Рекомендация: Брать подвыборки размером $\frac{1}{2}|X|$.

Какая интуиция стоит за этим?

Это достаточно мало, чтобы ускорить вычисления и каждая последующая выборка отличалась от предыдущей, но при этом достаточно много, чтобы выборка была репрезентативной.

Задача классификации

Рассмотрим задачу бинарной классификации: $y^i \in \{-1, +1\}$.
Тогда решающее правило принимает вид: $f(x) = \text{sign}(\hat{y}(x))$
Экспоненциальная функция потерь:

$$\ell(y, z) = \exp(-yz)$$

$$\frac{\partial \ell(y, z)}{\partial z} = -y \exp(-yz)$$

$$\tilde{e}_t^i = \frac{\partial \ell(y^i, \hat{y}_{t-1}(x^i))}{\partial z} = -y^i \cdot \exp(-y^i \cdot \hat{y}_{t-1}(x^i))$$

Модель g_t обучается на выборке $\{x^i, y^i \cdot \exp(-y^i \cdot \hat{y}_{t-1}(x^i))\}_{i=1}^n$

Взвешенное голосование (Majority voting)

Возьмём $y = \{\pm 1\}$, $g_t : X \rightarrow \{-1, 0, +1\}$,
 $g_t(x) = 0$ отказ (лучше промолчать, чем соврать)

Взвешенное голосование - решающее правило композиции:

$$\text{sign} \left(\sum_{t=1}^T \gamma_t g_t(x) \right), \quad x \in X$$


Функционал качества - число ошибок на обучающей выборке X^n :

$$\mathcal{L}_T(x, y) = \sum_{i=1}^n \left[(y^i \sum_{t=1}^T \gamma_t g_t(x^i)) \leq 0 \right]$$

Ключевые эвристики бустинга

- 1 Фиксация уже обученных $\gamma_1 g_1(x), \dots, \gamma_{t-1} g_{t-1}(x)$ при добавлении $\gamma_t g_t(x)$
- 2 Используем **гладкую** аппроксимацию пороговой функции потерь

Гладкие аппроксимации пороговой функции потерь



Экспоненциальная аппроксимация пороговой функции потерь - AdaBoost

Функционал качества $\mathcal{L}_T$ ограничен сверху:

$$\mathcal{L}_T \leq \tilde{\mathcal{L}}_T = \prod_{t=1}^T \sum_{i=1}^n \exp(-y^i \gamma_t g_t(x^i))$$

Нормированные веса объектов: $\tilde{W}^n = \left(\frac{w_1}{\sum w_j}, \dots, \frac{w_n}{\sum w_j} \right)$

Для произвольного вектора весов $U^n = (u^1, \dots, u^n)$ определим:

Ошибки: $N(g, U^n) = \sum_{i: g(x^i) \neq y^i} u^i$

Верные ответы: $P(g, U^n) = \sum_{i: g(x^i) = y^i} u^i$

Взвешенное число отказов от классификации: $1 - [N(g, U^n) + P(g, U^n)]$

Основная теорема бустинга (для AdaBoost)

Пусть $\mathcal{G}$ — достаточно богатое семейство базовых алгоритмов.

Theorem (Freund, Schapire, 1996)

Пусть для любого нормированного вектора весов U^n существует алгоритм $g \in \mathcal{G}$, классифицирующий выборку хотя бы немного лучше, чем наугад:

$$P(g; U^n) > N(g; U^n).$$

Тогда минимум функционала $\tilde{\mathcal{L}}_T$ достигается при:

$$g_T = \operatorname{argmax}_{g \in \mathcal{G}} \left(\sqrt{P(g; \tilde{W}^n)} - \sqrt{N(g; \tilde{W}^n)} \right),$$

$$\gamma_T = \frac{1}{2} \ln \left(\frac{P(g_T; \tilde{W}^n)}{N(g_T; \tilde{W}^n)} \right).$$

Доказательство - 1/2

Воспользуемся тождеством $\forall \gamma \in \mathbb{R}, \forall g \in \{-1, 0, +1\}$:

$$e^{-\gamma g} = e^{-\gamma}[g = 1] + e^{\gamma}[g = -1] + [g = 0].$$

Положим для краткости $\gamma = \gamma_T$ и $g^i = g_T(x^i)$. Тогда

$$\begin{aligned}\tilde{\mathcal{L}}_T &= \left(e^{-\gamma} \sum_{i=1}^n \tilde{w}_i [g^i = y^i] + e^{\gamma} \sum_{i=1}^n \tilde{w}_i [g^i = -y^i] + \sum_{i=1}^n \tilde{w}_i [g^i = 0] \right) \sum_{i=1}^n w_i \\ &= (e^{-\gamma} P + e^{\gamma} N + (1 - P - N)) \tilde{\mathcal{L}}_{T-1} \rightarrow \min_{\gamma, g}.\end{aligned}$$

$$\frac{\partial}{\partial \gamma} \tilde{\mathcal{L}}_T = (-e^{-\gamma} P + e^{\gamma} N) \tilde{\mathcal{L}}_{T-1} = 0 \Rightarrow e^{-\gamma} P = e^{\gamma} N \Rightarrow e^{2\gamma} = \frac{P}{N}.$$

Получили требуемое: $\gamma_T = \frac{1}{2} \ln \frac{P}{N}$.

Доказательство - 2/2

Подставим оптимальное значение $\gamma = \frac{1}{2} \ln \frac{P}{N}$ обратно в $\tilde{\mathcal{L}}_T$:

$$\begin{aligned}\tilde{\mathcal{L}}_T &= (e^{-\gamma}P + e^{\gamma}N + (1 - P - N))\tilde{\mathcal{L}}_{T-1} = \\ &= \left(1 + \sqrt{\frac{N}{P}}P + \sqrt{\frac{P}{N}}N - P - N\right)\tilde{\mathcal{L}}_{T-1} = \\ &= \left(1 - (\sqrt{P} - \sqrt{N})^2\right)\tilde{\mathcal{L}}_{T-1} \rightarrow \min_g.\end{aligned}$$

Поскольку $\tilde{\mathcal{L}}_{T-1}$ не зависит от γ_T и g_T , минимизация $\tilde{\mathcal{L}}_T$ эквивалентна либо максимизации $\sqrt{P} - \sqrt{N}$ при $P > N$, либо максимизации $\sqrt{N} - \sqrt{P}$ при $P < N$, однако второй случай исключён условием теоремы.

Получили $g_T = \operatorname{argmax}_g \sqrt{P} - \sqrt{N}$. Теорема доказана.

Следствие 1. Классический AdaBoost.

Пусть отказов нет, $g_t : X \rightarrow \{\pm 1\}$. Тогда $P = 1 - N$.

Theorem (Freund, Schapire, 1995)

Пусть для любого нормированного вектора весов U^n существует алгоритм $g \in \mathcal{G}$, классифицирующий выборку хотя бы немного лучше, чем наугад: $N(g; U^n) < \frac{1}{2}$.

Тогда минимум функционала $\tilde{\mathcal{L}}_T$ достигается при

$$g_T = \operatorname{argmin}_{g \in \mathcal{G}} N(g; \tilde{W}^n).$$

$$\gamma_T = \frac{1}{2} \ln \frac{1 - N(g_T; \tilde{W}^n)}{N(g_T; \tilde{W}^n)}.$$

Следствие 2. Сходимость

Theorem

Если на каждом шаге семейство $\mathcal{G}$ и метод обучения обеспечивают построение базового алгоритма g_t такого, что

$$\sqrt{P(g_t; W^n)} - \sqrt{N(g_t; W^n)} = \gamma_t > \gamma$$

при некотором $\gamma > 0$, то за конечное число шагов будет построен корректный алгоритм $g_T(x)$.

Доказательство

$\mathcal{L}_T$ сходится к нулю со скоростью геометрической прогрессии:

$$\mathcal{L}_{T+1} \leq \tilde{\mathcal{L}}_{T+1} = \tilde{\mathcal{L}}_T(1 - \gamma^2) \leq \dots \leq \tilde{\mathcal{L}}_1(1 - \gamma^2)^T.$$

Наступит момент, когда $\tilde{\mathcal{L}}_T < 1$. Но тогда $\mathcal{L}_T = 0$, поскольку $\mathcal{L}_T \in \{0, 1, \dots, n\}$.

Алгоритм AdaBoost - исходный вариант

Вход: обучающая выборка X^n , **параметр T**

Выход: базовые алгоритмы и их веса $\gamma_t g_t$, $t = 1, \dots, T$

1. Инициализировать веса объектов: $w_i := 1/n$, $i = 1, \dots, n$
2. Для всех $t = 1, \dots, T$ выполнить:
 - 2.1 Обучить базовый алгоритм: $g_t := \underset{g}{\operatorname{argmin}} N(g; W^n)$
 - 2.2 Подсчитать вес модели:

$$\gamma_t := \frac{1}{2} \ln \frac{1 - N(g_t; W^n)}{N(g_t; W^n)}$$

- 2.3 Обновить веса объектов:

$$w_i := w_i \exp(-\gamma_t y^i g_t(x^i)), \quad i = 1, \dots, n$$

- 2.4 Нормировать веса объектов:

$$w_0 := \sum_{j=1}^n w_j, \quad w_i := w_i / w_0, \quad i = 1, \dots, n$$

Эвристики и рекомендации

- Базовые классификаторы (weak classifiers):
 - решающие деревья — используются чаще всего;
 - пороговые правила, т.н. «решающие пни» (data stumps)

$$A = \{g(x) = [f_j(x) \leq \theta] \mid j = 1, \dots, n, \theta \in \mathbb{R}\}$$

- для SVM бустинг не эффективен.
- Модификация формулы для γ_t на случай $N = 0$:

$$\gamma_t := \frac{1}{2} \ln \frac{1 - N(g_t; W^n) + \frac{1}{n}}{N(g_t; W^n) + \frac{1}{n}}$$

- Дополнительный критерий остановки: увеличение частоты ошибок на контрольной выборке.