

# Введение в глубокое обучение. Часть 1

## Машинное обучение


Александр Богданов

Московский физико-технический институт

20 марта 2024



# Чат-боты



Пример: <https://chatgpt.com>


# Генерация изображений



Рис.: Бегемот в пальто


Пример: <https://shedevrum.ai>

# Наложение стиля



Пример: <https://junyanz.github.io/CycleGAN/>

# Детекция объектов



Пример: <https://viso.ai/deep-learning/object-detection/>

# Генерация видео



Пример: <https://openai.com/sora>

# Обработка звука



Пример: <https://fjiang9.github.io/NKF-AEC/>

# Игры



Пример: <https://www.youtube.com/watch?v=sMHr0H15Ubg>  
<https://ale.farama.org/environments/>




# Беспилотные автомобили




Пример: <https://www.youtube.com/shorts/Q0r5YJJTj8w>

# Рекомендательные системы



Content-based filtering



Collaborative filtering

Пример: <https://www.youtube.com>

# Что такое нейронная сеть?

Нейронная сеть — это сложная дифференцируемая функция, задающая отображение из исходного признакового пространства в пространство ответов.

Нейросети были придуманы еще в 1970 годах, но их развитие началось примерно с 2012 года.

# Причины возникновения нейронных сетей

# Причины возникновения нейронных сетей

- Стремление к переходу от построения сложных пайплайнов, каждая компонента которых тренируется сама по себе решать кусочек задачи, к end-to-end обучению всей системы, как одного целого.

# Причины возникновения нейронных сетей


- Стремление к переходу от построения сложных пайплайнов, каждая компонента которых тренируется сама по себе решать кусочек задачи, к end-to-end обучению всей системы, как одного целого.
- Автоматизация процесса отбора признаков.

# Причины возникновения нейронных сетей


- Стремление к переходу от построения сложных пайплайнов, каждая компонента которых тренируется сама по себе решать кусочек задачи, к end-to-end обучению всей системы, как одного целого.
- Автоматизация процесса отбора признаков.
- Решение задач, которые еще не были решены.

# Различие пайплайнов

## Классический



## Нейросетевой








# Математическая модель нейрона

$$a(x, w) = \sigma(\langle x, w \rangle) = \sigma \left( \sum_{i=1}^n w_i f_i(x) - w_0 \right)$$

- $\sigma(z)$  — функция активации (нелинейная);
- $w_i$  — весовые коэффициенты синаптических связей;
- $w_0$  — порог активации;
- $f_i(x) \equiv x_i$  — обобщение.



# Модель логистической регрессия




$$a(x, w) = \sigma(\langle x, w \rangle) = \frac{1}{1 + e^{-\langle x, w \rangle}}$$

# Линейный слой

Линейный слой — линейное преобразование над входящими данными. Его обучаемые параметры — это матрица  $W$  и вектор  $b$ :

$$x \rightarrow Wx + b, \quad W \in \mathbb{R}^{k \times d}, \quad x \in \mathbb{R}^d, \quad b \in \mathbb{R}^k.$$









# Полносвязная нейронная сеть



# Функции активации

Функция активации — нелинейное преобразование, покомпонентно применяющееся к пришедшим на вход данным. Благодаря функциям активации нейронные сети способны порождать более информативные признаковые описания, преобразуя данные нелинейным образом.

# Функции активации



# Теорема Цыбенко

## Теорема

Если  $\sigma(z)$  — сигмоида, тогда для любой непрерывной на  $[0, 1]^n$  функции  $f(x)$  существуют такие значения параметров  $H$ ,  $\alpha_h \in \mathbb{R}$ ,  $w_h \in \mathbb{R}^n$ ,  $w_0 \in \mathbb{R}$ , что двухслойная сеть

$$a(x) = \sum_{h=1}^H \alpha_h \sigma(\langle x, w_h \rangle - w_0)$$

равномерно приближает  $f(x)$  с любой точностью  $\varepsilon$ :

$$|a(x) - f(x)| < \varepsilon, \text{ для всех } x \in [0, 1]^n.$$

# Пайплайн обучения



# Пайплайн обучения

- Подготовить данные;

# Данные

С помощью нейронных сетей мы решили проблему с выделением признаков. Но осталась проблема, которая мешает ускорению развития нейронных сетей, какая?

# Данные

С помощью нейронных сетей мы решили проблему с выделением признаков. Но осталась проблема, которая мешает ускорению развития нейронных сетей, какая?


Небольшое (по меркам интернета) количество размеченных данных. При этом большинство больших датасетов закрытые, а владеют ими большие компании.

# Данные

Как размечают данные большие компании?


# Данные

Как размечают данные большие компании? Например, капчи



# Данные

Другой вариант — специализированные сайты.



Пример: <https://tasks.yandex.ru>

# Данные

Как можно искусственно увеличивать количество данных?

# Данные

Как можно искусственно увеличивать количество данных?  
Аугментации.





# Пайплайн обучения

- Подготовить данные;

# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;

# Dataloader

Dataloader подает данные в модель во время обучения. Что он позволяет?

# Dataloader

Dataloader подает данные в модель во время обучения. Что он позволяет?

- Перемешивать данные;
- Указывать число потоков;
- Изменять размер батча.

# Dataloader

Dataloader подает данные в модель во время обучения. Что он позволяет?

- Перемешивать данные;
- Указывать число потоков;
- Изменять размер батча.

Для чего нужно разбиение данных на батчи?

# Dataloader

Dataloader подает данные в модель во время обучения. Что он позволяет?

- Перемешивать данные;
- Указывать число потоков;
- Изменять размер батча.

Для чего нужно разбиение данных на батчи?

- Ускоряет обучение за счет векторизации;
- Стабилизирует обновление градиентов.

# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;


# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;
- Подготовить модель;



# Модель

Модель — конструктор, который собирается из слоев.  
Например, AlexNet:



# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;
- Подготовить модель;

# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;
- Подготовить модель;
- Перевести модель в режим обучения;

# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;
- Подготовить модель;
- Перевести модель в режим обучения;
- Выбрать подходящий loss;

# Loss

Классификация (Cross-entropy):

$$\mathcal{L}_{\text{ce}}(y, \hat{y}) = - \sum_{i=1}^n y_i \log \hat{y}_i.$$

Регрессия (MSE):

$$\mathcal{L}_{\text{mse}}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$


# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;
- Подготовить модель;
- Перевести модель в режим обучения;
- Выбрать подходящий loss;

# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;
- Подготовить модель;
- Перевести модель в режим обучения;
- Выбрать подходящий loss;
- На каждой итерации необходимо делать backpropagation;

# Backpropagation





# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;
- Подготовить модель;
- Перевести модель в режим обучения;
- Выбрать подходящий loss;
- На каждой итерации необходимо делать backpropagation;

# Пайплайн обучения

- Подготовить данные;
- Загрузить данные в Dataloader;
- Подготовить модель;
- Перевести модель в режим обучения;
- Выбрать подходящий loss;
- На каждой итерации необходимо делать backpropagation;
- На каждой итерации необходимо делать шаг оптимизатора.

# Оптимизатор

## Алгоритм Adam

**Вход:** стартовая точка  $x^0 \in \mathbb{R}^d$ , сглаженные суммы квадратов компонент субградиентов  $G_i^{-1} = 0$ , сглаженные суммы субградиентов  $v^{-1} = 0$ , параметры  $\beta_1, \beta_2 \in [0, 1]$ ,  $\epsilon \sim 10^{-8}$ ,  $D_i > 0$ , количество итераций  $K$

- 1: **for**  $k = 0, 1, \dots, K - 1$  **do**
- 2:   Вычислить  $g^k \in \partial f(x^k)$
- 3:   Вычислить  $v^k = \beta_1 v^{k-1} + (1 - \beta_1) g^k$
- 4:   Вычислить  $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
- 5:   Для каждой координаты:  $G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2$
- 6:   Вычислить  $\hat{G}^k = G^k / (1 - \beta_2^{k+1})$
- 7:   Для каждой координаты:  $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k + \epsilon}} \hat{v}_i^k$
- 8: **end for**

**Выход:**  $\frac{1}{K} \sum_{k=0}^K x^k$

# Оптимизатор

Спасибо за внимание!