

C1 Матрично-векторное дифференцирование

Для обучения моделей мы будем минимизировать ту или иную функцию потерь. Для приближенного поиска минимума функции пользуются численными методами оптимизации, о которых мы поговорим позднее. В численных методах оптимизации текущее приближение оптимума x^k обновляется за счёт сдвига вдоль некоторого направления d^k . В простейшем случае, это выглядит как

$$x^{k+1} = x^k + \alpha_k d^k,$$

где α_k, d^k — длина и направление шага на k -ой итерации. Чтобы такое обновление имело смысл, пространство параметров модели должно быть наделено линейной структурой, то есть быть замкнуто относительно сложения элементов и умножения на число. Кроме того, для оценки скорости сходимости методов на пространстве параметров должна быть задана норма.

Определение C1.1. *Линейным нормированным пространством (ЛНП) будем называть пару $(U, \|\cdot\|)$, где U — линейное пространство, а $\|\cdot\| : U \rightarrow \mathbb{R}_+$ — действующая на нём норма.*

Замечание C1.1. В основном мы будем рассматривать пространства $\mathbb{R}^d, \mathbb{R}^{n \times d}$ и вторую норму на них.

Замечание C1.2. Обычно маленькая латинская буква будет означать вектор, а большая — матрицу.

C1.1 Первый дифференциал

Самые распространённые на практике численные методы используют градиент (например, градиентный спуск или ускоренный градиентный метод) или гессиан (например, метод Ньютона) целевой функции для построения направления спуска d^k . В этом разделе мы введём формальное определение дифференцирования в конечномерных ЛНП, а также определим градиент и гессиан функции. Кроме этого, мы также подробно поговорим о частных случаях — действительных пространствах векторов и матриц.

Определение C1.2. Пусть U, V — конечномерные ЛНП. Линейный оператор $df(x) : U \rightarrow V$ называется *производной функции $f : U \rightarrow V$ в точке $x \in U$* , если для $h \in U$ выполнено

$$f(x+h) = f(x) + df(x)[h] + o(\|h\|), \quad \|h\| \rightarrow 0.$$

Сама функция f в случае существования такого оператора называется *дифференцируемой по Фреше в точке x* . $df(x)[h]$ называют *дифференциалом функции f в точке x* .

Замечание C1.3. $df(x)[h]$ — действие производной функции на h .

Замечание C1.4. Иногда для обозначения приращения h мы будем использовать dx .

Пример C1.1. Найдите дифференциал функции $f : \mathbb{R} \rightarrow \mathbb{R} : f(x) = x^2$.

Решение. Воспользуемся определением дифференцируемости по Фреше:

$$(x+h)^2 = x^2 + 2xh + h^2 \implies df(x)[h] = 2xh,$$

так как $h^2 = o(|h|)$ при $|h| \rightarrow 0$. ■

Определение C1.2 накладывает достаточно сильные условия на функцию. Оно проверяет существование единого линейного приближения вдоль всех направлений. Можно рассматривать более слабый вариант производной.

Определение C1.3. Пусть U, V — конечномерные ЛНП. Оператор $\tilde{d}f(x) : U \rightarrow V$ называется *производной по направлению функции $f : U \rightarrow V$ в точке $x \in U$* , если существует предел

$$\tilde{d}f(x)[h] = \lim_{t \rightarrow 0} \frac{f(x + th) - f(x)}{t}, \quad \forall h \in U.$$

Сама функция f в случае существования такого оператора называется *дифференцируемой по Гато в точке x* .

Замечание C1.5. Пусть $\{e_i\}_{i=1}^d$ — ортонормированный базис в U . Тогда $\tilde{d}f(x)[e_i]$ называется *i -ой частной производной f в точке x* .

Из дифференцируемости по Фреше следует дифференцируемость по Гато, однако обратное неверно.

Замечание C1.6. В дальнейшем, дифференцируемость функции будем понимать в смысле Фреше.

В $\mathbb{R}^d$ и $\mathbb{R}^{n \times d}$ действие оператора производной единственным образом представляется через скалярное произведение.

Теорема C1.1. Пусть $df(x) : U \rightarrow \mathbb{R}$ — линейный функционал, действующий на конечномерном линейном пространстве U , снабжённом скалярным произведением. Тогда существует единственный $g_f(x) \in U$, такой, что

$$df(x)[h] = \langle g_f(x), h \rangle.$$

Этот факт является частным случаем более общей теоремы Рисса о представлении линейного функционала для произвольного гильбертова пространства.

Замечание C1.7. В случае ортонормированного базиса $g_f(x)$ — вектор частных производных $\frac{\partial f}{\partial x_i}$. Он называется *градиентом* функции и обозначается как $\nabla f(x)$.

Замечание C1.8. Рассмотрим $f : \mathbb{R}^d \rightarrow \mathbb{R}^n$. Представим

$$f(x) = (f_1(x), \dots, f_n(x))^{\top}.$$

Каждая координатная функция — понятное с точки зрения производной функция $\mathbb{R}^d \rightarrow \mathbb{R}$. Получается, производная функции $\mathbb{R}^d \rightarrow \mathbb{R}^n$ — матрица Якоби, этого отображения $(J_{ij}(x) = \frac{\partial f_i}{\partial x_j}(x))$. В общем случае отображения матрицы в матрицу для построения градиента достаточно найти все частные производные в виде тензора

$$\left\{ \frac{\partial f_{ij}}{\partial x_{kl}}(x) \right\}_{ijkl}.$$

Рассуждения, приведённые в Замечании C1.8, сформулируем в виде таблицы.

Вход \ Выход	Скаляр $\mathbb{R}$	Вектор $\mathbb{R}^d$
Скаляр $\mathbb{R}$	$\nabla f(x)$ скаляр, h скаляр	$\nabla f(x)$ вектор, h скаляр
Вектор $\mathbb{R}^d$	$\nabla f(x)$ вектор, h вектор	$\nabla f(x)$ матрица, h вектор
Матрица $\mathbb{R}^{n \times d}$	$\nabla f(x)$ матрица, h матрица	$\nabla f(x)$ тензор, h матрица

Утверждение C1.1. Из формулы градиента верно, что

$$df(x) = (\nabla f(x))^\top dx \iff \nabla f(x) = J_f^\top(x).$$

Доказательство. Утверждение следует из покомпонентного представления градиента и матрицы Якоби. ■

C1.2 Второй дифференциал

Пусть U, V — конечномерные ЛНП. Пусть отображение $f : U \rightarrow V$ дифференцируемо в каждой точке $x \in U$. Второй дифференциал будем определять, фиксируя приращение h_1 и рассматривая первый дифференциал как функцию от x :

$$g(x) = df(x)[h_1].$$

Определение C1.4. Если в некоторой точке x функция $g(x) = df(x)[h_1]$ дифференцируема, то билинейный оператор $dg(x)[h_2] = d(df(x)[h_1])[h_2]$ называется *вторым дифференциалом*.

Замечание C1.9. Если $f : \mathbb{R}^d \rightarrow \mathbb{R}$, то второй дифференциал — билинейная форма, имеющая вид

$$d^2f(x)[h_1, h_2] = \langle G_f(x)h_1, h_2 \rangle.$$

В случае стандартного базиса $G_f(x)$ — матрица вторых производных $\frac{\partial^2 f}{\partial x_i \partial x_j}$. Она называется гессианом отображения и обозначается $\nabla^2 f(x)$.

Утверждение C1.2. Из формулы гессиана верно, что

$$d(\nabla f(x)) = (\nabla^2 f(x))^\top dx \iff \nabla^2 f(x) = J_{\nabla f}^\top(x).$$

Доказательство. Утверждение следует из покомпонентного представления градиента и матрицы Якоби. ■

С1.3 Примеры и задачи

Известные из курса математического анализа правила дифференцирования (производная произведения, частного, композиции) сохраняются. Мы напомним их, не обращаясь к доказательствам.

Утверждение С1.3. Пусть U, V — ЛНП. Тогда для векторных и матричных дифференциалов справедливо:

1. $d(\alpha x) = \alpha dx, \alpha \in \mathbb{R}$;
2. $d(x + y) = dx + dy$;
3. $d\langle x, y \rangle = \langle dx, y \rangle + \langle x, dy \rangle$;
4. $d(f(x)g(x)) = d(f(x))g(x) + f(x)d(g(x))$ ($f : U \rightarrow \mathbb{R}, g : U \rightarrow \mathbb{R}$);
5. $d\left(\frac{f(x)}{\phi(x)}\right) = \frac{\phi(x)df(x) - f(x)d\phi(x)}{\phi^2(x)}$ ($f : U \rightarrow \mathbb{R}, \phi : \mathbb{R} \rightarrow \mathbb{R} \setminus \{0\}$);
6. $d(g \circ f(x)) = dg(f(x))[df(x)]$ ($f : U \rightarrow f(U), g : f(U) \rightarrow V$);
7. $J_{g \circ f}(x) = J_g(f(x))J_f(x)$ ($f : U \rightarrow f(U), g : f(U) \rightarrow V$).

Дополнительно для матричных дифференциалов справедливо:

1. $d(AXB) = A dX B$;
2. $d(XY) = (dX)Y + X(dY)$;
3. $d(X^\top) = (dX)^\top$.

Перед тем как перейти к вычислению нетривиальных примеров, придётся воспользоваться определением и получить выражения для базовых градиентов.

Пример С1.2. Справедливы следующие выражения:

- $d\langle c, x \rangle = \langle c, dx \rangle \implies \nabla(\langle c, x \rangle) = c$;
- $d\langle Ax, x \rangle = \langle (A + A^\top)x, dx \rangle \implies \nabla(\langle Ax, x \rangle) = (A + A^\top)x$;
- $d(X^{-1}) = -X^{-1} dX X^{-1}$ при $\det X \neq 0$;
- $d \det(X) = \langle \det(X)X^{-\top}, dX \rangle$ при $\det X \neq 0 \implies \nabla(\det(X)) = \det(X)X^{-\top}$.

С1.3.1 Дифференцирование по вектору

В машинном обучении широко известен метод наименьших квадратов (МНК). По матрице признаков $\tilde{A}$ и вектору параметров x требуется линейно приблизить целевой вектор $\tilde{b}$. Для решения этой задачи требуется вычислять градиент невязки

$$f(x) = \frac{1}{2} \|\tilde{A}x - \tilde{b}\|_2^2 = \frac{1}{2} \langle \tilde{A}x, \tilde{A}x \rangle - \langle \tilde{A}x, \tilde{b} \rangle + \frac{1}{2} \|\tilde{b}\|_2^2$$

Если мы введём обозначения $A = \tilde{A}^\top \tilde{A}$, $b = -\tilde{A}^\top \tilde{b}$, $c = \frac{1}{2} \|\tilde{b}\|_2^2$, то вычисление градиента невязки эквивалентно вычислению градиента функции

$$f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c.$$

Пример C1.3. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c, \quad A \in \mathbb{R}^{d \times d}, \quad b \in \mathbb{R}^d, \quad c \in \mathbb{R}.$$

Решение. Найдём первый дифференциал

$$\begin{aligned} df(x) &= d \left(\frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c \right) = \frac{1}{2} \langle (A + A^\top)x, dx \rangle + \langle b, dx \rangle + 0 \\ &= \left\langle \frac{1}{2} (A + A^\top)x + b, dx \right\rangle. \end{aligned}$$

Приведя к стандартному виду $df(x) = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \frac{1}{2} (A + A^\top)x + b.$$

Для поиска гессиана фиксируем первое приращение dx_1 у первого дифференциала и берём уже от него ещё один дифференциал

$$d^2 f(x) = d \left\langle \frac{1}{2} (A + A^\top)x + b, dx_1 \right\rangle = \left\langle \frac{1}{2} (A + A^\top) dx, dx_1 \right\rangle.$$

Переносим и транспонируем матрицу в скалярном произведении, но поскольку $A + A^\top$ симметричная, то она не меняется:

$$d^2 f(x) = \left\langle dx, \frac{1}{2} (A + A^\top)^\top dx_1 \right\rangle = \left\langle \frac{1}{2} (A + A^\top) dx_1, dx \right\rangle.$$

Следовательно, приведя к стандартному виду $d^2 f(x) = \langle \nabla^2 f(x) dx_1, dx \rangle$, получаем гессиан

$$\nabla^2 f(x) = \frac{1}{2} (A + A^\top).$$

■

Замечание C1.10. Заметим, что в случае если A симметричная, то

$$\nabla f(x) = Ax + b, \quad \nabla^2 f(x) = A.$$

Пример C1.4. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \setminus \{0\} \rightarrow \mathbb{R}$:

$$f(x) = \log \langle Ax, x \rangle, \quad A \in \mathbb{S}_{++}^d.$$

Решение. Найдём первый дифференциал

$$df(x) = d \log \langle Ax, x \rangle = \frac{1}{\langle Ax, x \rangle} d \langle Ax, x \rangle = \frac{2 \langle Ax, dx \rangle}{\langle Ax, x \rangle} = \left\langle \frac{2Ax}{\langle Ax, x \rangle}, dx \right\rangle.$$

Приведя к стандартному виду $df(x) = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \frac{2Ax}{\langle Ax, x \rangle}.$$

Теперь найдём дифференциал градиента

$$\begin{aligned} d\left(\frac{2Ax}{\langle Ax, x \rangle}\right) &= \frac{d(2Ax)\langle Ax, x \rangle - (2Ax)d\langle Ax, x \rangle}{\langle Ax, x \rangle^2} = \frac{2\langle Ax, x \rangle A dx - 4Ax\langle Ax, dx \rangle}{\langle Ax, x \rangle^2} \\ &= \left(\frac{2A}{\langle Ax, x \rangle} - \frac{4Ax x^\top A}{\langle Ax, x \rangle^2}\right) dx = J_{\nabla f}(x) dx. \end{aligned}$$

Поскольку $\nabla^2 f(x) = J_{\nabla f}^\top(x)$, а гессиан симметричен из-за непрерывности, то

$$\nabla^2 f(x) = \frac{2A}{\langle Ax, x \rangle} - \frac{4Ax x^\top A}{\langle Ax, x \rangle^2}.$$

■

Далее рассмотрим модель логистической регрессии — модель машинного обучения для задачи разделения двух классов. Её обучение может сводиться к оптимизации функции

$$f(x) = \log(1 + \exp(\langle x, a \rangle)).$$

Пример C1.5. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \log(1 + \exp(\langle x, a \rangle)), \quad a \in \mathbb{R}^d.$$

Решение. Найдём первый дифференциал

$$\begin{aligned} df(x) &= d \log(1 + \exp(\langle x, a \rangle)) = \frac{1}{1 + \exp(\langle x, a \rangle)} d(1 + \exp(\langle x, a \rangle)) \\ &= \frac{\exp(\langle x, a \rangle)}{1 + \exp(\langle x, a \rangle)} d\langle x, a \rangle = \left\langle \frac{\exp(\langle x, a \rangle)}{1 + \exp(\langle x, a \rangle)} a, dx \right\rangle. \end{aligned}$$

Для удобства введём сигмоиду

$$\sigma(x) := \frac{1}{1 + \exp(-x)}.$$

При этом заметим, что $\sigma(-x) = 1 - \sigma(x)$ и $\sigma'(x) = \sigma(x)(1 - \sigma(x))$. После этого приведём $df(x)$ к стандартному виду и получим

$$\nabla f(x) = \sigma(\langle x, a \rangle) a.$$

Таким образом, градиент $\nabla f(x)$ — вектор, коллинеарный вектору a с коэффициентом $\sigma(\langle a, x \rangle) \in (0, 1)$. От точки x зависит лишь длина градиента, но не направление.

Теперь посчитаем второй дифференциал, зафиксировав приращение dx_1 первого. Имеем

$$\begin{aligned} d^2 f(x) &= d\langle \sigma(\langle x, a \rangle) a, dx_1 \rangle = \langle d\sigma(\langle x, a \rangle) a, dx_1 \rangle = \langle \sigma'(\langle x, a \rangle) d\langle x, a \rangle a, dx_1 \rangle \\ &= \langle \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \langle dx, a \rangle a, dx_1 \rangle \\ &= \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \langle \langle dx, a \rangle a, dx_1 \rangle \\ &= \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) (dx^\top a a^\top dx_1) \\ &= \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \langle a a^\top dx_1, dx \rangle. \end{aligned}$$

Получим

$$\nabla^2 f(x) = \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) a a^\top.$$

Заметим, что $\nabla^2 f(x)$ — одноранговая матрица, пропорциональная $a a^\top$ с коэффициентом $\sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \in (0, 0.25)$. Точка x влияет лишь на коэффициент. ■

С1.3.2 Дифференцирование по матрице

Для подсчёта градиентов по матрицам активно применяются производные таких функций, как $\det, \text{Tr}, X^{-1}$. Приведем несколько примеров.

Пример С1.6. Найдите $\nabla f(X)$ функции $f : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$:

$$f(X) = \|AX - B\|_F, \quad A \in \mathbb{R}^{m \times n}, \quad B \in \mathbb{R}^{m \times d}.$$

Решение. Сначала отдельно вычислим $d\|X\|_F$:

$$d\|X\|_F = d\langle X, X \rangle^{1/2} = \frac{d\langle X, X \rangle}{2\langle X, X \rangle^{1/2}} = \left\langle \frac{2X}{2\langle X, X \rangle^{1/2}}, dX \right\rangle = \left\langle \frac{X}{\|X\|_F}, dX \right\rangle.$$

Тогда первый дифференциал

$$\begin{aligned} df(X) &= d\|AX - B\|_F = \left\langle \frac{AX - B}{\|AX - B\|_F}, d(AX - B) \right\rangle = \left\langle \frac{AX - B}{\|AX - B\|_F}, A dX \right\rangle \\ &= \text{Tr} \left(\frac{(AX - B)^\top}{\|AX - B\|_F} A dX \right) = \text{Tr} \left(\left(\frac{A^\top (AX - B)}{\|AX - B\|_F} \right)^\top dX \right) \\ &= \left\langle \frac{A^\top (AX - B)}{\|AX - B\|_F}, dX \right\rangle. \end{aligned}$$

Тогда градиент

$$\nabla f(X) = \frac{A^\top (AX - B)}{\|AX - B\|_F}. \quad \blacksquare$$

Пример C1.7. Найдите $\nabla f(X)$ функции $f : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$:

$$f(X) = \text{Tr}(AX^\top X), \quad A \in \mathbb{R}^{d \times d}.$$

Решение. Перепишем след через скалярное произведение

$$f(X) = \langle I_d, AX^\top X \rangle.$$

Найдём первый дифференциал

$$\begin{aligned} df(X) &= d\langle I_d, AX^\top X \rangle = \langle I_d, A d(X^\top X) \rangle = \langle I_d, A dX^\top X \rangle + \langle I_d, AX^\top dX \rangle \\ &= \text{Tr}(A dX^\top X) + \langle XA^\top, dX \rangle = \text{Tr}(XA dX^\top) + \langle XA^\top, dX \rangle \\ &= \langle XA, dX \rangle + \langle XA^\top, dX \rangle = \langle XA + XA^\top, dX \rangle. \end{aligned}$$

Тогда градиент

$$\nabla f(X) = XA + XA^\top.$$

■

Пример C1.8. Найдите $\nabla f(X)$ и $d^2 f(X)$ функции $f : \mathbb{S}_{++}^d \rightarrow \mathbb{R}$:

$$f(X) = \log(\det(X)).$$

Решение. Найдём первый дифференциал

$$df(X) = d\log(\det(X)) = \frac{d(\det(X))}{\det(X)} = \frac{\det(X) \langle X^{-1}, dX \rangle}{\det(X)} = \langle X^{-1}, dX \rangle.$$

Тогда градиент

$$\nabla f(X) = X^{-1}.$$

Теперь посчитаем второй дифференциал, зафиксировав приращение dX_1 первого

$$d^2 f(X) = \langle dX^{-1}, dX_1 \rangle = -\langle X^{-1} dX X^{-1}, dX_1 \rangle.$$

Мы получили билинейную форму от dX, dX_1 , выписывать тензор производных в явном виде мы не будем. Вместо этого посмотрим, является ли эта форма отрицательно полуопределённой. В следующих параграфах станет понятно, зачем мы проверяем это условие. Возьмём $H \in \mathbb{S}^d$ из исходного пространства. Поскольку $X \in \mathbb{S}_{++}^d$, то $X^{-1} \in \mathbb{S}_{++}^d$. Матрицу X^{-1} можно разложить на произведение двух одинаковых матриц, обозначим их $X^{-1/2}$, то есть $X^{-1} = X^{-1/2} X^{-1/2}$. Такое разложение можно получить, перейдя в ортонормированный базис из собственных векторов V , который всегда существует для симметричных матриц, при этом все собственные значения будут положительными:

$$X^{-1} = V \Lambda V^\top \implies X^{-1/2} = V \sqrt{\Lambda} V^\top.$$

Тогда

$$\begin{aligned}
d^2 f(X) [H, H] &= -\langle X^{-1} H X^{-1}, H \rangle = -\text{Tr}(X^{-1} H X^{-1} H) \\
&= -\text{Tr}\left(X^{-1/2} X^{-1/2} H X^{-1/2} X^{-1/2} H\right) \\
&= -\text{Tr}\left(X^{-1/2} H X^{-1/2} X^{-1/2} H X^{-1/2}\right) \\
&= -\langle X^{-1/2} H X^{-1/2}, X^{-1/2} H X^{-1/2} \rangle \\
&= -\|X^{-1/2} H X^{-1/2}\|_F^2 \leq 0.
\end{aligned}$$

■

С1.3.3 Другие примеры

Помимо классических примеров, когда нужно продифференцировать функцию по вектору/матрице, проводя алгоритмические действия, бывают и менее тривиальные. В этом разделе мы посвятим их рассмотрению немного времени.

В нейронных сетях часто встречается функция softmax, которая позволяет отобразить вектор из d координат в распределение вероятностей на d исходах:

$$\text{softmax}(x) := \left(\frac{\exp(x_1)}{\sum_{i=1}^d \exp(x_i)}, \dots, \frac{\exp(x_d)}{\sum_{i=1}^d \exp(x_i)} \right)^\top.$$

Пример С1.9. Найдите матрицу Якоби $J(x)$ функции $s : \mathbb{R}^d \rightarrow \mathbb{R}^d$:

$$s(x) = \left(\frac{\exp(x_1)}{\sum_{i=1}^d \exp(x_i)}, \dots, \frac{\exp(x_d)}{\sum_{i=1}^d \exp(x_i)} \right)^\top.$$

Решение. Считаем частные производные по определению

- При $k \neq j$

$$\frac{\partial s_k}{\partial x_j} = \frac{\partial}{\partial x_j} \frac{\exp(x_k)}{\sum_{i=1}^d \exp(x_i)} = -\frac{\exp(x_k) \exp(x_j)}{(\sum_{i=1}^d \exp(x_i))^2} = -s_k \cdot s_j,$$

- при $k = j$

$$\begin{aligned}
\frac{\partial s_j}{\partial x_j} &= \frac{\partial}{\partial x_j} \frac{\exp(x_j)}{\sum_{i=1}^d \exp(x_i)} = \frac{\exp(x_j)(\sum_{i=1}^d \exp(x_i)) - \exp(x_j) \frac{\partial}{\partial x_j} (\sum_{i=1}^d \exp(x_i))}{(\sum_{i=1}^d \exp(x_i))^2} \\
&= \frac{\exp(x_j)}{\sum_{i=1}^d \exp(x_i)} - \frac{\exp(x_j) \exp(x_j)}{(\sum_{i=1}^d \exp(x_i))^2} = s_j(1 - s_j).
\end{aligned}$$

Таким образом, получаем

$$J_{k,j} = \begin{cases} -s_k \cdot s_j, & k \neq j; \\ s_j(1 - s_j), & k = j. \end{cases}$$

■